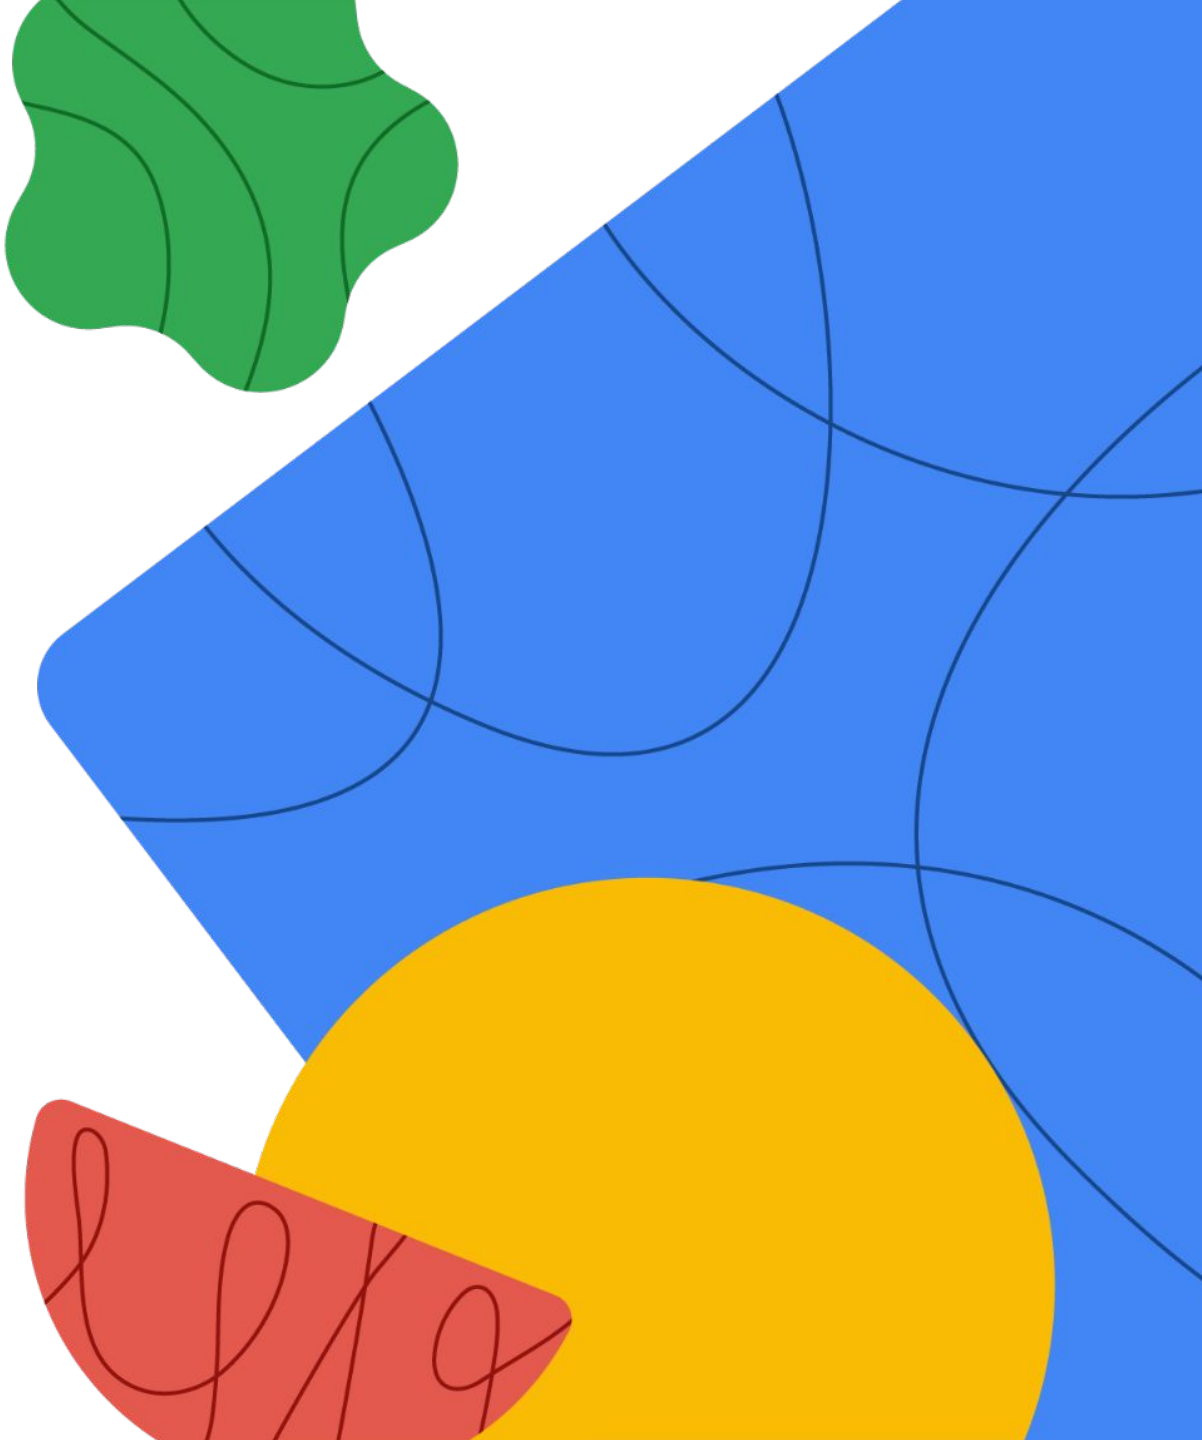
Google Cloud

モジュール 03
生成 AI: 取り巻く環境への対応



機密 / 専有情報

生成 AI リーダー学習プログラム



01 生成 AI: chatbot を超えて

02 生成 AI: 基本概念の理解

03 生成 AI: 取り巻く環境への対応

04 生成 AI アプリ: 働き方の変革

05 生成 AI エージェント: 組織の変革

Google Cloud

お昼休み明け！午後のパワーを注入しよう ⚡

全 5 モジュールのうち、前半 2 つをクリア！
残り 3 モジュール（約 5 時間）を乗り切る今の気分は？

02

完了したモジュール

基礎と環境理解はバッチリ！順調なスタートです。

03

残りのモジュール

実務での活用と変革へ、いよいよ本番突入！

~5h

残りの目安時間

じっくり深く学べる充実の午後。マイペースでいこう！



💡 みんなで今の気分を Slido でシェア！

「準備万端！」「コーヒー淹れてきました！」「お腹いっぱいで眠いかも.？🥱」
どんな気分でも大歓迎！お互いにエネルギーを送り合って、午後も楽しく進めましょう！

午後の重要テクノロジー略語ガイド

午後の難関トピックで頻出する 4 大キーワード（RAG・CoT・ReAct・Agent）の直感理解

略語 / 正式名称	日本語ワンフレーズ解説（直感理解）	ここを押さえる！（試験・実務ポイント）
RAG Retrieval-Augmented Generation	**社内資料を検索して回答に引用させる技術**	モデルの再学習なしに最新・独自情報に対応し、ハルシネーションを防止
CoT Chain-of-Thought	**段階的に考えさせて推論ミスを防ぐ指示技法**	「ステップ順に考えて」と促すプロンプト。複雑な計算や論理思考で精度向上
ReAct Reasoning + Acting	**思考とツール実行を交互に繰り返し目標を達成する仕組み**	「考える→検索/ API 実行→結果を確認」の自律ループで動くエージェントの基本構造
Agent Search Grounding & Vector Search	**Google 検索基盤と直結し出典付き回答を自動化するサービス**	自前で検索パイプラインを作らずに高精度 RAG を実現

★午後の攻略ポイント（見分け方のコツ）

午後は「モデル単体で解く技術（CoT）」と「外部ツールや DB と連携する技術（RAG / ReAct / Agent）」の境界線が頻出です。迷ったら「外部へアクセスしているか？」を判断軸にしましょう。

モジュールの目的

01 生成 AI を取り巻く環境のレイヤについて説明する。

02 生成 AI を取り巻く環境の中から、ビジネスニーズとイノベーションに対応するためのエントリ ポイントを特定する。

03 Google Cloud の生成 AI ポートフォリオのコンポーネントを説明する。

04 Google Cloud の AI に最適化されたリソースが生成 AI の開発をどのようにサポートするのかを説明する。

05 特定の用途において考慮すべきビジネス上の要因を説明する。





アジェンダ

01 生成 AI を取り巻く環境

02 生成 AI のアプリケーションとエージェント

03 生成 AI のプラットフォーム、モデル、インフラストラクチャ

04 生成 AI プロジェクトのリソースと管理



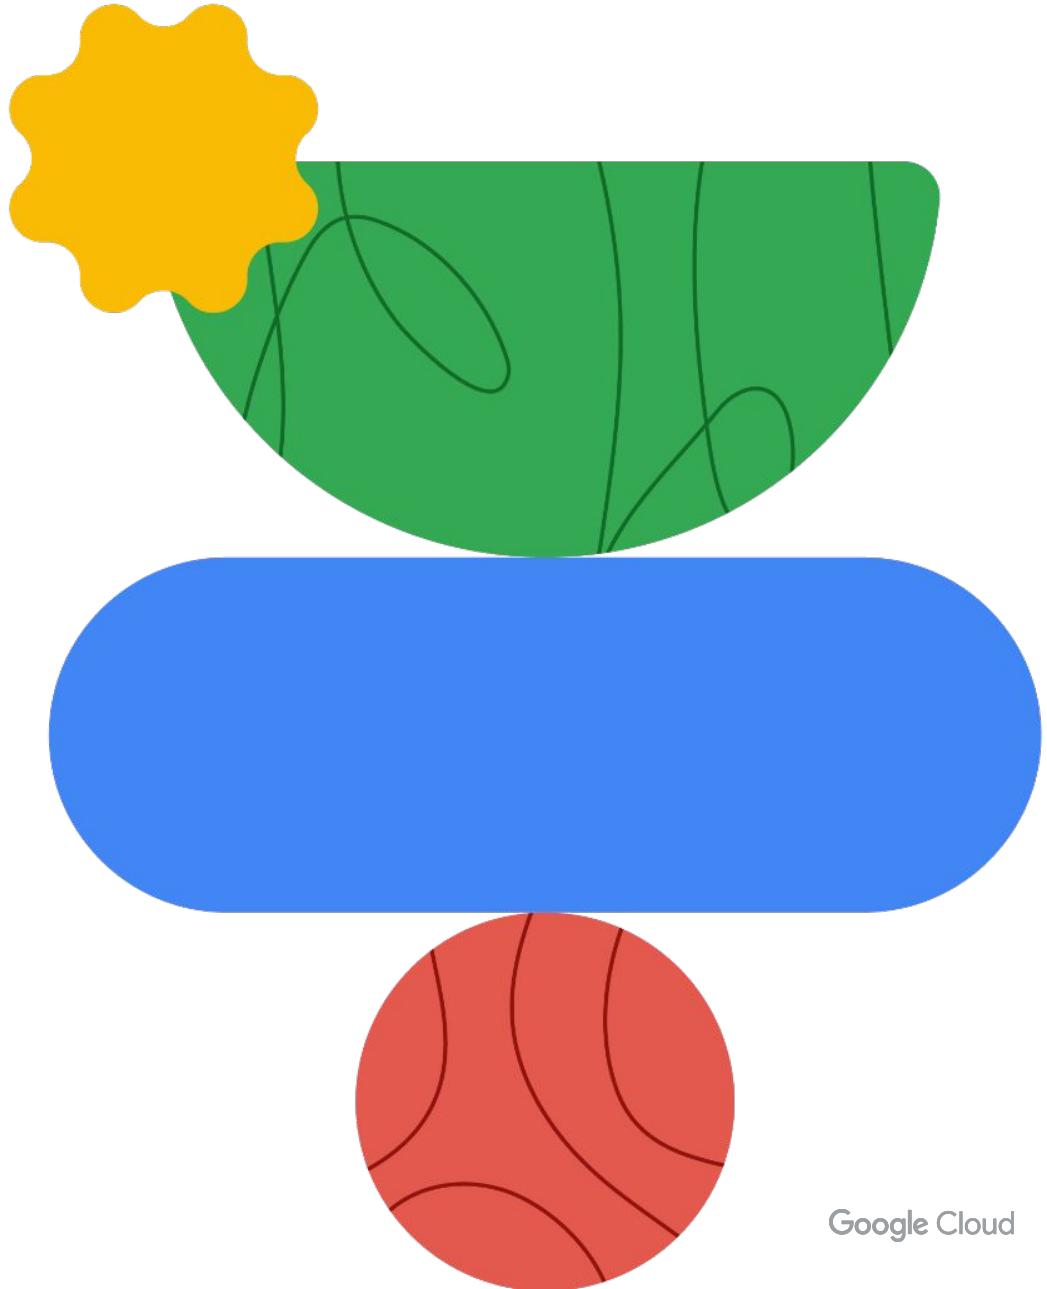
機密 / 専有情報



生成 AI を取り巻く環境

機密 / 専有情報

生成 AI のレイヤを理解する



生成 AI の構成要素

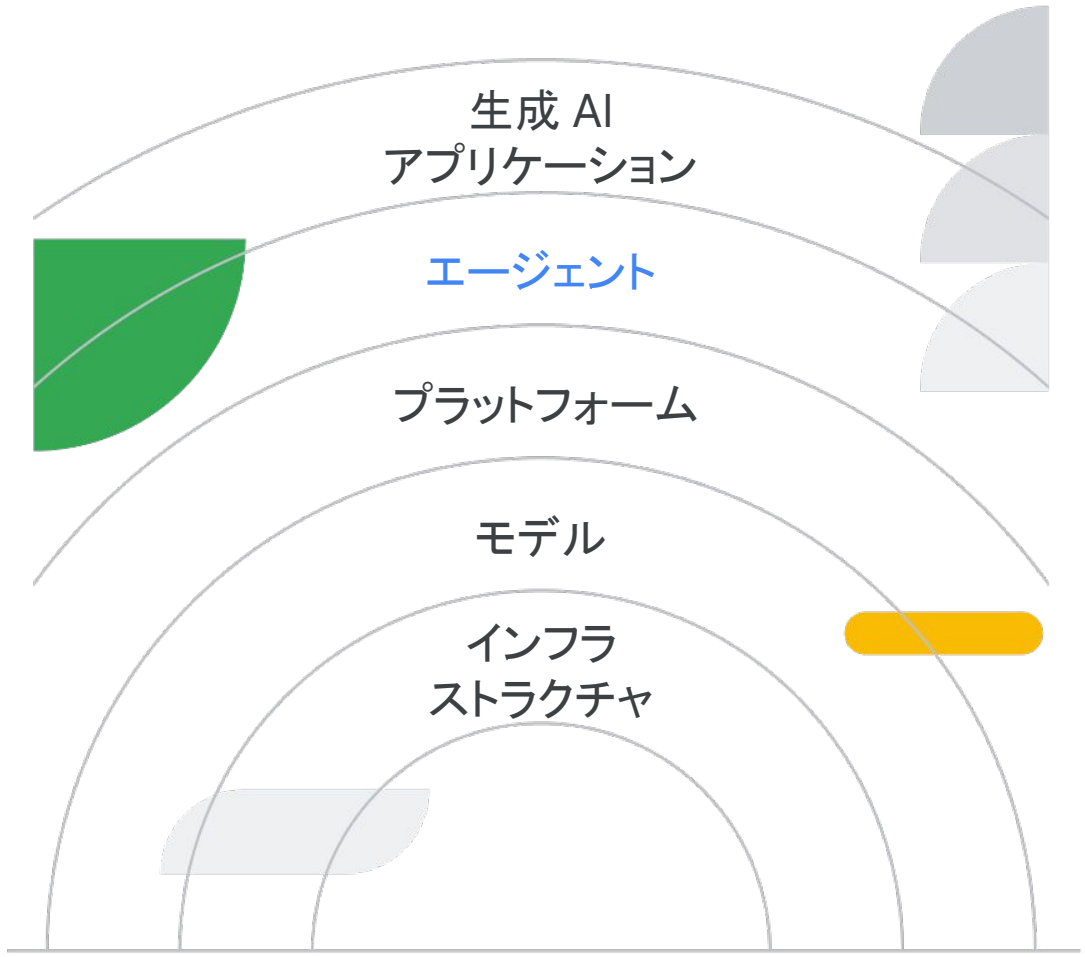


生成 AI の構成要素: 生成 AI アプリケーション



- 生成 AI アプリケーションは、生成 AI のユーザー向けの部分（フロントエンド）。
- ユーザーが AI の機能とやり取りし、その機能を活用できるようにする。
- 例: Gemini アプリ、Google Workspace with Gemini、Gemini Notebook

生成 AI の構成要素: エージェント



- エージェントは、入力と利用可能なツールに基づいて、目標を達成する最適な方法を学習するソフトウェア。
- 自律的なアクションに焦点を当てている。
- 例: カスタマー エージェント、コード エージェント、データ エージェントなど

生成 AI の構成要素: プラットフォーム



- プラットフォームは、エージェントとモデルがやり取りするためのツールとサービスを提供する。
- API、データ マネジメント機能、モデルのデプロイツールを提供する。

生成 AI の構成要素: モデル



- AI モデルはエージェントの頭脳として機能する。
- AI モデルは、大量のデータでトレーニングされた複雑なアルゴリズム。
- 新しいコンテンツの生成、言語の翻訳、質問への回答などを行う。
- 例: 大規模言語モデル（LLM）、画像認識モデル、レコメンデーション システム

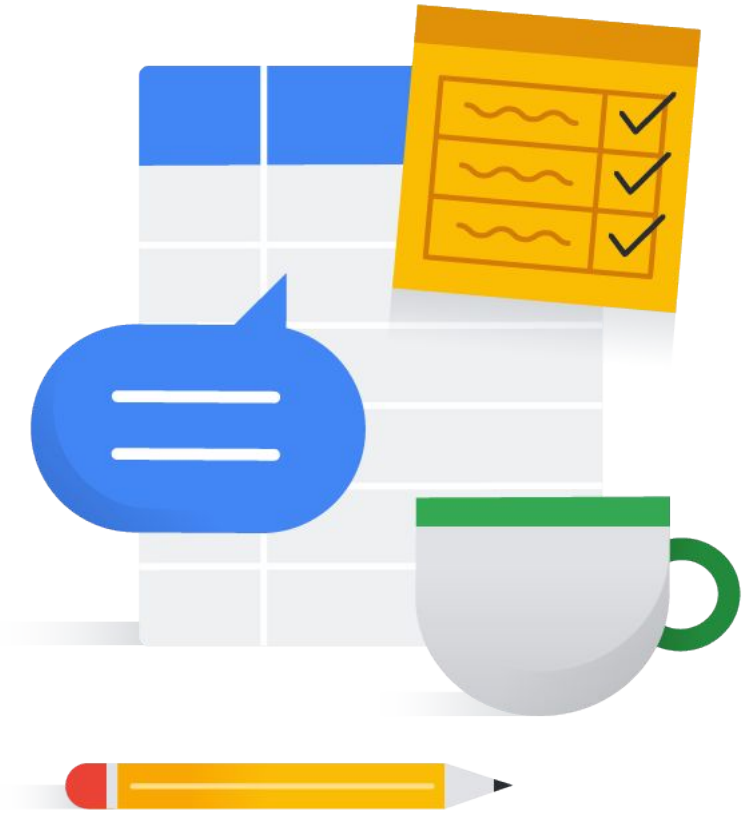
生成 AI の構成要素: インフラストラクチャ



- インフラストラクチャは、生成 AI に必要なコア コンピューティング リソースを提供する。
- AI モデルとトレーニング データの保存および実行に必要なハードウェアとソフトウェアが含まれる。

重要ポイント

- 生成 AI は、インフラストラクチャから生成 AI アプリケーションまでの、相互に連携する複数のレイヤに依存している。
- これらのレイヤを理解することで、十分な情報に基づく意思決定が可能になり、ビジネス イノベーションを実現できる。





アジェンダ

01 生成 AI を取り巻く環境

02 生成 AI のアプリケーションとエージェント

03 生成 AI のプラットフォーム、モデル、インフラストラクチャ

04 生成 AI プロジェクトのリソースと管理



機密 / 専有情報

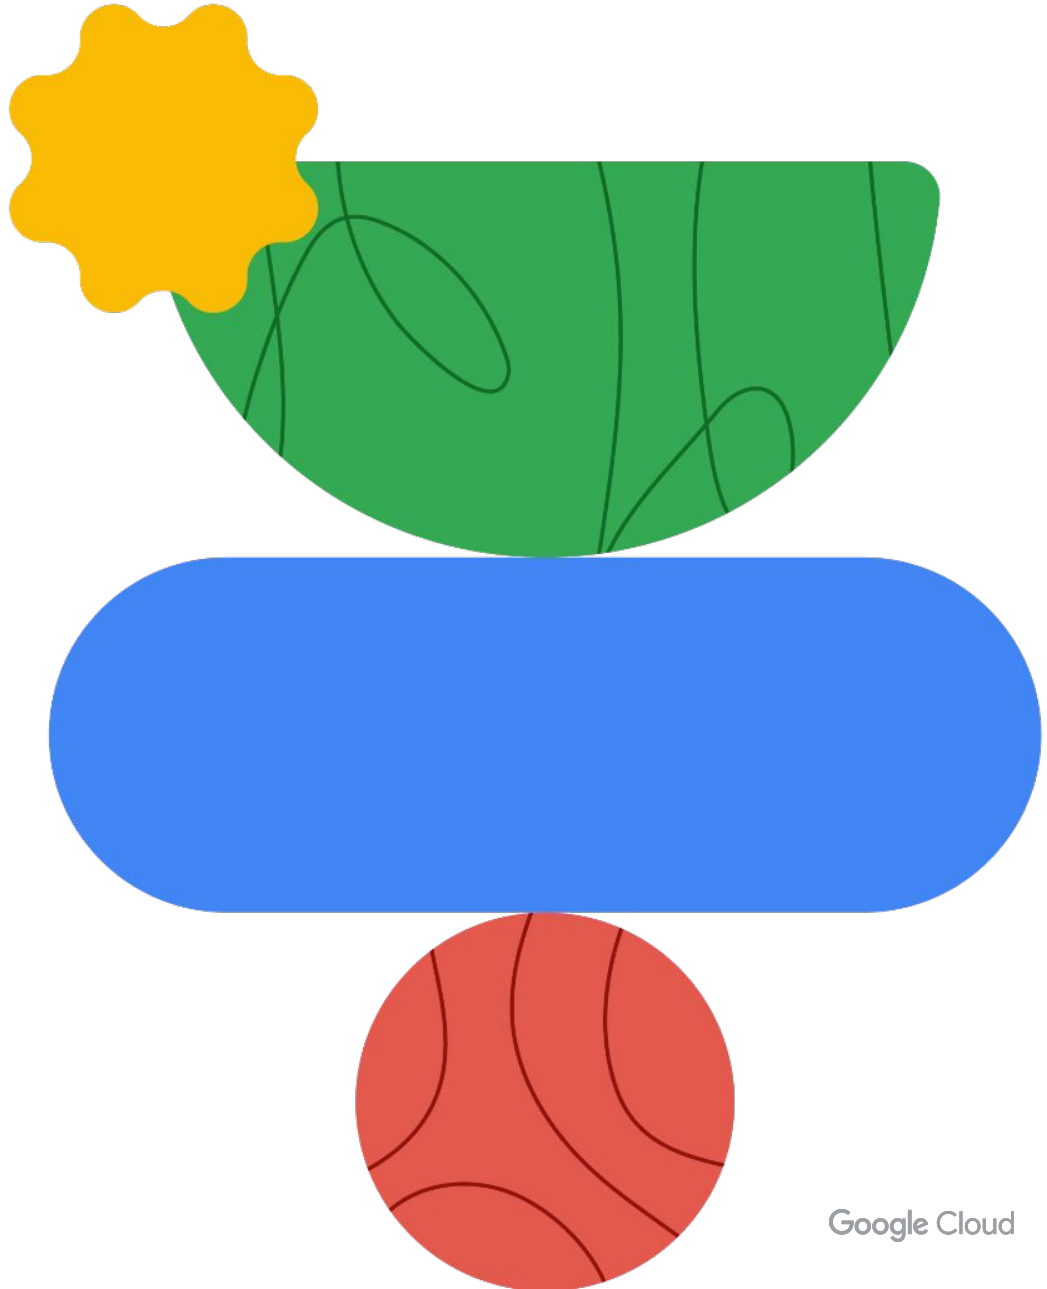


生成 AI のアプリケーションとエージェント


生成 AI
アプリケーション
エージェント
プラットフォーム
モデル
インフラ
ストラクチャ

機密 / 専有情報

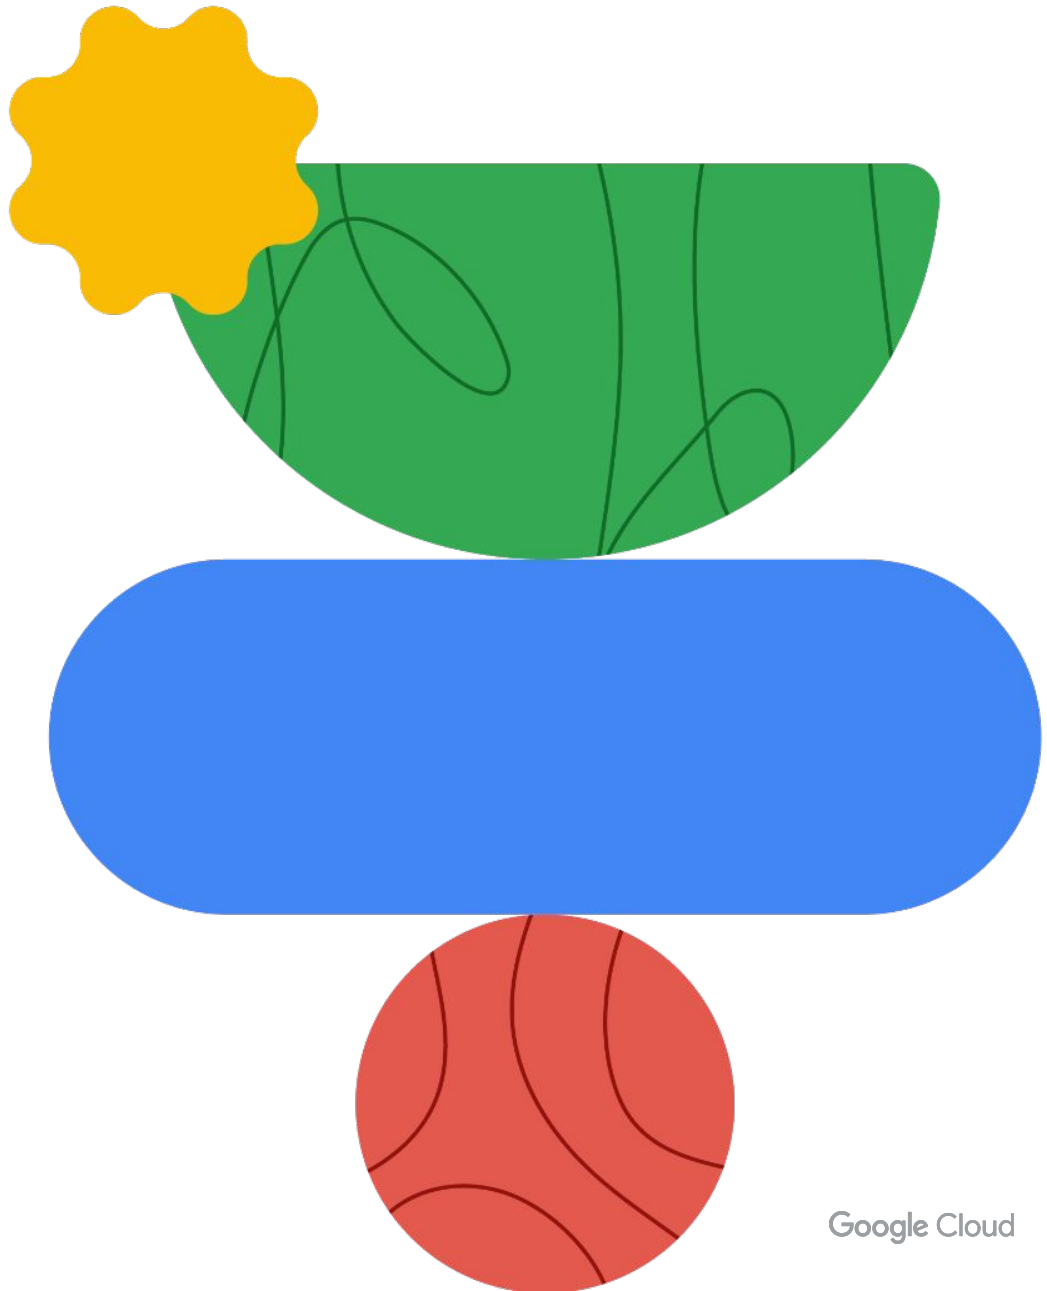
エージェントができること



生成 AI エージェントとは、自由に使えるツールを
使用して周囲の世界に対する観察と行動をすることで、
目標の達成を試みるアプリケーションのこと。

機密 / 専有情報

エージェントと生成 AI を活用したアプリケーションの関係



エージェントの機能

自然言語を理解して応答する

エージェントによって、複雑なリクエストを理解することが可能な、より直感的なインターフェースをアプリケーションに実装できる。

複雑なタスクを自動化する

複数のステップからなるプロセスをアプリケーション内で処理できる。

カスタマイズ

ユーザーの好みを学習し、それに応じてアプリケーションのエクスペリエンスを調整できる。

生成 AI を活用したアプリケーション内のマルチエージェント システム

アプリケーションが全体の枠組みとUIを提供し、専門特化した複数のエージェントが自律協調して高度な体験を実現

協調アーキテクチャ

アプリケーション層がユーザー向けUIと全体目標・文脈を定義し、内部で動作する**複数の専門エージェント**が複雑な個別タスクを分担して連携することで、より動的で洗練されたUXを提供します。

専門エージェントの分業　統合ユーザー インターフェース

ユースケース 01
旅行予約アプリ

専門エージェントの協調

手配エージェント
ユーザーの好みに基づき、最適なフライトとホテルを探索・選定

観光提案エージェント
目的地で開催される関連イベントや現地アクティビティを提案

アプリケーション層の役割
各エージェントの提案を統合し、一覧閲覧から決済・予約までを完結するUIを提供

ユースケース 02
カスタマー サポート アプリ

専門エージェントの協調

一次対応エージェント
定型的な質問への自動即時回答と基本トラブルシューティング

エスカレーション エージェント
複雑な問題や感情の高まりを検知し、文脈を添えて人間の担当者へ引き継ぎ

アプリケーション層の役割
シームレスな対話チャットUIを提供し、社内CRMや既存サポート基盤と双方向連携

ユースケース 03
パーソナライズ学習アプリ

専門エージェントの協調

習熟度・教材推薦エージェント
生徒の理解度を客観的に評価し、弱点に応じた最適教材をリコメンド

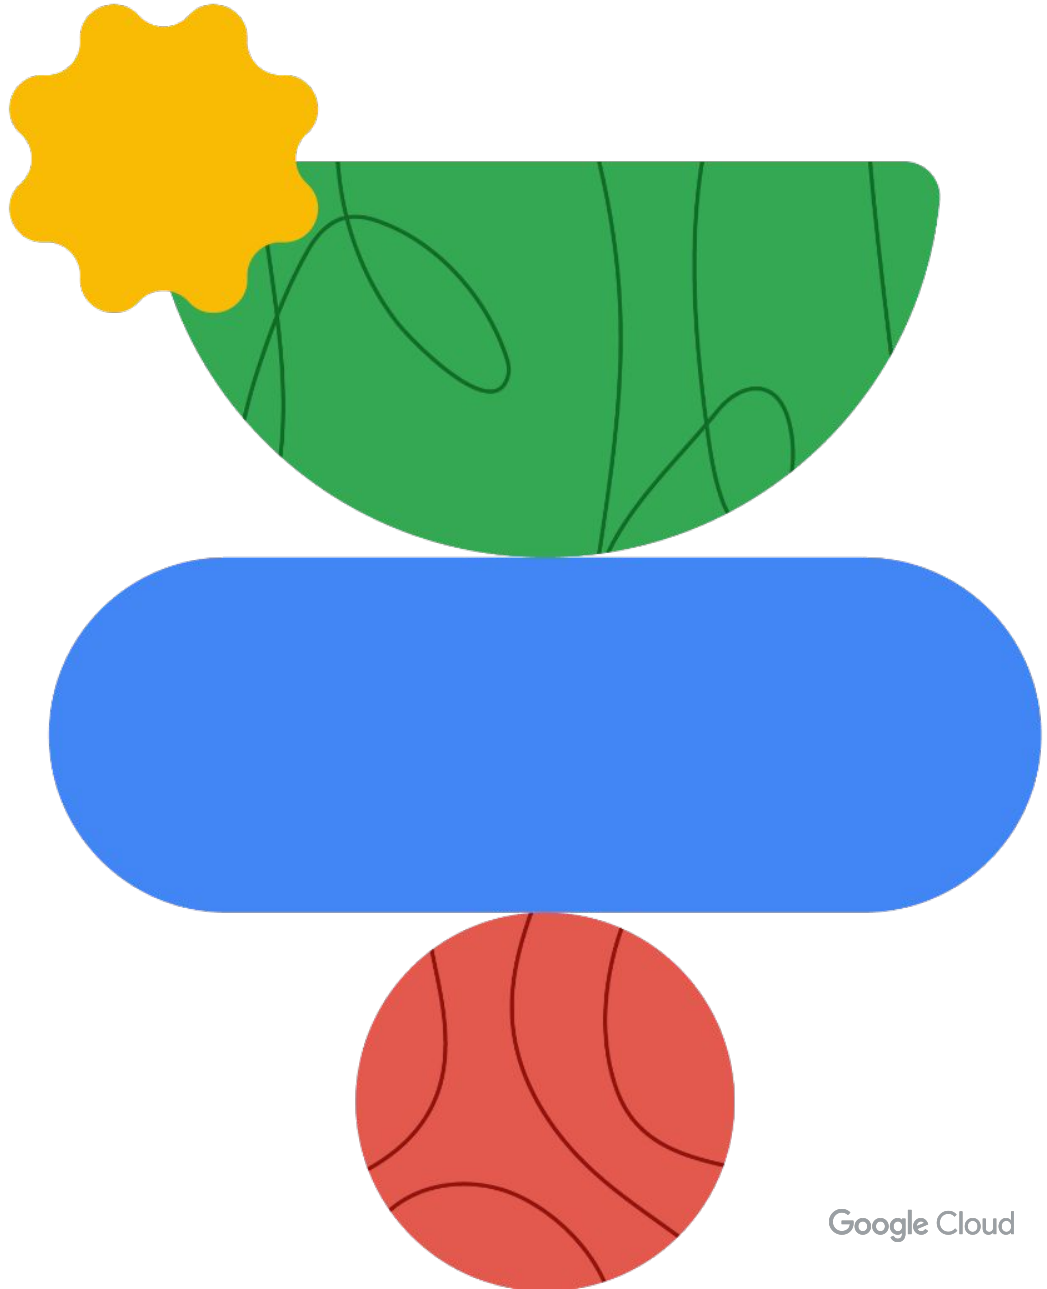
演習問題生成エージェント
個別の理解度や目標レベルに合わせたパーソナライズ演習課題を自動生成

アプリケーション層の役割
授業・単元の全体ロードマップを提示し、学習進捗や習得スコアを視覚的に追跡

複数の自律型エージェントの協調により、単一モデルでは困難な複雑ワークフローを実現

機密 / 専有情報

エージェントの仕組み



エージェントの仕組み

01 **会話エージェント**

02 ワークフロー エージェント

仕組み

1. ユーザーが入力を提供する: ユーザーがメッセージを入力するか、エージェントに話しかける。
2. エージェントが理解する。
3. エージェントがツールを呼び出す。
4. エージェントが回答を生成する。
5. エージェントが回答を返す。



エージェントの仕組み

01 **会話エージェント**

02 ワークフロー エージェント

仕組み

1. ユーザーが入力を提供する: ユーザーがメッセージを入力するか、エージェントに話しかける。
2. エージェントが理解する。
3. エージェントがツールを呼び出す。
4. エージェントが回答を生成する。
5. エージェントが回答を返す。

例

- 質問への回答
- 気軽なチャット
- 情報へのアクセス

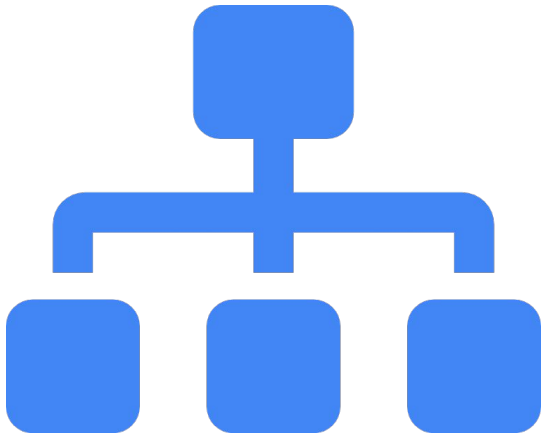
エージェントの仕組み

01 会話エージェント

02 **ワークフロー エージェント**

仕組み

1. ユーザーが入力を提供する: ユーザーがタスクを定義するか、プロセスをトリガーする。
2. エージェントが理解する。
3. エージェントがツールを呼び出す。
4. エージェントが結果または出力を生成する。
5. エージェントが結果または出力を返す。



エージェントの仕組み

01 会話エージェント

02 **ワークフロー エージェント**

仕組み

1. ユーザーが入力を提供する: ユーザーがタスクを定義するか、プロセスをトリガーする。
2. エージェントが理解する。
3. エージェントがツールを呼び出す。
4. エージェントが結果または出力を生成する。
5. エージェントが結果または出力を返す。

例

- e コマースの注文処理
- 顧客のオンボーディング
- 自動調査
- セキュリティ ログの解析

機密 / 専有情報

エージェントの仕組み: 会話型とワークフロー型

意図を理解して意味ある回答を返す「会話エージェント」と、業務プロセスを自律的に遂行する「ワークフロー エージェント」

共通サイクル

いずれのエージェントも
「入力 ➔ 理解 ➔ ツール呼出 ➔ 生成 ➔ 返却」
の 5 ステージを経てタスクを完了します。

① 入力/トリガー > ② 意図・要件理解 > ③ ツール呼出 > ④ 生成・集約 > ⑤ 回答・システム返却

01 会話エージェント

対話・情報提供型

言葉の字面だけでなく**背後にある意味や意図を理解** し、文脈に沿った自然で価値の高い回答を生成。

1	**ユーザーが入力を提供**	メッセージを入力するか、音声で直接話しかける
2	**エージェントが理解する**	高度な AI で発話の背後にある本質的な意図を解釈
3	**ツールを呼び出す**	Web検索・社内DB・外部アプリ等で必要情報を収集
4	**回答を生成する**	ユーザーのリクエストに即した自然で正確な回答文を構成
5	**回答を返す**	画面へのテキスト表示または音声でユーザーへ提供

主なユースケースと例:

- **質問への回答:** パリの天気を尋ねると、予報と共に旅行の持ち物まで提案
- **気軽なチャット:** 友人のように雑談、ジョーク、おすすめの本・映画の相談
- **情報へのアクセス:** オーストラリアの首都や歴史事項など、膨大な知識から即時要約・回答

02 ワークフロー エージェント

業務・タスク自動化型

複雑な一連のプロセスを案内・代行し、**作業を正確かつ自律的に遂行・合理化** 。

1	**タスク定義 / トリガー**	フォーム送信、ファイル配置、定期スケジュール等で開始
2	**エージェントが理解する**	要件を解釈し、達成に必要な一連の自動化手順を定義
3	**ツールを呼び出す**	データ変換、ファイル転送、通知送信、外部API呼出
4	**結果・出力を生成する**	レポート作成、データファイル出力、ステータス更新
5	**結果・出力を返す**	メール通知、DB反映、ダッシュボード配信、ストレージ保存

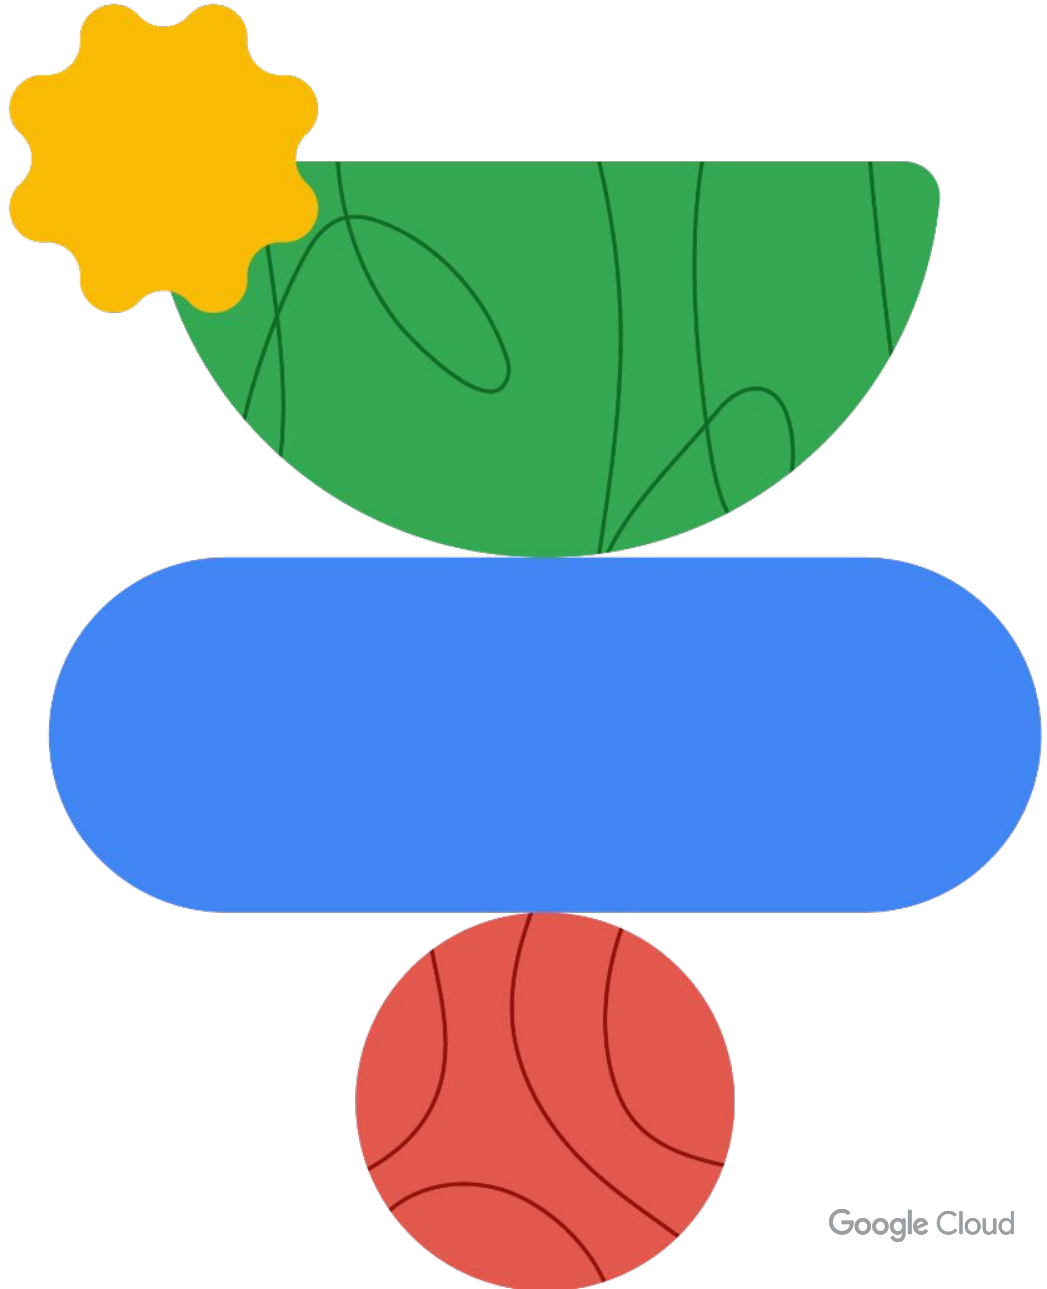
主なユースケースと例:

- **e コマース注文処理:** 在庫更新・発送通知・返品処理を全自動化
- **顧客オンボーディング:** 初期設定案内・チュートリアル・FAQ対応
- **自動調査（Deep Research）:** 自律的なWeb閲覧・情報要約・包括レポート
- **セキュリティログ解析:** 異常検知・トリアージ・チケット起票・割当

ポイント: 会話エージェントは「ユーザー対話の最適化」、ワークフロー エージェントは「組織プロセスの自律遂行」に強みを発揮

機密 / 専有情報

エージェントの
ユースケース



エージェントのユースケース

カスタマー サービス エージェント

問い合わせに回答し、問題を解決して、パーソナライズされた推奨事項を提示する。

従業員の生産性向上エージェント

従業員が情報の検索、タスクの管理、ワークフローの自動化を行えるよう支援する。

クリエイティブ エージェント

新しいアイデアの生成、コンテンツの作成、言語の翻訳を行う。

エージェントのその他のユースケース

コード エージェント

開発者がコードを記述、確認、デバッグし、さらにコードを生成できるよう支援する。

データ エージェント

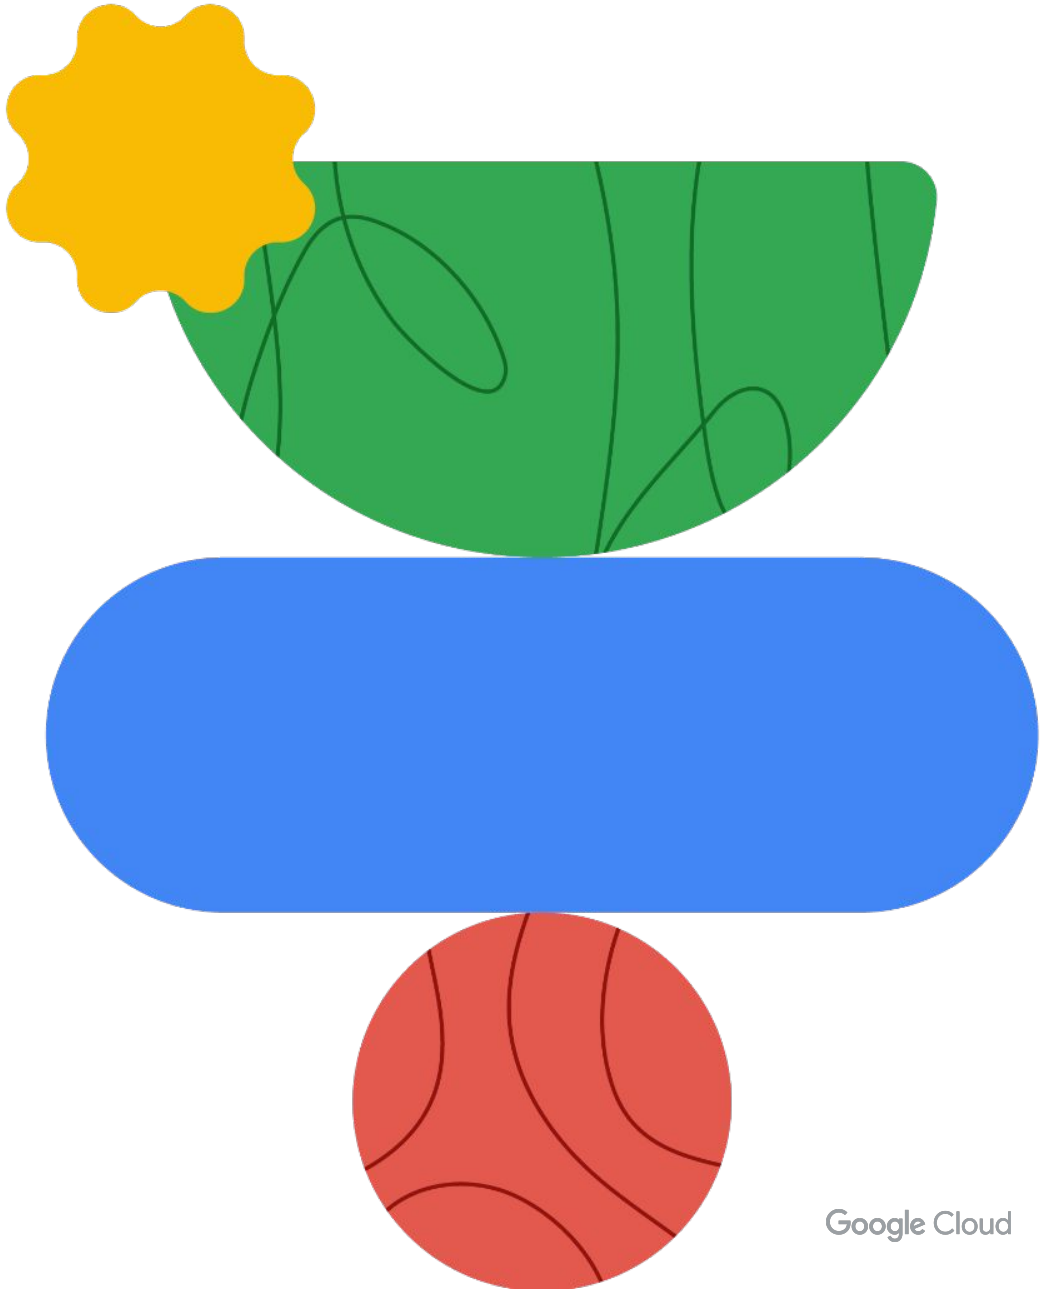
大規模なデータセットを分析し、傾向を特定して、データから分析情報を引き出す。

セキュリティ エージェント

セキュリティ タスクを自動化する。

機密 / 専有情報

生成 AI エージェント: モデルを上回る能力を発揮



推論ループでは通常、意思決定プロセスを
導くために、高度なプロンプト エンジニアリング
フレームワークが使用される。

機密 / 専有情報

高度なプロンプト エンジニアリング フレームワーク

フレームワークの構成要素

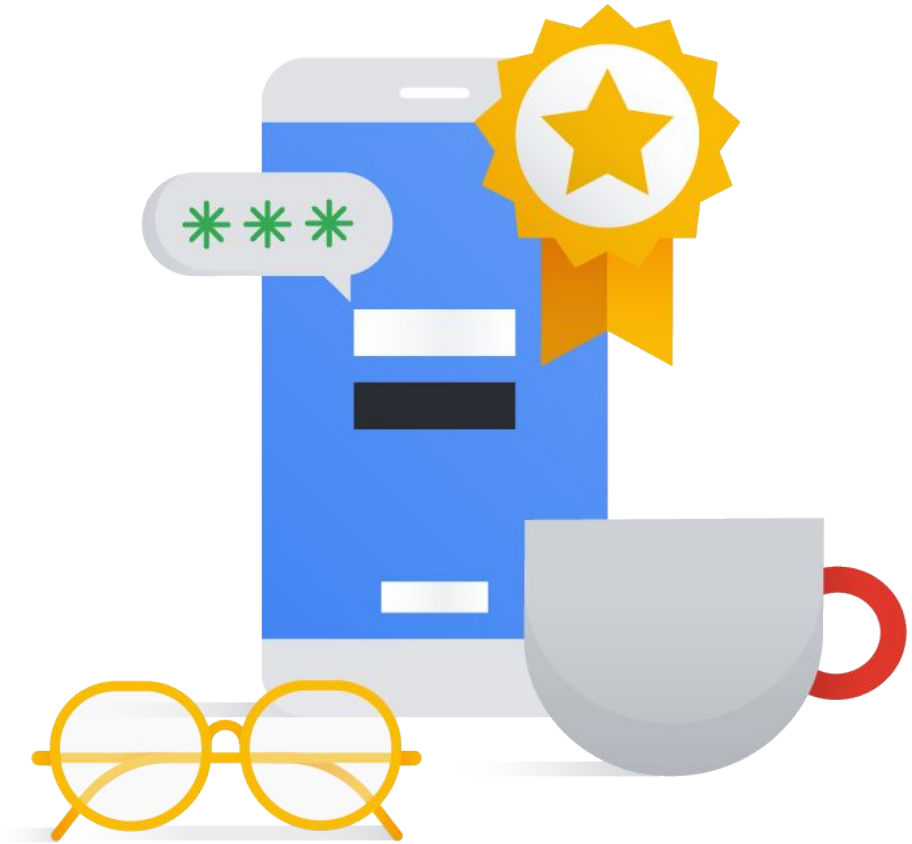
- シンプルなルールベースの計算
- 複雑な思考チェーン
- ML アルゴリズム
- 確率的推論手法

アプローチの代表例

- **ReAct**（推論と行動）プロンプト
- **Chain-of-Thought**（CoT）プロンプト

推論ループでは通常、意思決定プロセスを導くために、
高度なプロンプト エンジニアリング フレームワーク が使用される。

簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

生成 AI エージェントの主な目的は何ですか。

A. テキストや画像などのクリエイティブ コンテンツの生成のみを行う。

B. 利用可能なツールを使って環境を観察し、推論して行動することで、特定の目標を達成する。

C. 他の AI モデルを構築するためのプラットフォームとしてのみ機能する。

D. アクションを実行したりツールを使用したりする機能は持たずに、情報を受動的に提供する。

理解度チェック | 問題 01

正解

生成 AI エージェントの主な目的は何ですか。

A. テキストや画像などのクリエイティブ コンテンツの生成のみを行う。

B. 利用可能なツールを使って環境を観察し、推論して行動することで、特定の目標を達成する。



C. 他の AI モデルを構築するためのプラットフォームとしてのみ機能する。

D. アクションを実行したりツールを使用したりする機能は持たずに、情報を受動的に提供する。

理解度チェック | 問題 02

問題

生成 AI エージェントと生成 AI を活用したアプリケーションの間にはどのような関係がありますか。

A. 生成 AI エージェントは、生成 AI を活用したより大規模なアプリケーション内で機能するインテリジェントなコンポーネントである。生成 AI を活用したアプリケーションは、ユーザー インターフェースと全体的な目標を提供する。

B. 生成 AI エージェントは、アプリケーションとは独立して動作するスタンドアロン エンティティである。

C. 生成 AI を活用したアプリケーションは、単に生成 AI エージェントの別名であり、どちらの用語も同じ意味で使用される。

D. 生成 AI エージェントはユーザー インターフェースと全体的な目標を定義し、生成 AI を活用したアプリケーションは特定の複雑なタスクを処理する。

理解度チェック | 問題 02

正解

生成 AI エージェントと生成 AI を活用したアプリケーションの間にはどのような関係がありますか。

A. 生成 AI エージェントは、生成 AI を活用したより大規模なアプリケーション内で機能するインテリジェントなコンポーネントである。生成 AI を活用したアプリケーションは、ユーザー インターフェースと全体的な目標を提供する。



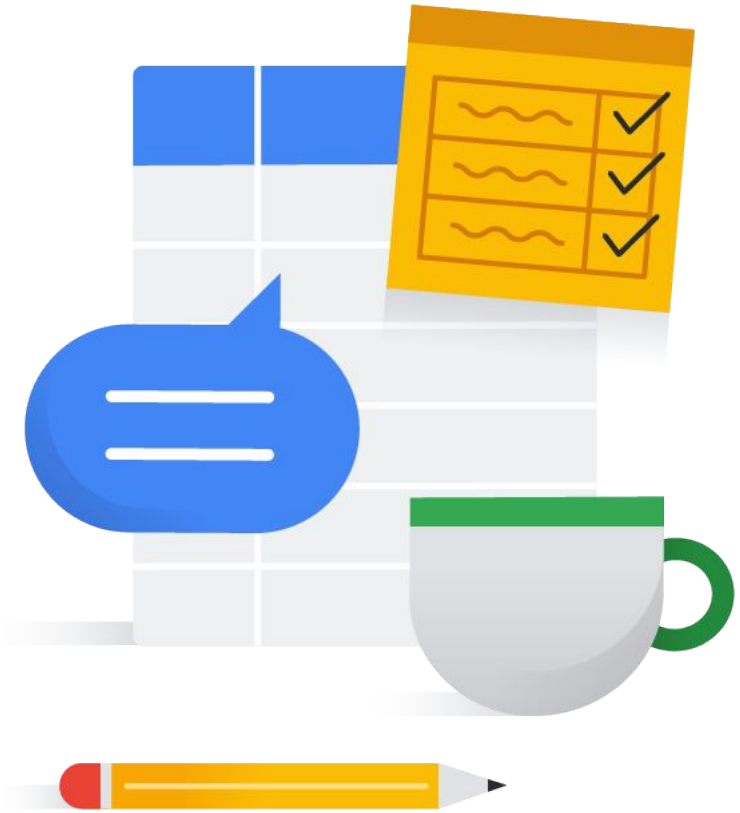
B. 生成 AI エージェントは、アプリケーションとは独立して動作するスタンドアロン エンティティである。

C. 生成 AI を活用したアプリケーションは、単に生成 AI エージェントの別名であり、どちらの用語も同じ意味で使用される。

D. 生成 AI エージェントはユーザー インターフェースと全体的な目標を定義し、生成 AI を活用したアプリケーションは特定の複雑なタスクを処理する。

重要ポイント

- エージェントは、アプリケーションを強化するためにインテリジェンスと自動化を追加する。
- アプリケーションはエージェントにフレームワークと目的を提供する。
- 推論能力とツールを備えた生成 AI エージェントは、スタンドアロンのモデルでは対応できない複雑な問題の解決が可能。生成 AI エージェントが秘めるイノベーションと効率化の可能性を理解することが重要。





アジェンダ

01 生成 AI を取り巻く環境

02 生成 AI のアプリケーションとエージェント

03 生成 AI のプラットフォーム、モデル、インフラストラクチャ

04 生成 AI プロジェクトのリソースと管理



機密 / 専有情報



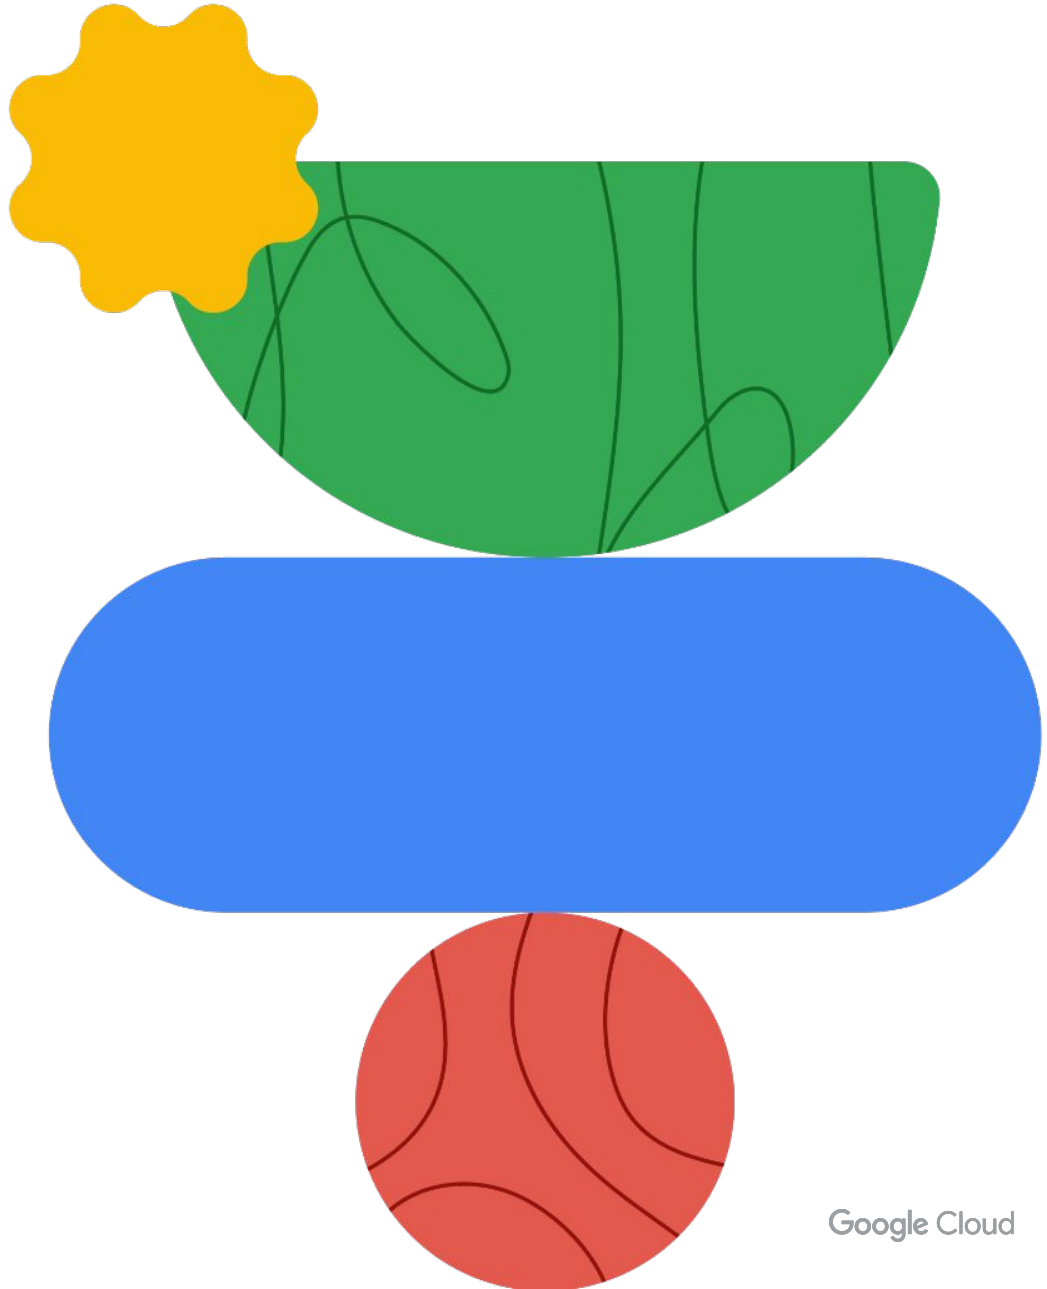
生成 AI の
プラットフォーム、
モデル、インフラストラクチャ

機密 / 専有情報



機密 / 専有情報

プラットフォーム レイヤ



プラットフォーム レイヤは、AI イニシアチブを
構築し、スケールするための基盤となる。

Agent Platform

Agent Platform には、ML ワークフロー全体を
合理化するために以下が用意されている。

- インフラストラクチャ
- 事前トレーニング済みモデル
- 構築、デプロイ、管理のためのツール



Agent Platform: 主な機能とメリット

オープンかつ
高い柔軟性

パワフルな
インフラストラクチャ

事前トレーニング
済みモデル

包括的なツール

カスタマイズ

容易な統合

Agent Platformの MLOps ツール: メリット

MLOps ツールが役立つタスク:

- エンドツーエンドの ML ワークフローをオーケストレートする。
- 特徴量エンジニアリングを実行する。
- テストを実施する。
- モデルの管理と反復処理を行う。
- ML メタデータを追跡する。
- モデルの品質をモニタリングし、評価する。
- ML プロジェクトのライフサイクルを自動化、標準化、管理する。



機密 / 専有情報

Agent Platform の MLOps ツール

Feature Store

ML 特徴の共有、サービング、再利用を行い、整合性と効率性を維持できる。

Model Registry

モデルのライフサイクル全体を通して、モデルのバージョンを管理し、変更を追跡して、モデルを整理できる。

モデルの評価

モデルのパフォーマンスを評価して比較できる。

機密 / 専有情報

Agent Platform のその他の MLOps ツール

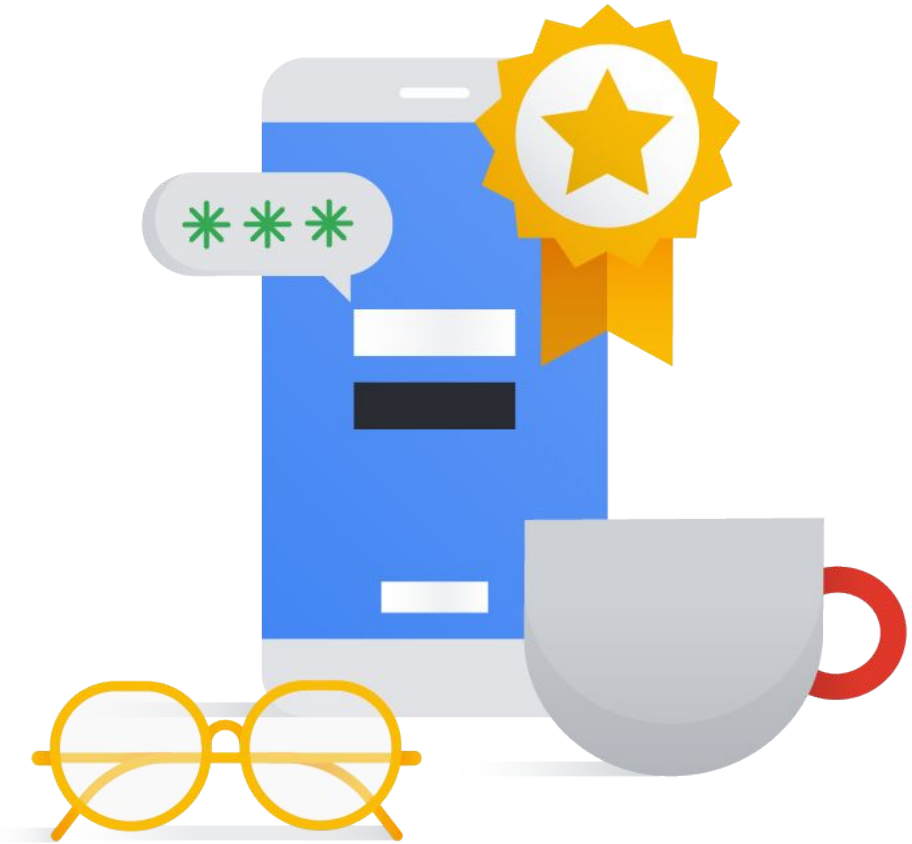
ワークフロー オーケストレーション

Agent Platform Pipelines を使用して ML ワークフローを自動化できる。

モデルのモニタリング

モデルをモニタリングしてパフォーマンスの低下を特定し、入力のスキューとドリフトを検出して、更新または再トレーニングをトリガーできる。

簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

あなたは、テストを追跡し、モデルのさまざまなバージョンを管理して、変更を記録する必要があります。このニーズに最適な Agent Platform ツールはどれですか。

A. モデルのモニタリング

B. ワークフロー オーケストレーション

C. Model Registry

理解度チェック | 問題 01

正解

あなたは、テストを追跡し、モデルのさまざまなバージョンを管理して、変更を記録する必要があります。このニーズに最適な Agent Platform ツールはどれですか。

A. モデルのモニタリング

B. ワークフロー オーケストレーション

C. Model Registry 

理解度チェック | 問題 02

問題

デプロイしたモデルのパフォーマンスが低下しているため、あなたは原因を特定してモデルを再トレーニングする必要があります。このニーズに最適な Agent Platform ツールはどれですか。

A. モデルのモニタリング

B. ワークフロー オーケストレーション

C. Feature Store

理解度チェック | 問題 02

正解

デプロイしたモデルのパフォーマンスが低下しているため、あなたは原因を特定してモデルを再トレーニングする必要があります。このニーズに最適な Agent Platform ツールはどれですか。

A. モデルのモニタリング



B. ワークフロー オーケストレーション

C. Feature Store

理解度チェック | 問題 03

問題

あなたは、データの前処理からモデルのデプロイに至るまでの ML パイプライン全体を自動化する必要があります。このニーズに最適な Agent Platform ツールはどれですか。

A. モデルのモニタリング

B. ワークフロー オーケストレーション

C. Model Registry

理解度チェック | 問題 03

正解

あなたは、データの前処理からモデルのデプロイに至るまでの ML パイプライン全体を
自動化する必要があります。このニーズに最適な Agent Platform ツールはどれですか。

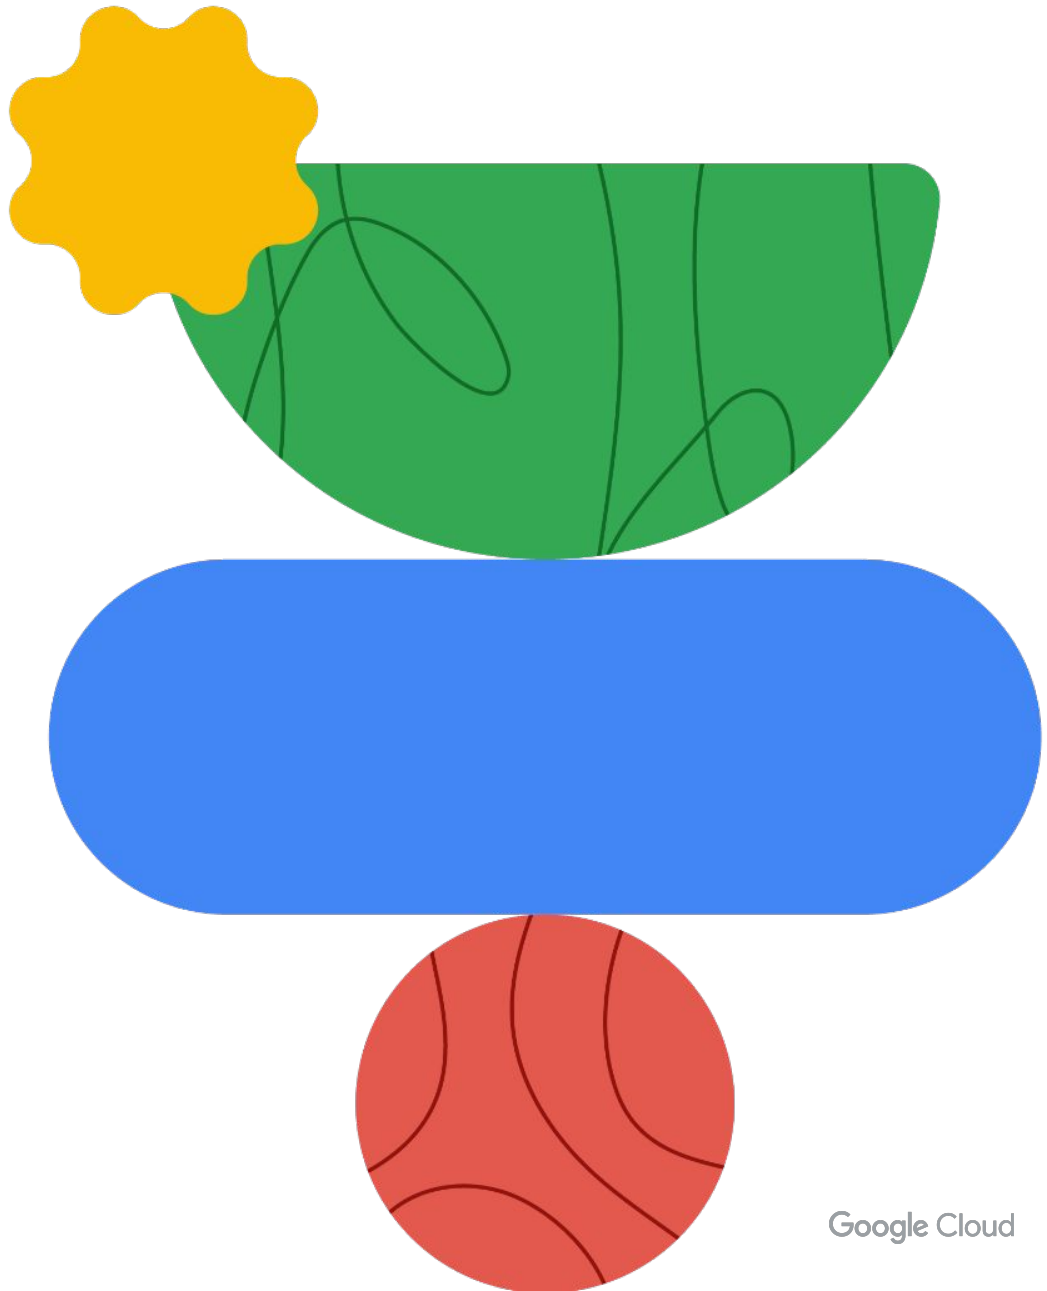
A. モデルのモニタリング

B. ワークフロー オーケストレーション 

C. Model Registry

機密 / 専有情報

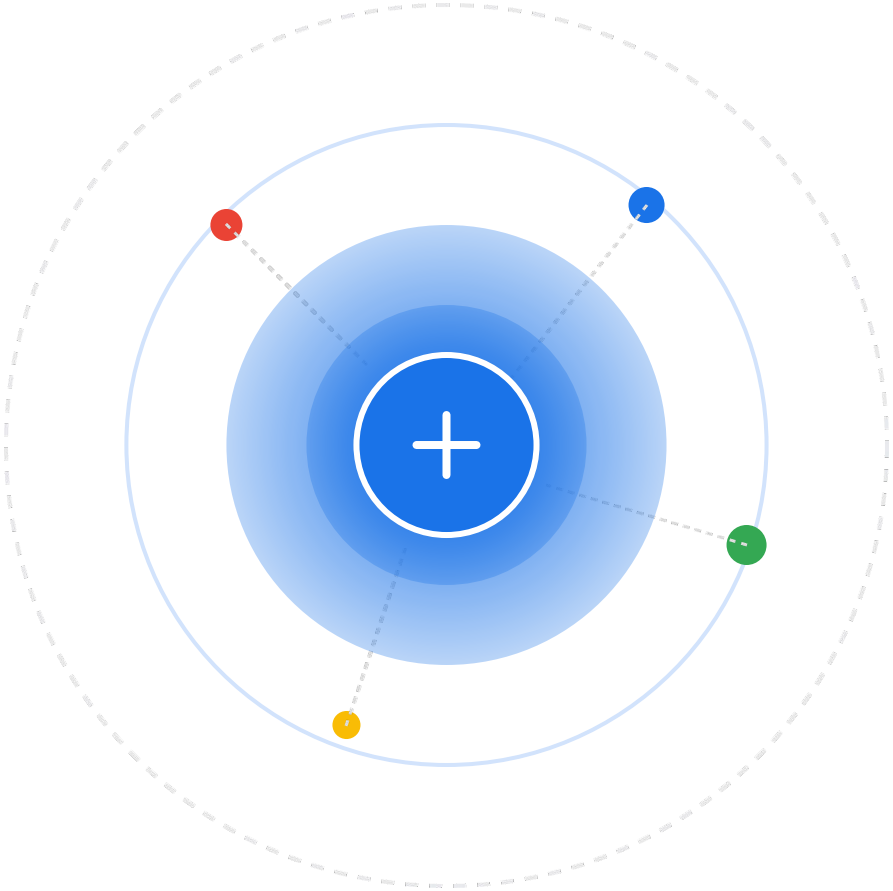
モデルレイヤ



AI & ML SYSTEM CORE

あらゆるシステムの中心には、**モデル**がある。

モデルとは、膨大なデータで
トレーニングされた**高度な数学的構造** です。



Agent Platform: Model Garden の活用 [選択肢 01]

160 以上の Google、オープンソース、サードパーティ製モデルを単一ハブから迅速に選定・即時利用可能 / 既存モデルの検出・カスタマイズ・デプロイ

ゼロからのモデル開発は不要：既存の高品質モデルを即座にファインチューニング

- 160+ の事前検証済みモデル
- 事前学習済み API は即時呼出可能
- 独自データでのカスタマイズ対応

GOOGLE 最先端
基盤モデル

Google の最先端 AI 研究を集約したマルチモーダル・高性能モデル群

✓ 代表的なモデル

- **Gemini**
  1.5 Pro / Flash、2.0 Experimental
- **Imagen / Veo**
  画像生成/ テキスト・画像からの動画作成
- **Chirp 2.0**
  次世代音声認識・文字変換モデル

事前構築済み
特化型 API

チューニング不要で即座に業務アプリへ組み込める専用 API

✓ 提供機能

- **Speech-to-Text**
  高精度な音声認識とストリーミング文字起こし
- **Vision / Translation**
  画像分析・OCR および 100+ 言語の即時翻訳
- **Natural Language**
  文章構造解析・感情分析・エンティティ抽出

オープンソース
オープンモデル

高い自由度とエンタープライズ統制を両立するオープンな重みモデル

✓ 代表的なモデル

- **Gemma 2 / Code / Pali**
  Google 提供の軽量・高性能オープンモデル
- **Llama 3.1 / 3.2**
  Meta の最新大規模言語モデルファミリー
- **Mistral / TII (Falcon)**
  高効率な推論と専門タスク向けアーキテクチャ

パートナー製
サードパーティ

主要パートナーの商用トップティアモデルも単一環境で安全に実行

✓ 代表的なモデル

- **Anthropic Claude**
  Claude 3.5 Sonnet / Haiku / Opus
- **AI21 Labs**
  自然言語理解・特定業種向け専用言語モデル
- **統一管理 & 課金**
  Google Cloud 上での一貫したIAM・請求統合

Agent Platform: 独自モデルの構築と開発 [選択肢 02]

完全カスタムな大規模学習と AutoML の 2 つのアプローチ、および標準化されたエンドツーエンドの ML 運用基盤 / ゼロからの独自モデル作成・自動化・ML ワークフロー

完全カスタムなモデル開発 & 大規模トレーニング

主要な ML フレームワークと専用アクセラレータ(TPU/GPU)を活用し、独自のアルゴリズムやハイパーパラメータを完全にコントロールして大規模に学習を実行。

PyTorch | TensorFlow | scikit-learn | XGBoost | カスタムコンテナ | 分散学習

AutoML による自動モデル作成 & 高精度化

Google の転移学習やニューラルアーキテクチャ検索(NAS)を活用。専門知識やコーディングを最小限に抑え、高品質なモデルをノーコード/ローコードで短期間に構築。

画像：分類・物体検出 | 動画：動作認識・トラッキング | 表形式：分類・回帰・需要予測

モデルの作成またはチューニングにおける標準ワークフロー(MLOps)

Step 01
データの収集
達成目標に応じて、学習用・検証用の元データを各種ソースから選定・インポート

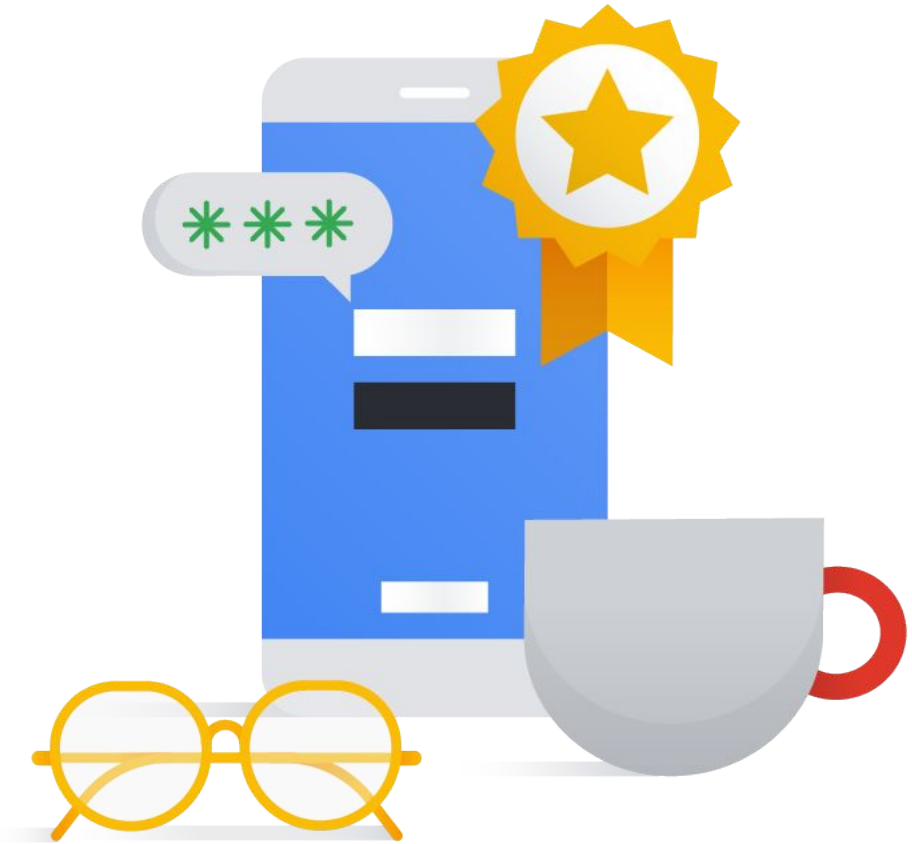
Step 02
データの準備
クリーニング、形式変換、正解ラベルの付与を行い、学習可能なデータセットに整備

Step 03
トレーニング
最適パラメータを設定し、カスタムコードまたは AutoML でモデルを構築・学習

Step 04
デプロイと予測
エンドポイントへモデルを配備し、リアルタイム推論やバッチ予測を即座に提供

Step 05
モデルの管理
精度指標の評価、データドリフト検知、再学習パイプラインによる継続的品質監視

簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

あなたは、グローバルな e コマース プラットフォームの言語を翻訳するモデルを必要としています。すぐに利用でき、高性能で、かつ中程度の価格帯のソリューションを求めています。

このニーズに最適な AI モデルはどれですか。

A. Agent Platform — 独自のカスタムモデルを構築

B. Agent Platform AutoML

C. Model Garden

理解度チェック | 問題 01

正解

あなたは、グローバルな e コマース プラットフォームの言語を翻訳するモデルを必要としています。すぐに利用でき、高性能で、かつ中程度の価格帯のソリューションを求めています。

このニーズに最適な AI モデルはどれですか。

A. Agent Platform — 独自のカスタムモデルを構築

B. Agent Platform AutoML

C. Model Garden 

理解度チェック | 問題 02

問題

あなたは、タンパク質フォールディング予測のための最先端モデルを開発している、経験豊富な AI 研究者です。モデルのアーキテクチャとトレーニング プロセスを完全に制御する必要があります。

このニーズに最適な AI モデルはどれですか。

A. Agent Platform - 独自のカスタムモデルを構築

B. Agent Platform AutoML

C. Model Garden

理解度チェック | 問題 02

正解

あなたは、タンパク質フォールディング予測のための最先端モデルを開発している、経験豊富な AI 研究者です。モデルのアーキテクチャとトレーニング プロセスを完全に制御する必要があります。

このニーズに最適な AI モデルはどれですか。

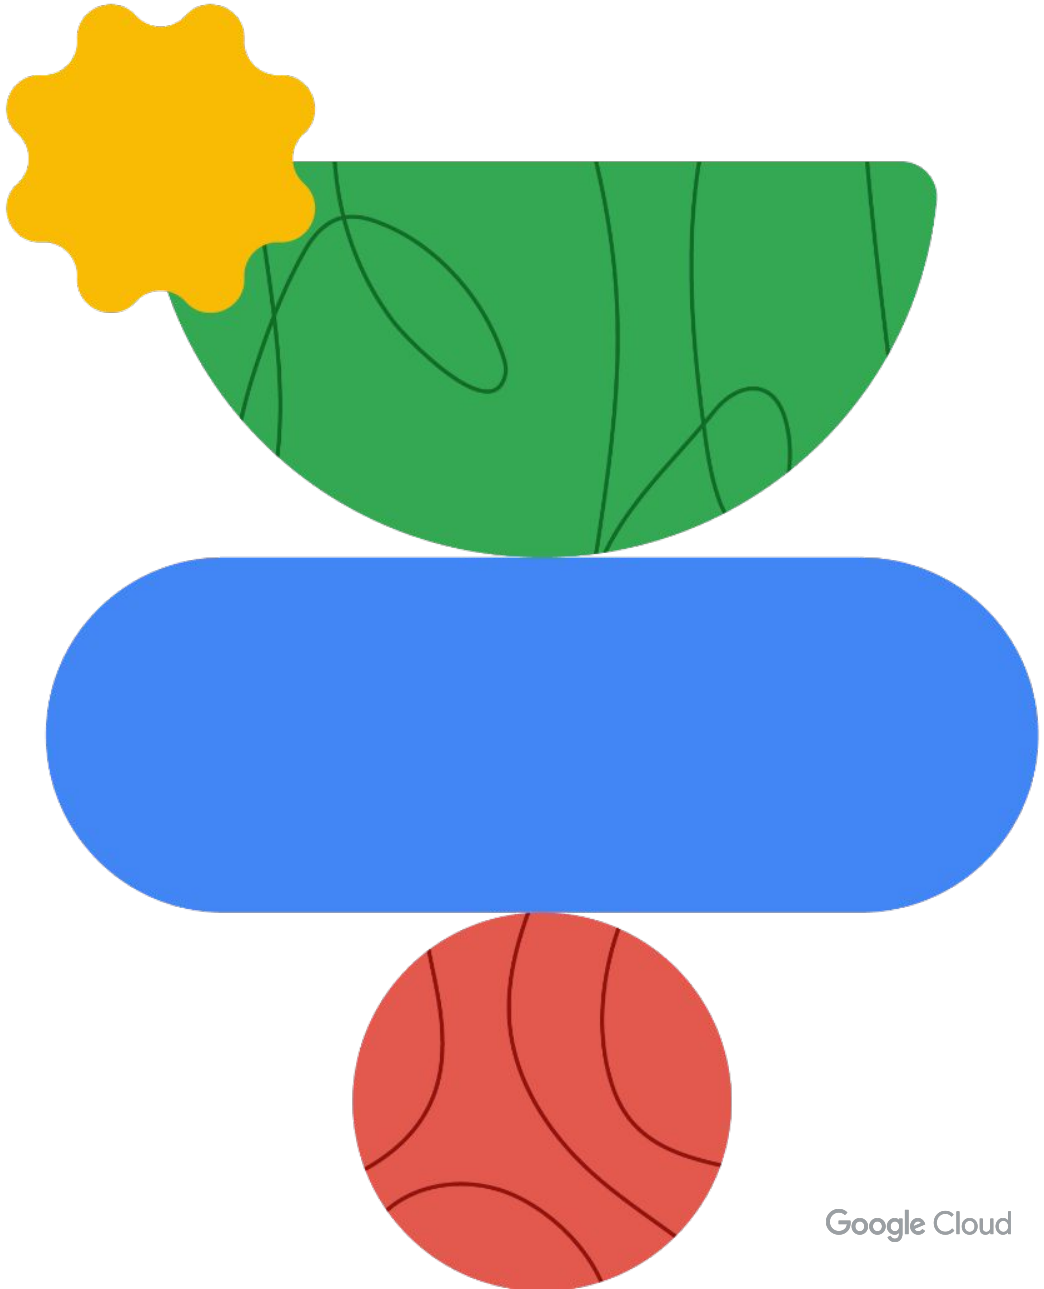
A. Agent Platform - 独自のカスタムモデルを構築 

B. Agent Platform AutoML

C. Model Garden

機密 / 専有情報

インフラストラクチャ レイヤ



インフラストラクチャ レイヤ

あらゆる AI システムの強固な基盤

インフラストラクチャ レイヤは、AI モデルのトレーニング、デプロイ、スケーリングに必要なリソースを包括的に提供する、すべての AIシステムの土台です。

ハードウェア リソース

GPU、TPU、高性能ストレージ、超高速ネットワーキングなど、膨大な計算処理とデータ転送を物理的に支える基盤コンポーネント。

ソフトウェア システム

ハードウェアのパフォーマンスを最大化し、AIモデルの効率的なトレーニング、自動化されたデプロイ、柔軟なスケーリングを実現する最適化ソフトウェア群。

AI インフラストラクチャの主要コンポーネント

ハイ パフォーマンス コンピューティング

- GPU と TPU
- ハイパーコンピュータ

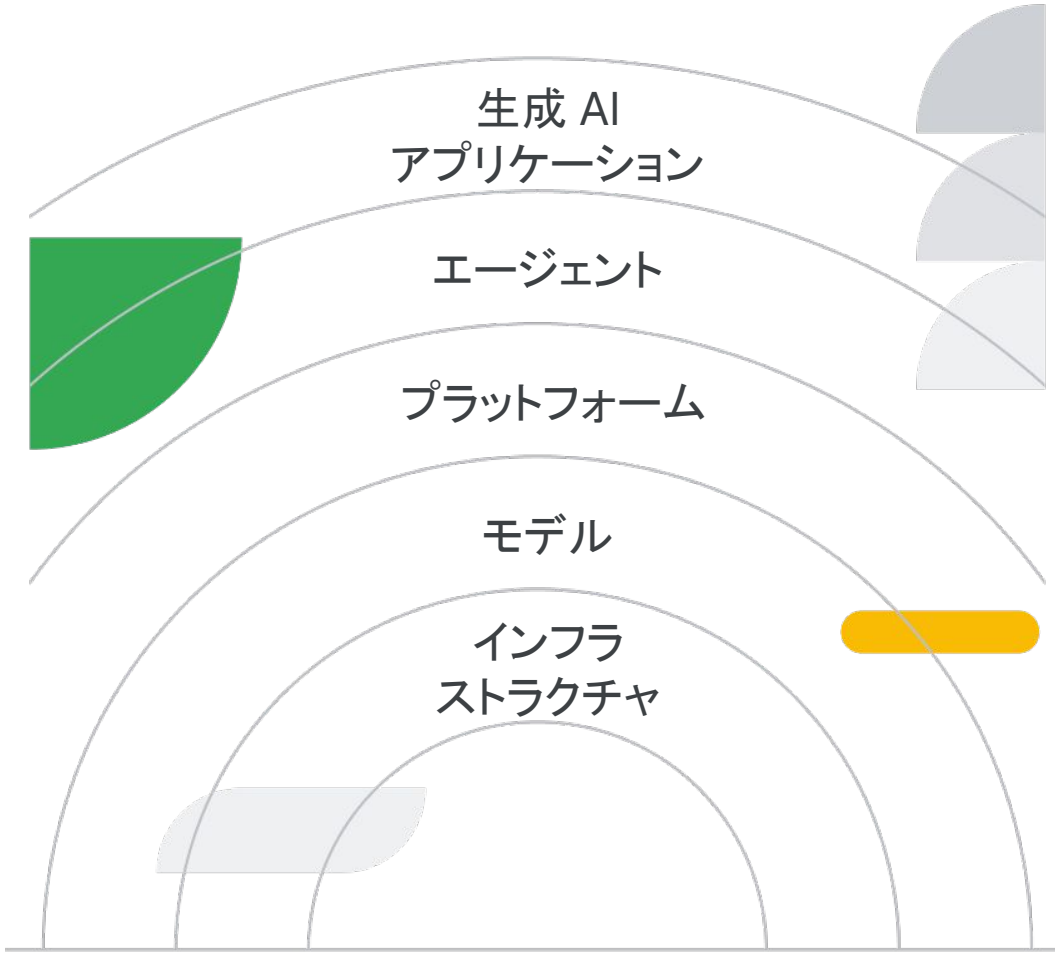
高性能ストレージ

- 大規模なストレージ システム
- ストレージへの高速アクセス

ネットワーキング

専用プロセッサ	**高度な並列処理力の提供** 汎用GPUと最適化TPUによる超高速な学習・推論
超大規模計算	**多数ノードの高速連携基** 大規模生成AIモデルの学習と実行を支える巨大クラスター
ペタバイト級	**高スループット＆拡張性** 膨大かつ増大し続けるデータセットの高耐久・安全な保管
高速 I/O	**高速な読み書き処理の維持** ボトルネックを排除し、モデルの学習効率と稼働率を最大化
低遅延通信	**グローバル光ファイバー** 高帯域・超低遅延でクラスター内の分散処理をシームレスに同期

生成 AI を取り巻く環境: 旅行 chatbot の例

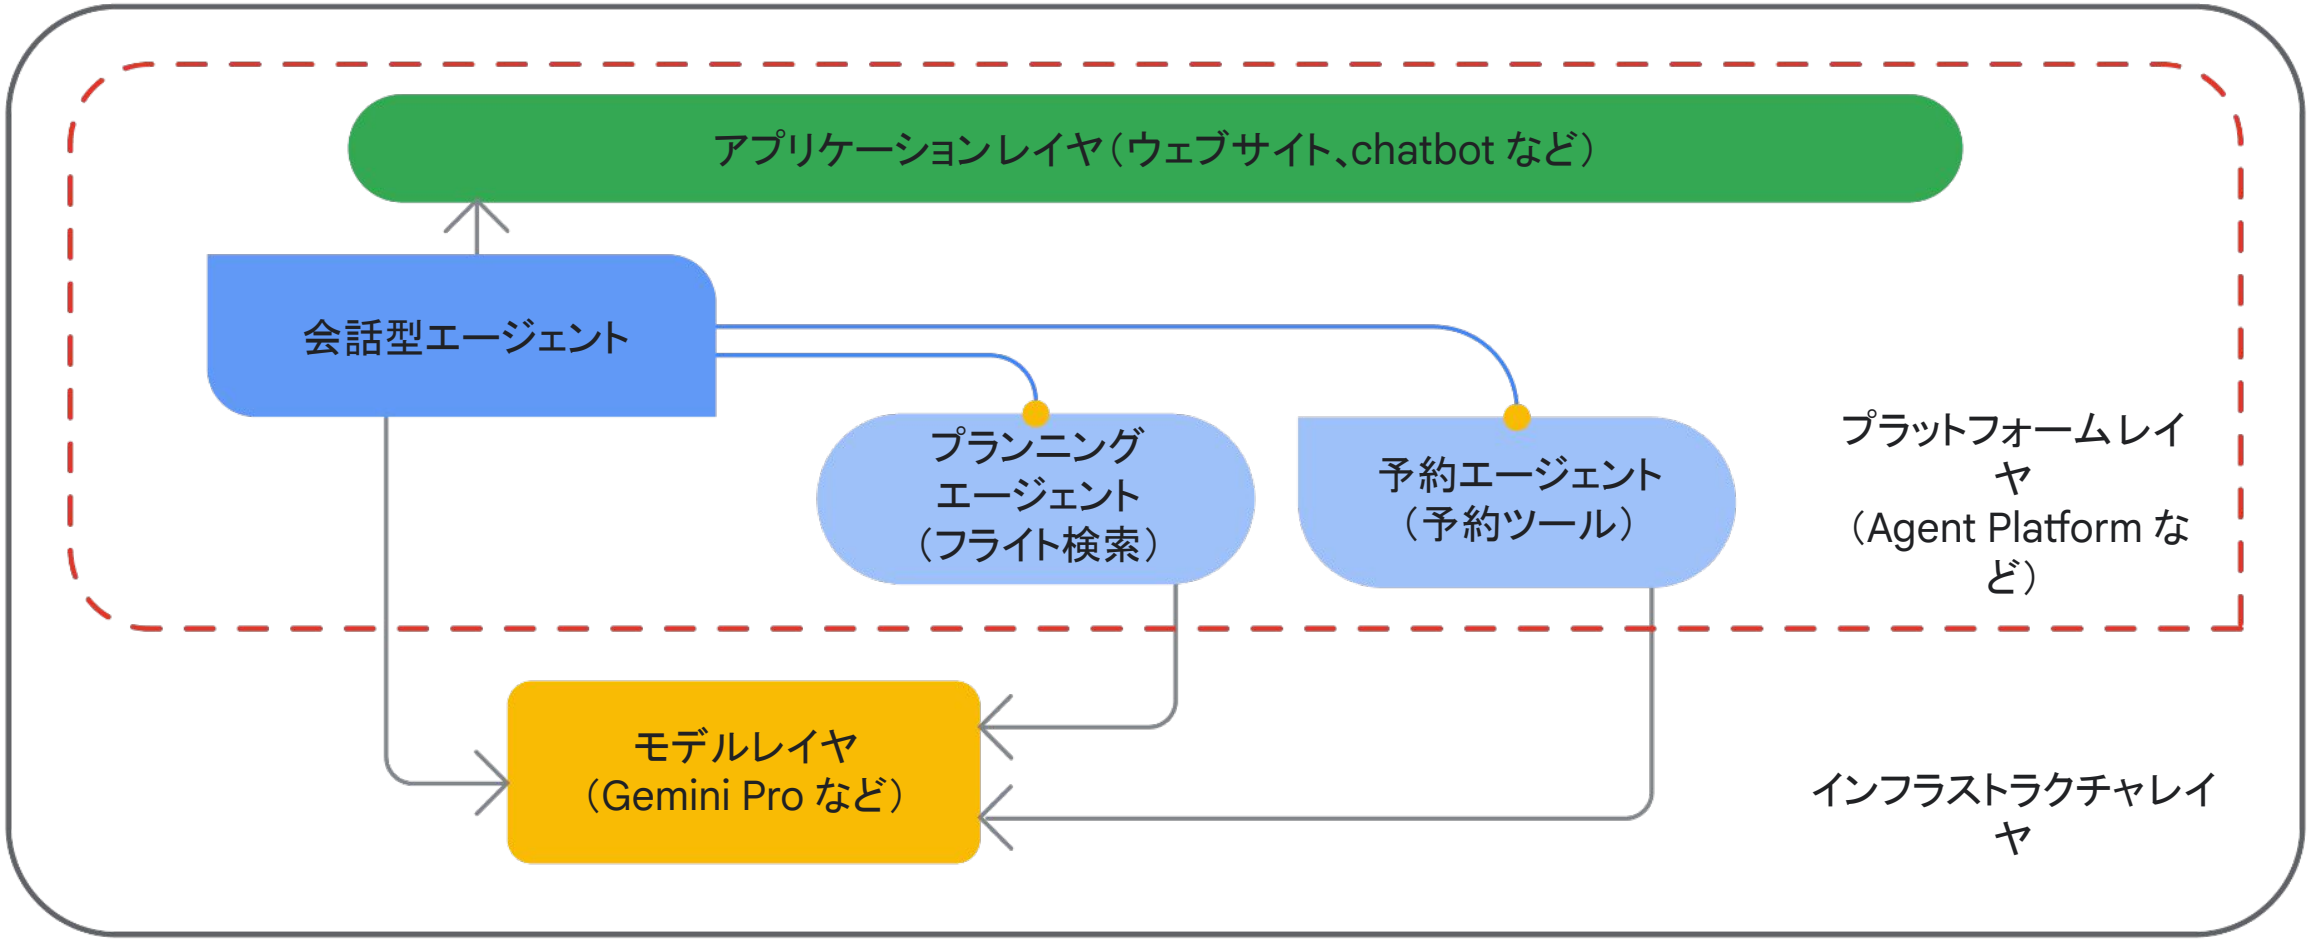


シナリオ:

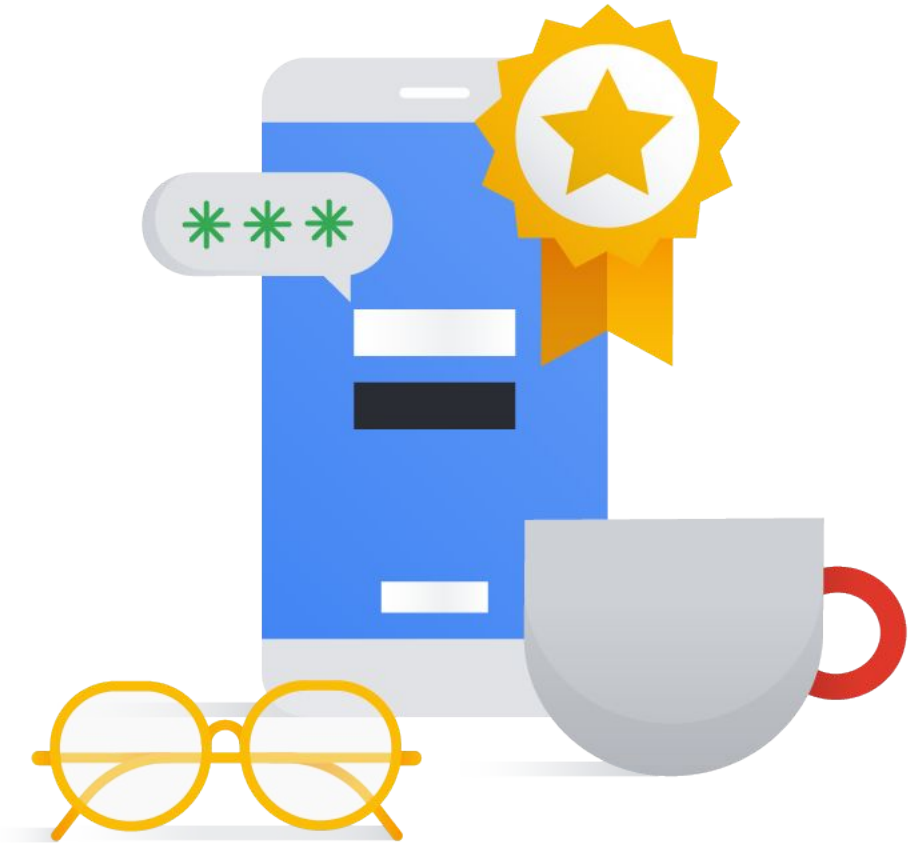
あなたがよく利用している航空会社が、
ウェブサイトでフライトを検索して予約できる
新しい chatbot 機能を導入しました。

機密 / 専有情報

生成 AI を取り巻く環境:
旅行 chatbot の例



簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

インフラストラクチャ要件が自動的に考慮されるプラットフォームで構築を行わない場合、インフラストラクチャ要件を考慮する必要がある生成 AI 開発プロセスの段階は、次のうちどれですか。該当するものをすべて選択してください。

A. モデルの改良: フィードバックや新しいデータに基づいて AI モデルを改善する。

B. モデルのモニタリング: デプロイした AI モデルのパフォーマンスを追跡し、潜在的な問題を特定する。

C. モデルのデプロイ: AI モデルをアプリケーションやサービスで使用できるようにする。

D. データの収集: AI モデルのトレーニングに使用するデータを収集して準備する。

E. モデルのトレーニング: 準備したデータで AI モデルをトレーニングする。

理解度チェック | 問題 01

正解

インフラストラクチャ要件が自動的に考慮されるプラットフォームで構築を行わない場合、インフラストラクチャ要件を考慮する必要がある生成 AI 開発プロセスの段階は、次のうちどれですか。該当するものをすべて選択してください。

A. モデルの改良: フィードバックや新しいデータに基づいて AI モデルを改善する。

B. モデルのモニタリング: デプロイした AI モデルのパフォーマンスを追跡し、潜在的な問題を特定する。

C. モデルのデプロイ: AI モデルをアプリケーションやサービスで使用できるようにする。

D. データの収集: AI モデルのトレーニングに使用するデータを収集して準備する。

E. モデルのトレーニング: 準備したデータで AI モデルをトレーニングする。



理解度チェック | 問題 02

問題

AI インフラストラクチャにおける GPU と TPU とは何を指しますか。

A. AI モデルを管理するためのソフトウェア アプリケーション。

B. 大規模な AI データセットを保存するためのストレージ デバイス。

C. AI システムを接続するためのネットワーキング プロトコル。

D. AI タスクの並列処理用に設計された特殊なプロセッサ。

理解度チェック | 問題 02

正解

AI インフラストラクチャにおける GPU と TPU とは何を指しますか。

A. AI モデルを管理するためのソフトウェア アプリケーション。

B. 大規模な AI データセットを保存するためのストレージ デバイス。

C. AI システムを接続するためのネットワーキング プロトコル。

D. AI タスクの並列処理用に設計された特殊なプロセッサ。



理解度チェック | 問題 03

問題

生成 AI において、高性能ストレージが重要である理由は何ですか。

A. AI トレーニングで使用される大規模なデータセットを保存し、効率的にアクセスするため。

B. AI モデルとやり取りするためのユーザー フレンドリーなインターフェースを提供するため。

C. AI モデルのデプロイと管理を自動化するため。

D. AI システムの責任ある利用を保証するため。

理解度チェック | 問題 03

正解

生成 AI において、高性能ストレージが重要である理由は何ですか。

A. AI トレーニングで使用される大規模なデータセットを保存し、効率的にアクセスするため。



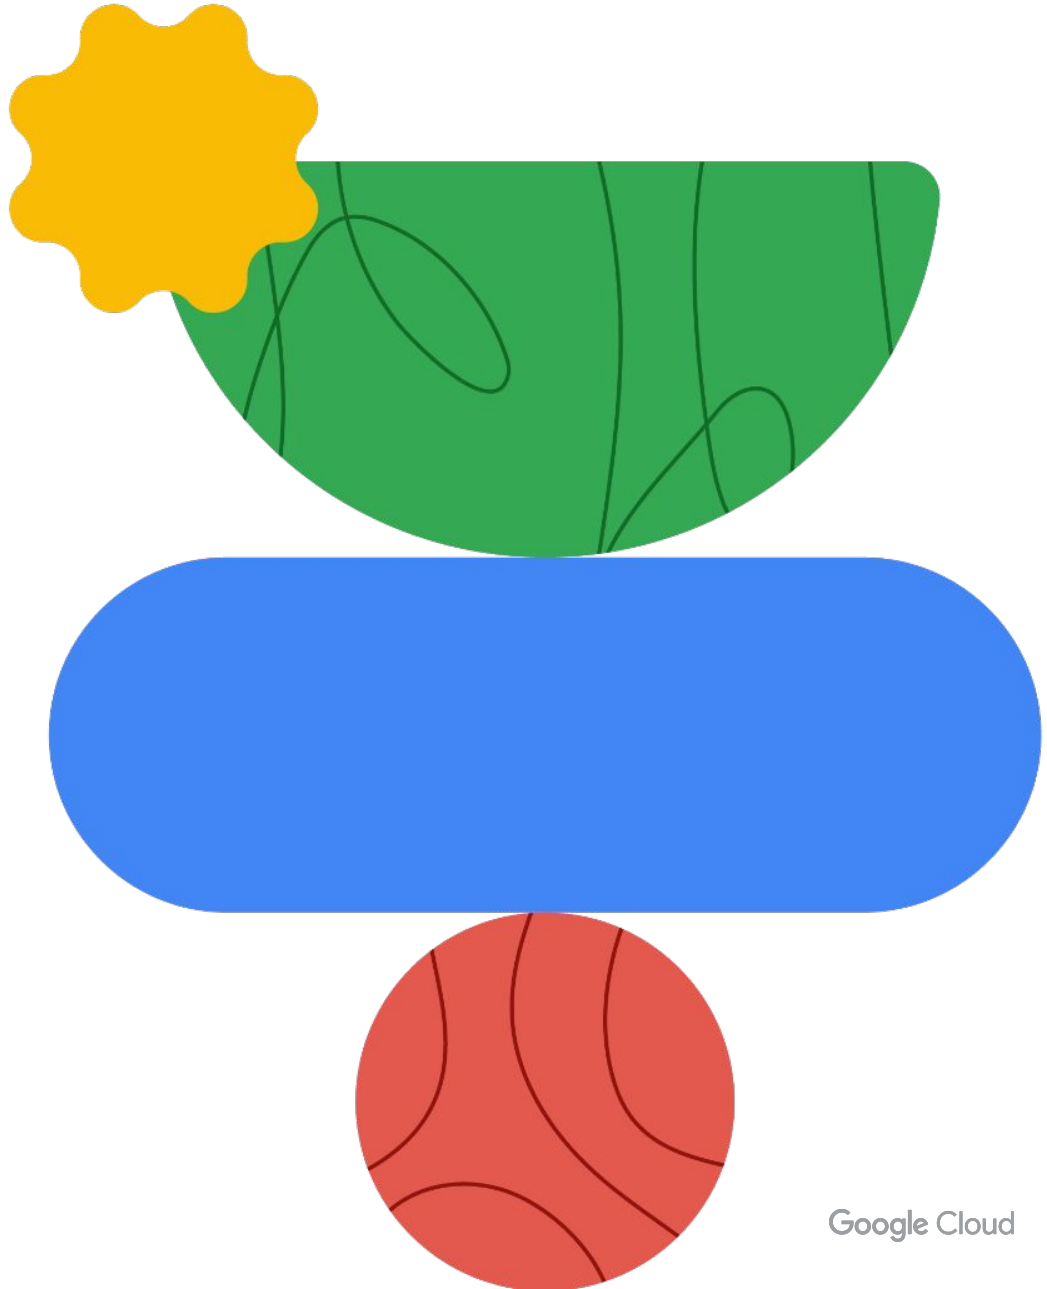
B. AI モデルとやり取りするためのユーザー フレンドリーなインターフェースを提供するため。

C. AI モデルのデプロイと管理を自動化するため。

D. AI システムの責任ある利用を保証するため。

機密 / 専有情報

エッジ コンピューティング



エッジ コンピューティング

エッジ コンピューティングでは、データソースまたは必要な場所の近くにあるデバイスやサーバーでAI を実行します。



必要な場所の近く

データの発生源や意思決定が行われる現場のすぐ近くで処理を行うことで、通信遅延を極限まで減らします。



デバイスやサーバー

スマートフォン、IoT ゲートウェイ、ローカルサーバーなどのエッジハードウェア側で直接コンピューティングリソースを確保します。



現場での AI 実行

大規模なクラウドに依存せず、ローカル環境で AI モデルを効率的に稼働させ、リアルタイムな推論とアクションを可能にします。

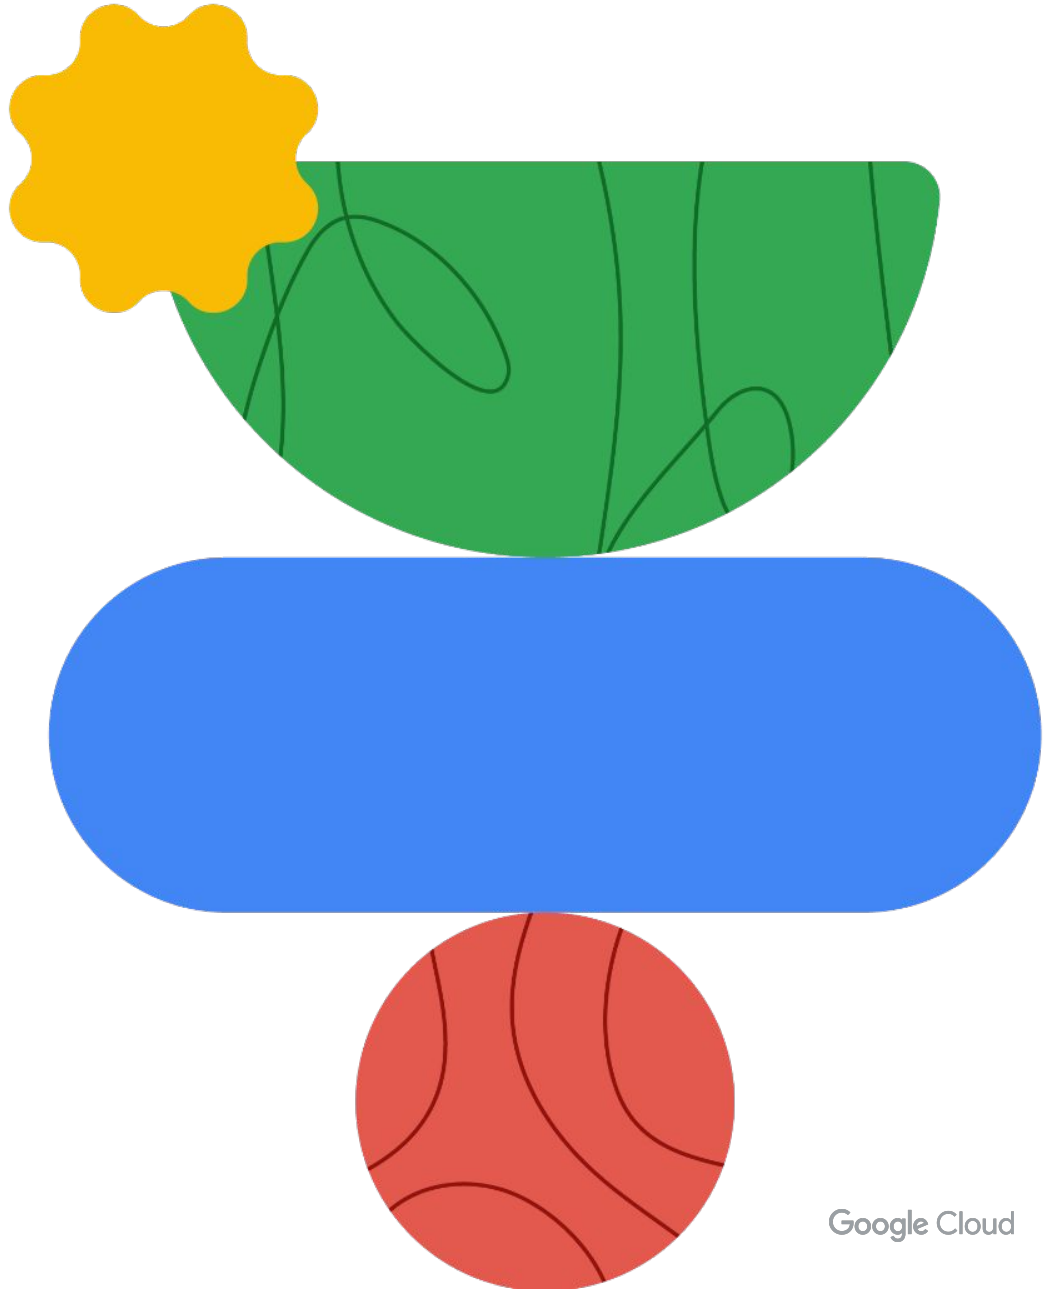
ローカル（エッジ）に移行するメリット

- リアルタイムの応答性が確保される。
- データのプライバシーが強化される。
- インターネット接続への依存度が低減する。
- Lite Runtime（LiteRT）を使用すると、エッジデバイスやスマートフォンで ML モデルを効率的に動作させることができる。
- Gemini Nano は、エッジ向けに設計された AI モデルの一例。



機密 / 専有情報

Gemini Nano

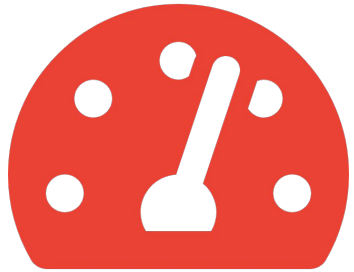


Gemini Nano のメリット



プライバシー

データはデバイス上に保存されるため、プライバシーが強化される。



スピード

データをクラウドに送信する必要がないため、すばやく応答が返される。



オフライン アクセス

Gemini Nano はインターネットへの接続がない状態でも利用できる。

Gemini Nano デバイス

Google Pixel

電話での会話を要約する通話メモや、音声録音を要約する Google Pixel レコーダーなどの機能で活用されている。

Android

Android デベロッパーは AI Edge SDK を介して利用でき、革新的な AI エクスペリエンスをアプリに組み込むことができる。



エッジデプロイ: Agent Platform ツール

モデルの変換

モデルを Lite Runtime（LiteRT）に変換して、エッジデバイスで最適なパフォーマンスを実現できる。

パッケージ化とデプロイ

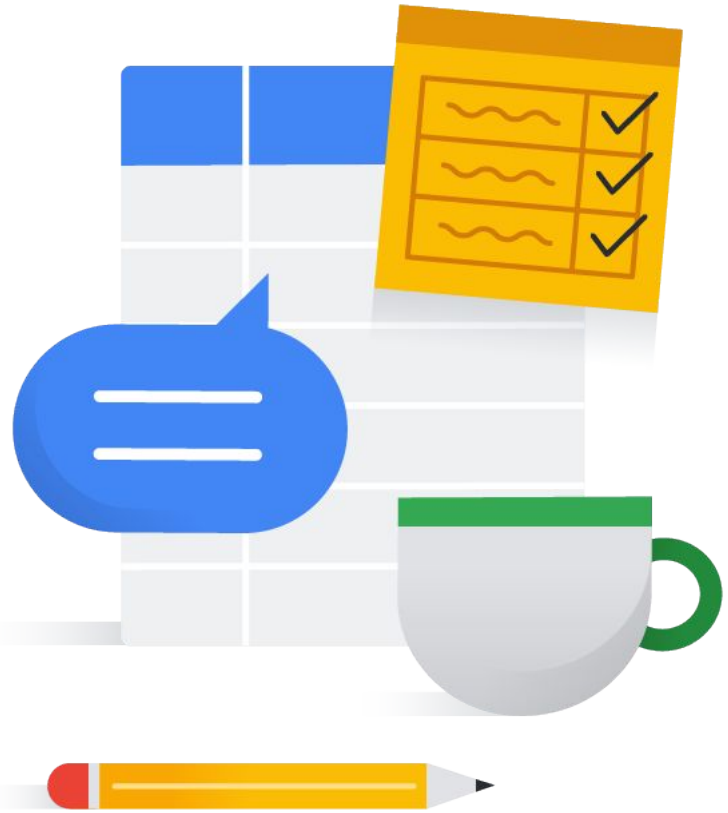
モデルと依存関係をコンテナにパッケージ化して、エッジ ハードウェアにデプロイできる。

管理とモニタリング

エッジのデプロイの管理、パフォーマンスの追跡、分析情報の収集を行ってモデルを継続的に改善できる。

重要ポイント

- Agent Platform は ML を合理化し、AI の開発とデプロイを簡素化するツールと MLOps を提供する。
- AI システムはモデルに依存する。Agent Platform に用意されている豊富なモデル オプションにより、AI イノベーションを実現できる。AI を効果的にデプロイするには、リーダーがモデルを理解することが重要となる。
- Google Cloud のインフラストラクチャは AI の基盤となる。効率的でスケーラブルな AI のデプロイとリソース管理を実現するには、リーダーが Google Cloud のインフラストラクチャを理解する必要がある。
- エッジ AI はリアルタイムでの応答を可能にする。Google のツールと Agent Platform が、エッジでのモデルの構築とデプロイをサポートする。





アジェンダ

01 生成 AI を取り巻く環境

02 生成 AI のアプリケーションとエージェント

03 生成 AI のプラットフォーム、モデル、インフラストラクチャ

04 生成 AI プロジェクトのリソースと管理



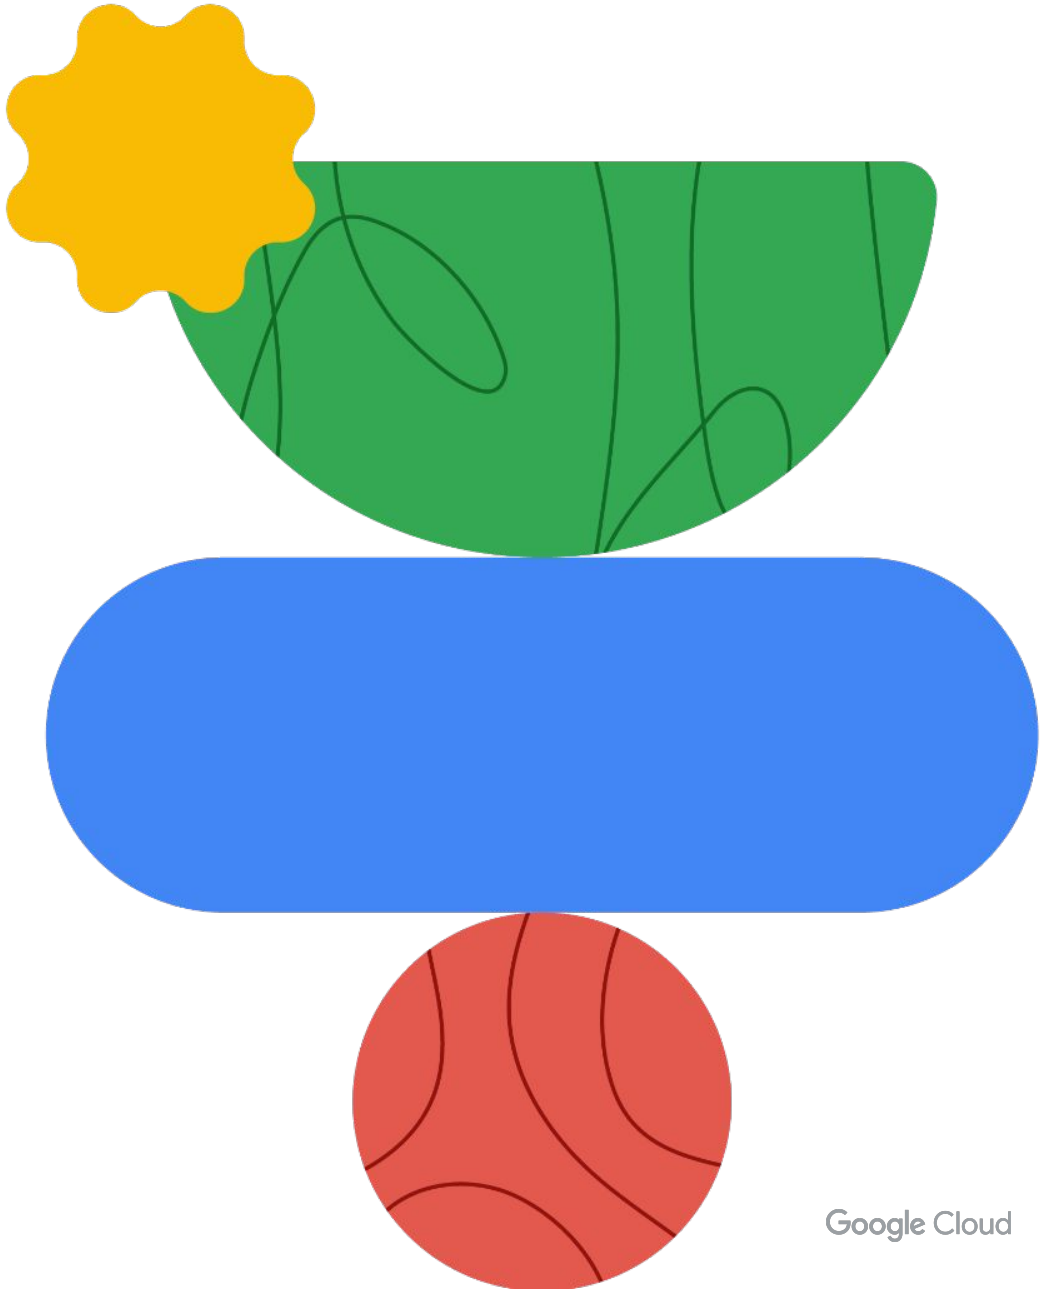
機密 / 専有情報



生成 AI プロジェクトのリソースと管理

機密 / 専有情報

生成 AI プロジェクトのリソース: 人材、費用、時間



生成 AI プロジェクトのリソース

規模: 個人、チーム、企業、数百万の顧客など、対象は誰か？

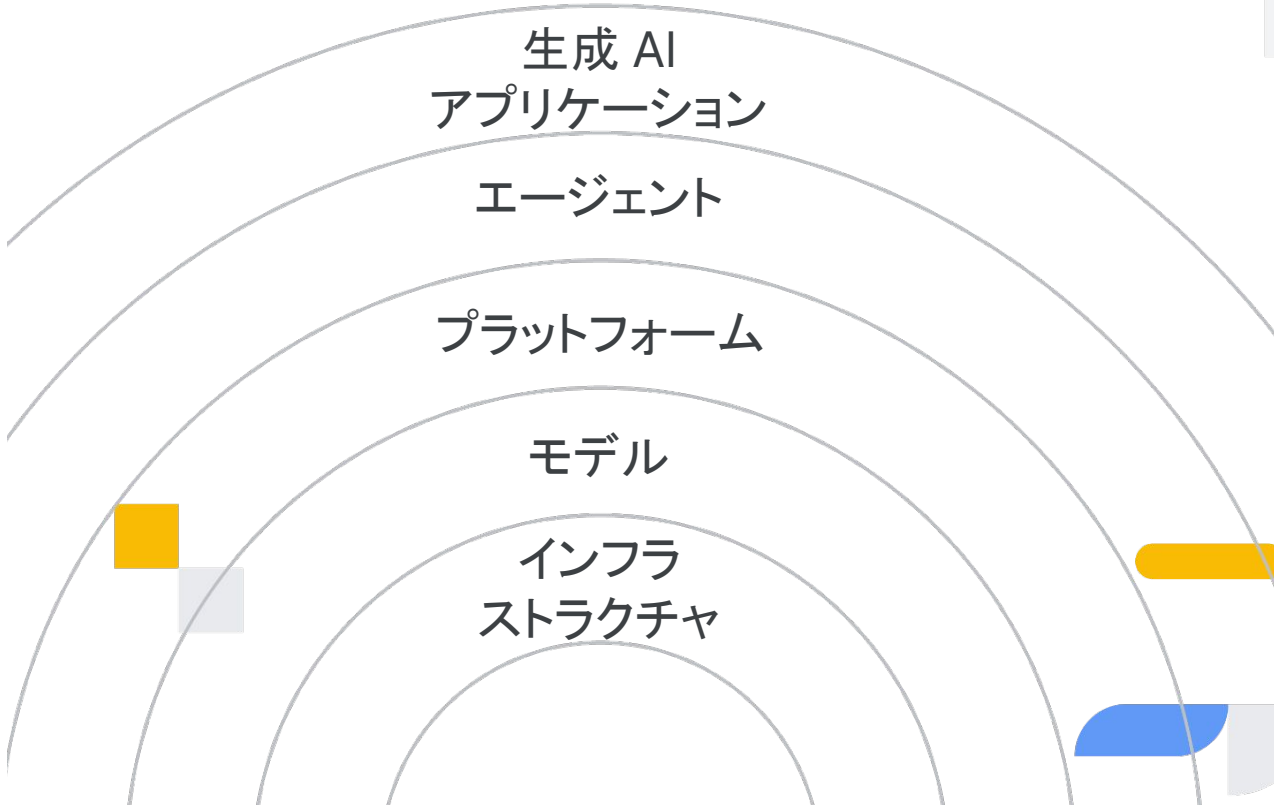
ユーザーはどのように、どこで、いつソリューションとやり取りするか？

どの程度カスタマイズするか？ファインチューニングを行うか、それともまったく新しいモデルを作成するのか？

必要な時間と人数はどれくらいで、予算はいくらか？

役割と責任

- ビジネス リーダー
- デベロッパー
- AI 担当者

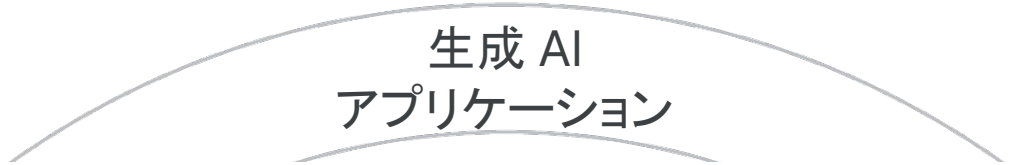


役割と責任

- ビジネス リーダー
- デベロッパー
- AI 担当者

事前構築済みの生成 AI ソリューションを利用して、日々の業務を強化し、カスタマー エクスペリエンスを向上させる。

例: Google Workspace with Gemini。

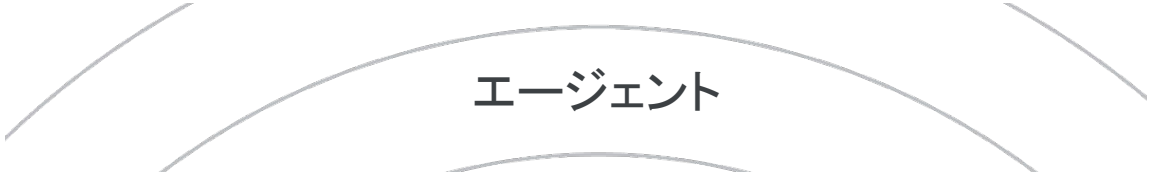


役割と責任

- ビジネス リーダー
- デベロッパー
- AI 担当者

カスタム AI エージェントの構築とデプロイ、
AI 機能の既存アプリケーションへの統合を担当する。

例: AI Applications、AI によるコード生成、AI を活用したデータ処理、事前トレーニング済み API、Agent Platform プラットフォーム

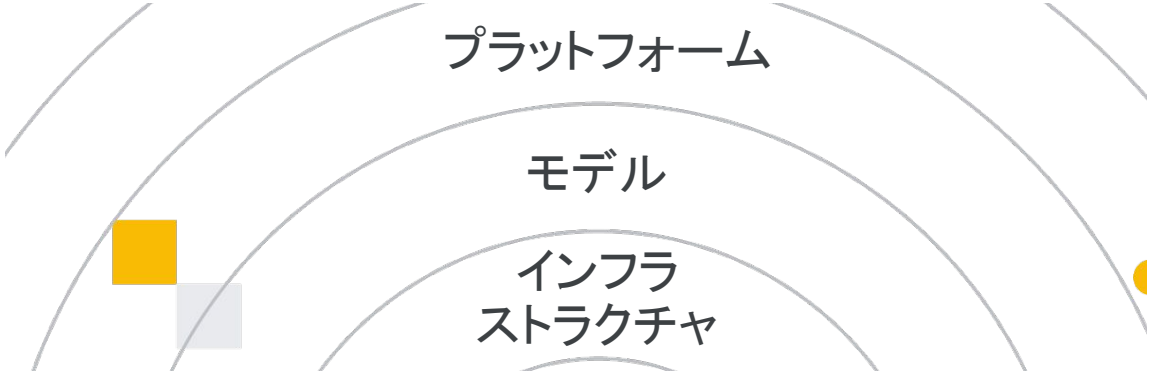


役割と責任

- ビジネス リーダー
- デベロッパー
- AI 担当者

生成 AI モデルのカスタマイズ、デプロイ、
最適化を担当する。

例: Agent Platform、AI ワークロードのスケーリング、
モデルと BigQuery の統合、責任ある AI 対策の
実装



費用

生成 AI ソリューションの構築時には、以下の 3 つの主要アクティビティに対して料金が発生する。

- モデルの**トレーニング** *
- エンドポイントへのモデルの**デプロイ** *
- 予測を行うためのモデルの**使用**



*コンピューティング時間、トレーニング データとモデル出力のストレージ

モデルの使用料金

従量制

- 使用量に応じて料金が発生。
- 処理されたトークン数または文字数の分を支払う。

サブスクリプションベース

- モデルへのアクセスに対して定期料金を支払う。
- 料金は使用量上限または機能に基づく。

ライセンス料

- モデルの使用に対して 1 回限りの料金または定期料金を支払う。
- 営利目的やプロダクトへの組み込みで使用される。

無料枠

- 無料アクセス（使用量に制限あり）。
- テストや非営利目的で使用される。

モデルの使用料金の指標

トークン	言語単位	**テキスト分割単位での課金** 単語・サブワード単位の処理量に応じて算出
文字数	文字単位	**入出力の実文字数での課金** Google Cloud 等で採用される明快な計算基準
リクエスト	呼出回数	**対話ターン（回数）ごとの定額課金** 処理の複雑さや出力規模に依存しない一律計算
コンピューティング時間	実行時間	**リソース消費時間に応じた課金** 高負荷タスクや専用インスタンスの稼働時間で算出

トークン単位の定義と課金イメージ

トークン（Token）とは？

AI がテキストを処理する際の「基本分割単位」です。人間が認識する文字や単語とは異なります。

英語では 1 単語が約 1.3 トークン、日本語では 1 文字が約 1〜2 トークン（漢字や平仮名で変動）として計算されます。

視覚的イメージ：テキストのトークン分割

元の日本語テキスト

自然言語処理された断片

↓

自然言語 | 処理 | 細分化 | された | 断片

それぞれの断片（トークン）ごとに処理・課金される

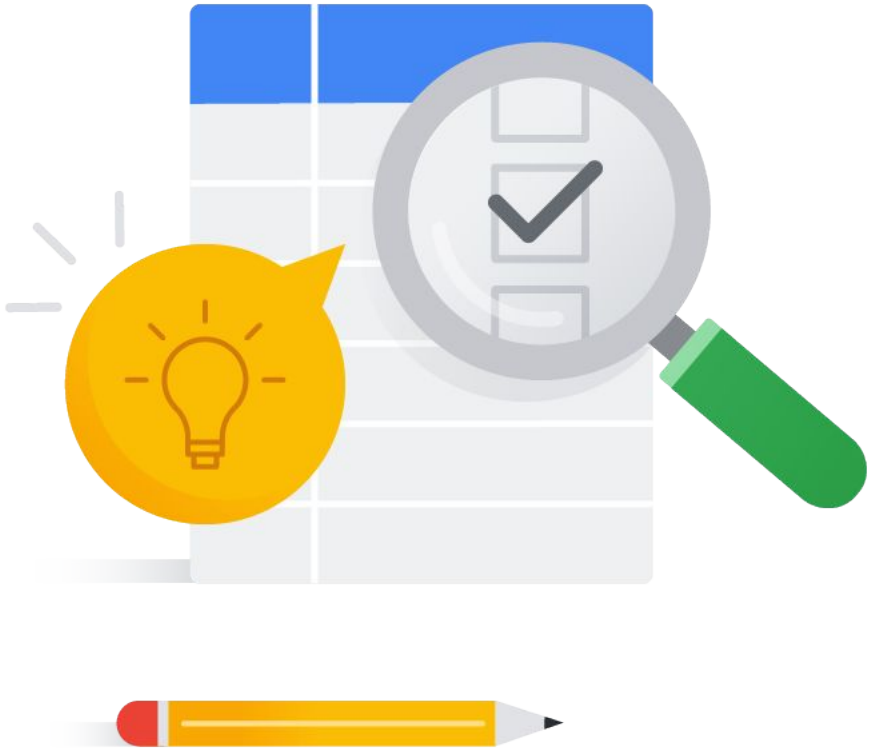
→

API 利用料金の計算

計 5 トークン として課金

デモ: Google Cloud の料金計算ツール

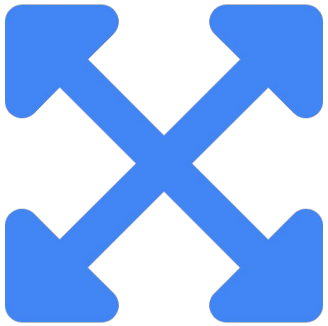
5 分



Google Cloud の料金計算ツール:
https://cloud.google.com/products/calculator?hl=en

参考資料: Agent Platform での AI モデルの構築とデプロイにかかる費用:
https://cloud.google.com/gemini-enterprise-agent-platform/generative-ai/pricing

費用に影響する要素



モデルのサイズと複雑さ

通常、モデルが大規模で高性能であるほど費用が増加する。



コンテキスト ウィンドウ

コンテキスト ウィンドウが大きいほど、費用が増加する可能性がある。



機能

特殊な機能には、別途料金がかかる場合がある。



デプロイ

コンピューティングに基づく費用が発生する場合がある。

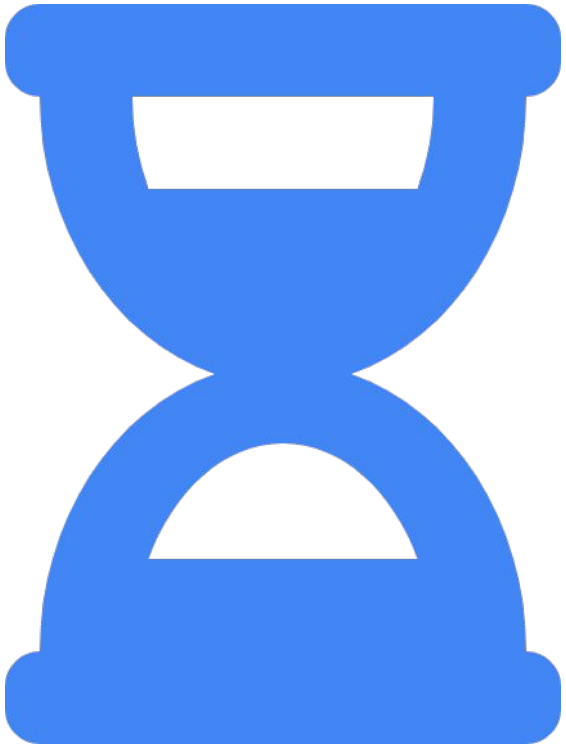
時間

カスタマイズとリソースの関係

ソリューションのカスタマイズが多くなれば、それだけ構築にかかる時間とリソースが増える傾向にあります。

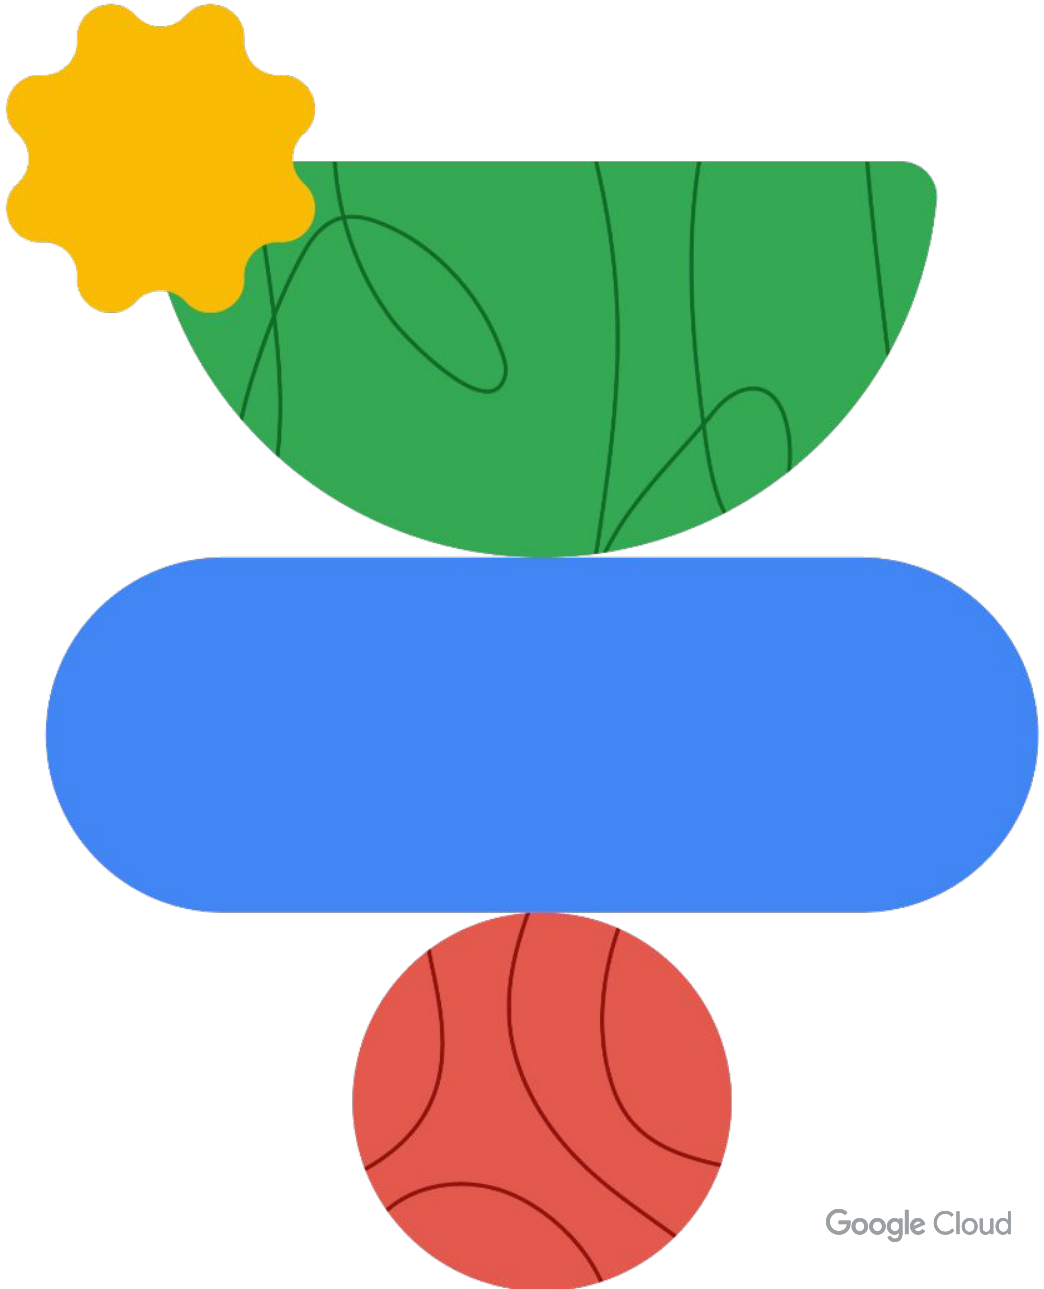
適切な評価とスケジュール策定

プロジェクトの全体スケジュールを考慮し、ビジネスニーズや要件と照らし合わせて最適なロードマップを評価する必要があります。



機密 / 専有情報

生成 AI ソリューションのニーズ



規模



小規模

- 事前構築済みのツールを選択する。
- 既存の生成 AI を活用したアプリケーションを利用する。



大規模

- スケーラビリティとセキュリティを優先する。
- インフラストラクチャの費用、データ ストレージ、レイテンシの課題を考慮する。

カスタマイズ

✓ 既存のモデルから始める	基盤活用	**事前学習済みモデルの活用** ゼロからの開発を避け、特定データでファインチューニング
✓ 固有のニーズを特定する	要件定義	**独自性と専門性の明確化** 専門知識や独自UXの要否から必要な調整レベルを判断
✓ データの特異性について検討する	専門領域	**専門分野データへの適応** 医療・法務など固有データセットの学習や特化モデル選定
✓ タスクの複雑さについて検討する	難易度評価	**処理難易度に応じたモデル選定** 要約（シンプル）から創作・コード生成（高度）まで最適化

ユーザー操作



ユーザー インターフェース（UI）

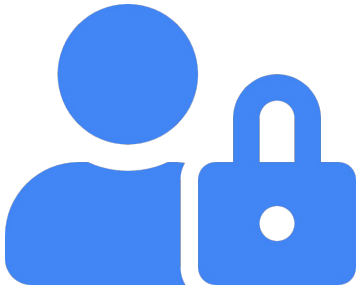
- 既存のワークフローに AI をシームレスに統合する。
- 専用のインターフェースを使用するか、現在のアプリケーションに AI 機能を組み込む。



ユーザー エクスペリエンス（UX）

- ユーザー フレンドリーなエクスペリエンスを目指す。
- 会話型、情報提供型、タスク指向のどれにすべきかを判断する。
- ユーザーが必要とするガイダンスとフィードバックのレベルを検討する。

プライバシー



データ セキュリティ

- 処理中のデータと保存データを保護するために実装する対策。
- 暗号化、アクセス制御、安全なデータセンター。



コンプライアンス

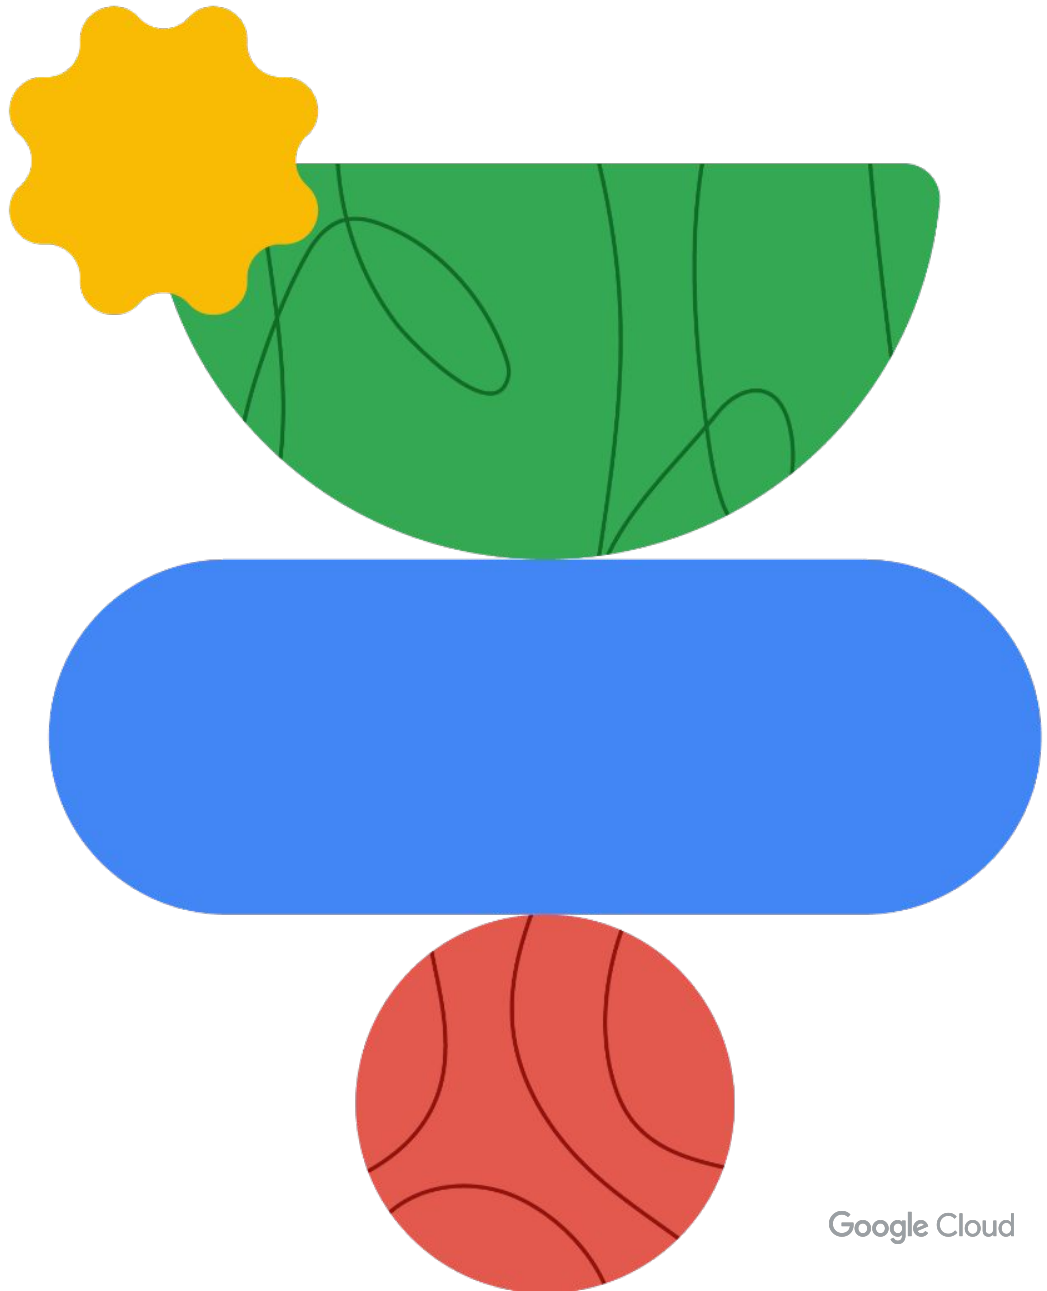
- 遵守すべき特定の規制。

その他の考慮事項

レイテンシ	応答速度	**即時性の要件確認** リアルタイム応答の必要性と許容遅延幅の評価
接続	通信環境	**常時接続要件の判断** インターネット環境とオフライン動作の必要性
精度	品質基準	**許容エラー率の定義** タスクに応じた出力精度と評価指標の策定
説明可能性	透明性	**推論根拠の可視化** 医療・金融等の特定領域における決定理由の明確化

機密 / 専有情報

意思決定とメンテナンス



意思決定: さまざまな企業とモデルの比較

要素の慎重な精査と客観的リソースの徹底調査により、ニーズに最も合致した費用対効果の高いソリューションを選択

意思決定の要点 各要素を慎重に検討・徹底調査することで、**生成 AI の料金や性能について十分な情報に基づく意思決定** を行い、最適な投資効果を実現します。

網羅的な比較検討　隠れコストの排除　規約・安全性の確認

01 さまざまな企業とモデルの比較

検討の 4 つの側面

複数の提供元やモデルを用途に合わせて横断的に見回り、品質・コスト・制約条件を多角的に評価します。

- **モデルの機能を評価する**
  ベンチマークや比較情報を参照し、各モデルの品質とパフォーマンスを精査
- **料金体系を比較する**
  予想される使用量に基づき、プロバイダごとの課金モデル・指標から費用を算出
- **追加費用を考慮に入れる**
  データ保管、API 呼出頻度、ファインチューニングなどの付随コストを網羅
- **注意事項・利用規約を読む**
  使用量上限（クォータ）、データプライバシー保護、各種コンプライアンス規約を確認

02 比較のための主なリソース

情報収集の 3 大ソース

正確で偏りのない判断を下すために、一次情報・独立評価・実運用コミュニティの知見を活用します。

- **プロバイダのウェブサイト** 一次情報
  各企業の公式料金ページ、最新の利用規約、公式仕様ドキュメントを直接確認して最新の価格体系と上限を把握
- **研究論文とベンチマーク** 中立評価
  各モデルの客観的・第三者による性能評価レポートや学術論文を参照し、公称値に惑わされない実力を検証
- **コミュニティ フォーラムと議論** 実務事例
  他のユーザーや導入エキスパートと交流し、実際の運用ノウハウ、障害時の挙動、隠れた運用コストなどの実情を収集

ベストプラクティス : 01 の 4 項目を 02 の信頼できるリソースで照合・精査することで、確実で費用対効果の高いモデル採用を実現

意思決定

01 さまざまな企業とモデルの比較

02 比較のための主なリソース

意思決定

01 さまざまな企業とモデルの比較

02 比較のための主なリソース

- モデルの機能を評価する。
- 料金体系を比較する。
- 追加費用を考慮に入れる。
- 注意事項を読む。

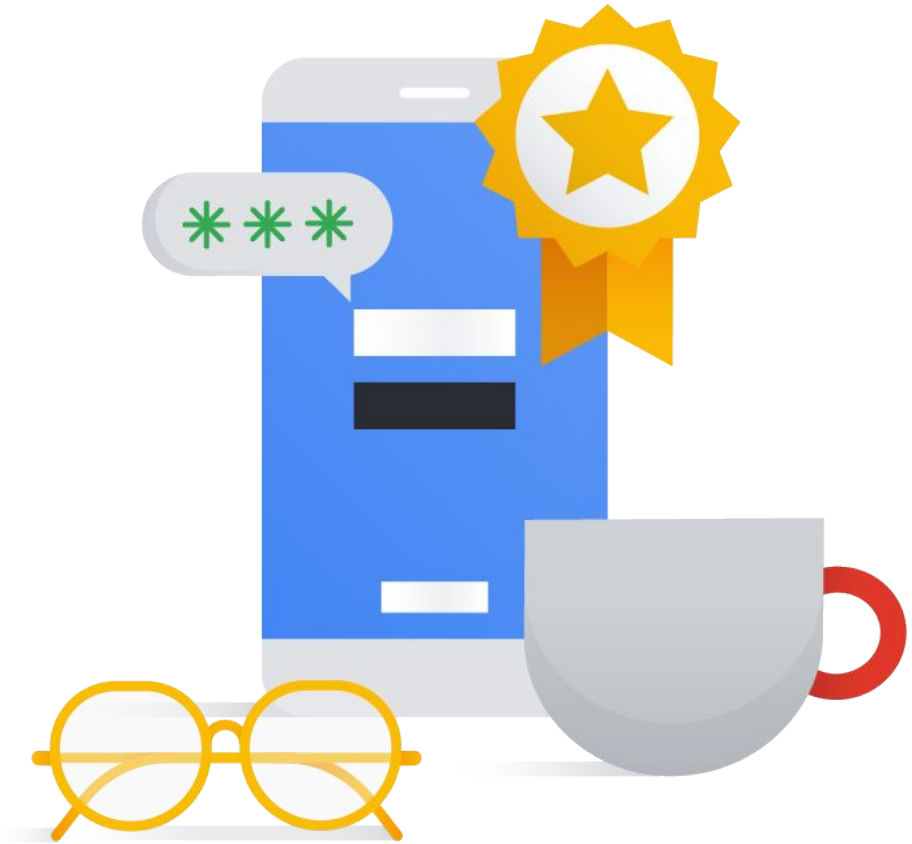
意思決定

01 さまざまな企業とモデルの比較

02 比較のための主なリソース

- プロバイダのウェブサイト
- 研究論文とベンチマーク
- コミュニティ フォーラムと ディスカッション

簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

生成 AI のコンテキストにおける AI 担当者の主な責任に関する説明として、最も適切なものは次のうちどれですか。

A. 事前構築済みの生成 AI ソリューションを活用して、日々のビジネス業務を改善する。

B. カスタム AI エージェントを構築してデプロイし、AI を既存アプリケーションに統合する。

C. 責任ある AI への取り組みを実現しながら、生成 AI モデルをカスタマイズ、デプロイ、最適化する。

D. AI を活用したアプリケーションとのやり取りによって、ユーザー エクスペリエンスを向上させる。

理解度チェック | 問題 01

正解

生成 AI のコンテキストにおける AI 担当者の主な責任に関する説明として、最も適切なものは次のうちどれですか。

A. 事前構築済みの生成 AI ソリューションを活用して、日々のビジネス業務を改善する。

B. カスタム AI エージェントを構築してデプロイし、AI を既存アプリケーションに統合する。

C. 責任ある AI への取り組みを実現しながら、生成 AI モデルをカスタマイズ、デプロイ、最適化する。



D. AI を活用したアプリケーションとのやり取りによって、ユーザー エクスペリエンスを向上させる。

メンテナンス

- プロジェクトのメンテナンスをどのように行うか。
- プロジェクトの長期的なメンテナンスのための
  リソースを確保しているか。
- プロジェクトには具体的にどのようなメンテナンスが必要
  か。



メンテナンスに関する重要な考慮事項

モデルのモニタリングと再トレーニング

- モデルのパフォーマンスを継続的にモニタリングする。
- モデルを定期的に再トレーニングする。

データの更新

- モデルを最新かつ関連性の高い状態に保つために、定期的なアップデートを計画する。

ソフトウェア アップデートとバグの修正

- アップデート情報を常に把握する。
- アップデートを適切に実装する。

メンテナンスに関するその他の重要な考慮事項

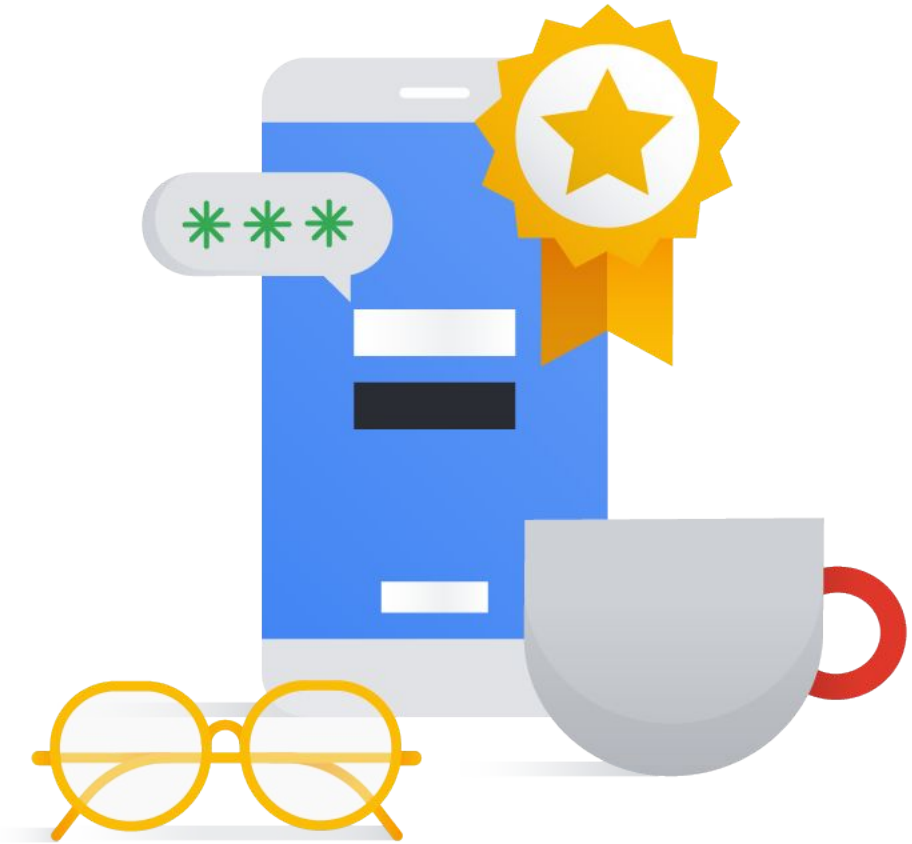
ハードウェアとインフラストラクチャ

- サーバーのメンテナンス。
- セキュリティに関する更新。
- キャパシティプランニング。

セキュリティとコンプライアンス

- セキュリティ対策を定期的に見直し、更新する。
- データ プライバシーへの継続的なコンプライアンスを確保する。

簡単な理解度チェックに
挑戦しましょう。



理解度チェック | 問題 01

問題

カスタム AI エージェントの構築とデプロイ、AI 機能のアプリケーションへの統合の責任を担うのは誰ですか。

A. ビジネス リーダー

B. デベロッパー

C. AI 担当者

D. ネットワーク エンジニア

理解度チェック | 問題 01

正解

カスタム AI エージェントの構築とデプロイ、AI 機能のアプリケーションへの統合の責任を担うのは誰ですか。

A. ビジネス リーダー

B. デベロッパー 

C. AI 担当者

D. ネットワーク エンジニア

理解度チェック | 問題 02

問題

マーケティング チームが、近々予定されている e コマースセールに向けて魅力的な商品説明を迅速に作成する必要があります。この目的を達成する最も効率的な方法はどれですか。

A. 商品説明を生成するカスタムモデルをゼロから構築する。

B. Model Garden から事前トレーニング済み言語モデルを取得し、既存の商品データでファインチューニングする。

C. コピーライターのチームを雇って、すべての商品説明を手動で作成する。

D. Google Workspace with Gemini などの生成 AI を活用したアプリケーションを使用して、商品説明の下書きを作成する。

理解度チェック | 問題 02

正解

マーケティング チームが、近々予定されている e コマースセールに向けて魅力的な商品説明を迅速に作成する必要があります。この目的を達成する最も効率的な方法はどれですか。

A. 商品説明を生成するカスタムモデルをゼロから構築する。

B. Model Garden から事前トレーニング済み言語モデルを取得し、既存の商品データでファインチューニングする。

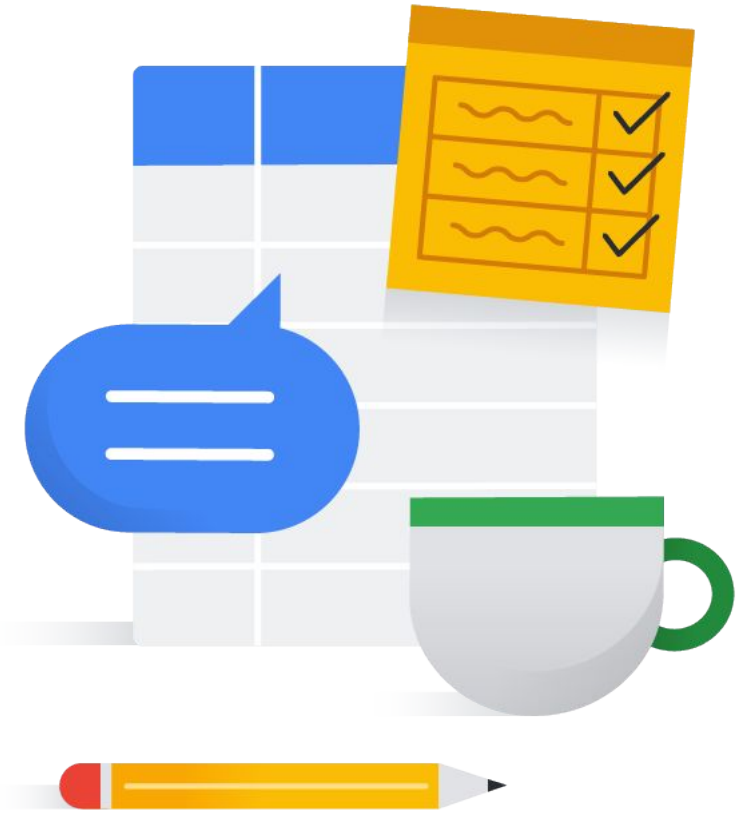
C. コピーライターのチームを雇って、すべての商品説明を手動で作成する。

D. Google Workspace with Gemini などの生成 AI を活用したアプリケーションを使用して、商品説明の下書きを作成する。

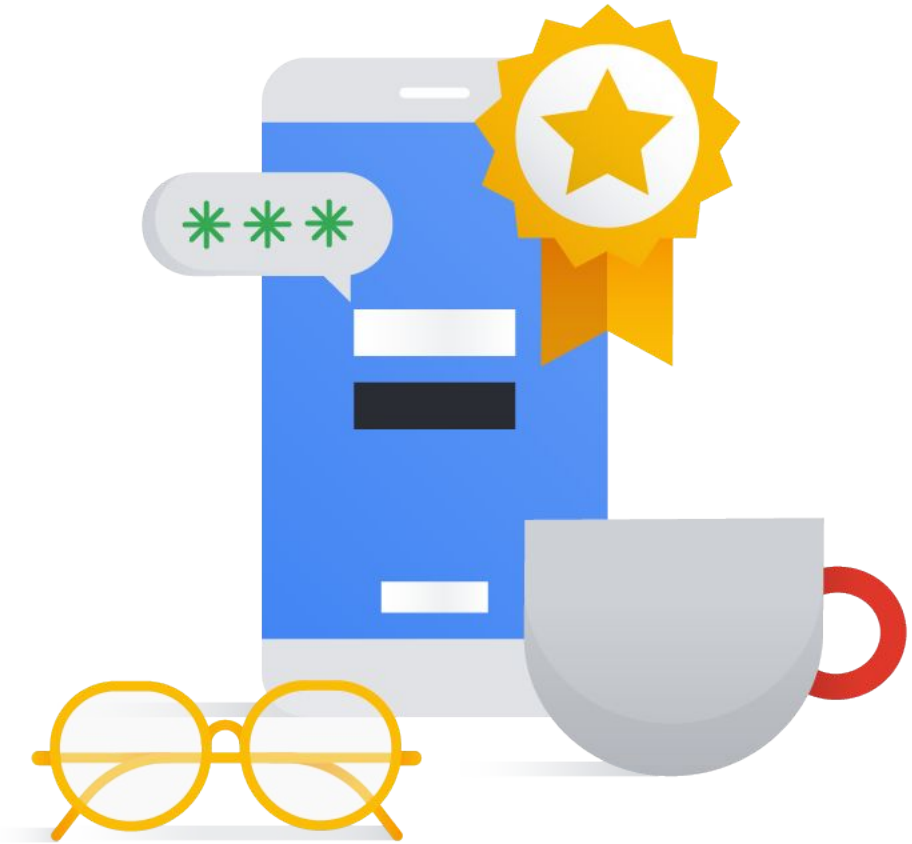


重要ポイント

- 生成 AI を成功させるには、ソリューションの複雑さに応じた戦略的なリソース配分、費用に対する意識、現実的なスケジュールが必要となる。
- AI の将来を見据えた計画を立てる。調整、更新、最適化によって継続的な価値を確保し、費用のかかるエラーを回避する。



最後に、モジュール 03
の理解度チェック
に挑戦しましょう。



理解度チェック | 問題 01

問題

AI エージェントをスタンドアロンの AI モデルと区別する重要な要素は何ですか。

A. 自然言語処理と ML

B. 推論ループとツール

C. データアクセスとユーザー インターフェース

D. 自動化とパーソナライズ

理解度チェック | 問題 01

正解

AI エージェントをスタンドアロンの AI モデルと区別する重要な要素は何ですか。

A. 自然言語処理と ML

B. 推論ループとツール 

C. データアクセスとユーザー インターフェース

D. 自動化とパーソナライズ

理解度チェック | 問題 02

問題

次のうち、AI アプリケーションにおけるエッジ コンピューティングの主なメリットはどれですか。

A. データ ストレージ容量の増加

B. データ前処理の必要性の低減

C. リアルタイムの応答性とレイテンシの低減

D. 開発費用の削減

理解度チェック | 問題 02

正解

次のうち、AI アプリケーションにおけるエッジ コンピューティングの主なメリットはどれですか。

A. データ ストレージ容量の増加

B. データ前処理の必要性の低減

C. リアルタイムの応答性とレイテンシの低減



D. 開発費用の削減

理解度チェック | 問題 03

問題

生成 AI ソリューションに関する意思決定で重要な手順は何ですか。

A. さまざまな企業とモデルを比較する。

B. 最先端の機能を優先する。

C. データ ガバナンスやコンプライアンスへの影響を理解するよりも、初期デプロイの容易さを優先する。

D. 初期の統合の取り組みを重視し、長期的なメンテナンスとスケーラビリティについては後から検討する。

理解度チェック | 問題 03

正解

生成 AI ソリューションに関する意思決定で重要な手順は何ですか。

A. さまざまな企業とモデルを比較する。



B. 最先端の機能を優先する。

C. データ ガバナンスやコンプライアンスへの影響を理解するよりも、初期デプロイの容易さを優先する。

D. 初期の統合の取り組みを重視し、長期的なメンテナンスとスケーラビリティについては後から検討する。

モジュールの目的

01 生成 AI を取り巻く環境のレイヤについて説明する。

02 生成 AI を取り巻く環境の中から、ビジネスニーズとイノベーションに対応するためのエントリ ポイントを特定する。

03 Google Cloud の生成 AI ポートフォリオのコンポーネントを説明する。

04 Google Cloud の AI に最適化されたリソースが生成 AI の開発をどのようにサポートするのかを説明する。

05 特定の用途において考慮すべきビジネス上の要因を説明する。



モジュール 03：試験出題ポイントチェックリスト

生成AIスタック階層・自律型エージェント設計・トークンコスト最適化の頻出論点整理

① 5 つのレイヤ構造

・インフラ〜モデル層 TPU/GPU ハードウェアと Gemini 基盤モデルの明確な分離。

・プラットフォーム（ Agent Platform） 検索・チューニング・評価ツール群を提供する開発環境層。

・エージェント〜アプリ層 タスク実行オーケストレーションとユーザー向け UI/ 業務機能。

試験のツボ

要件（例: 監査要件や独自UI構築）に対し、どのレイヤの技術を選択すべきかを問う問題が頻出。

② エージェントとモデル

・モデル単体の役割 入力コンテキストに基づくテキスト・コードの「推論と生成エンジン」。

・エージェントの本質 目標達成に向けた「推論＋計画＋外部ツール（API）呼び出し」。

・自律的なタスク遂行 実行結果を観察（Observe）し、完了までループ実行する自律性。

★試験のツボ

「受動的な回答生成」か「外部DB更新・予約等のアクション実行」かでモデルとエージェントを区別。

③ トークン課金とリソース

・入出力トークンの非対称性 一般に出力（生成）トークンの方が処理負荷が高く単価も高額。

・コンテキストウィンドウ管理 長大入力は情報保持に優れるが、レイテンシと課金増のトレードオフ。

・クォータとスループット RPM/TPM 制限の管理や、安定稼働に向けたプロビジョンド割当。

★試験のツボ

コスト削減策として「不要なプロンプトの削減」や「キャッシュ活用（Context Caching）」が直結。

参考情報

レッスン 03

- モデルと仕様の例

レッスン 03

- Lite Runtime（LiteRT）の概要

- Agent Platform での AI モデルの構築とデプロイの費用



機密 / 専有情報

モジュール 03
これで完了です