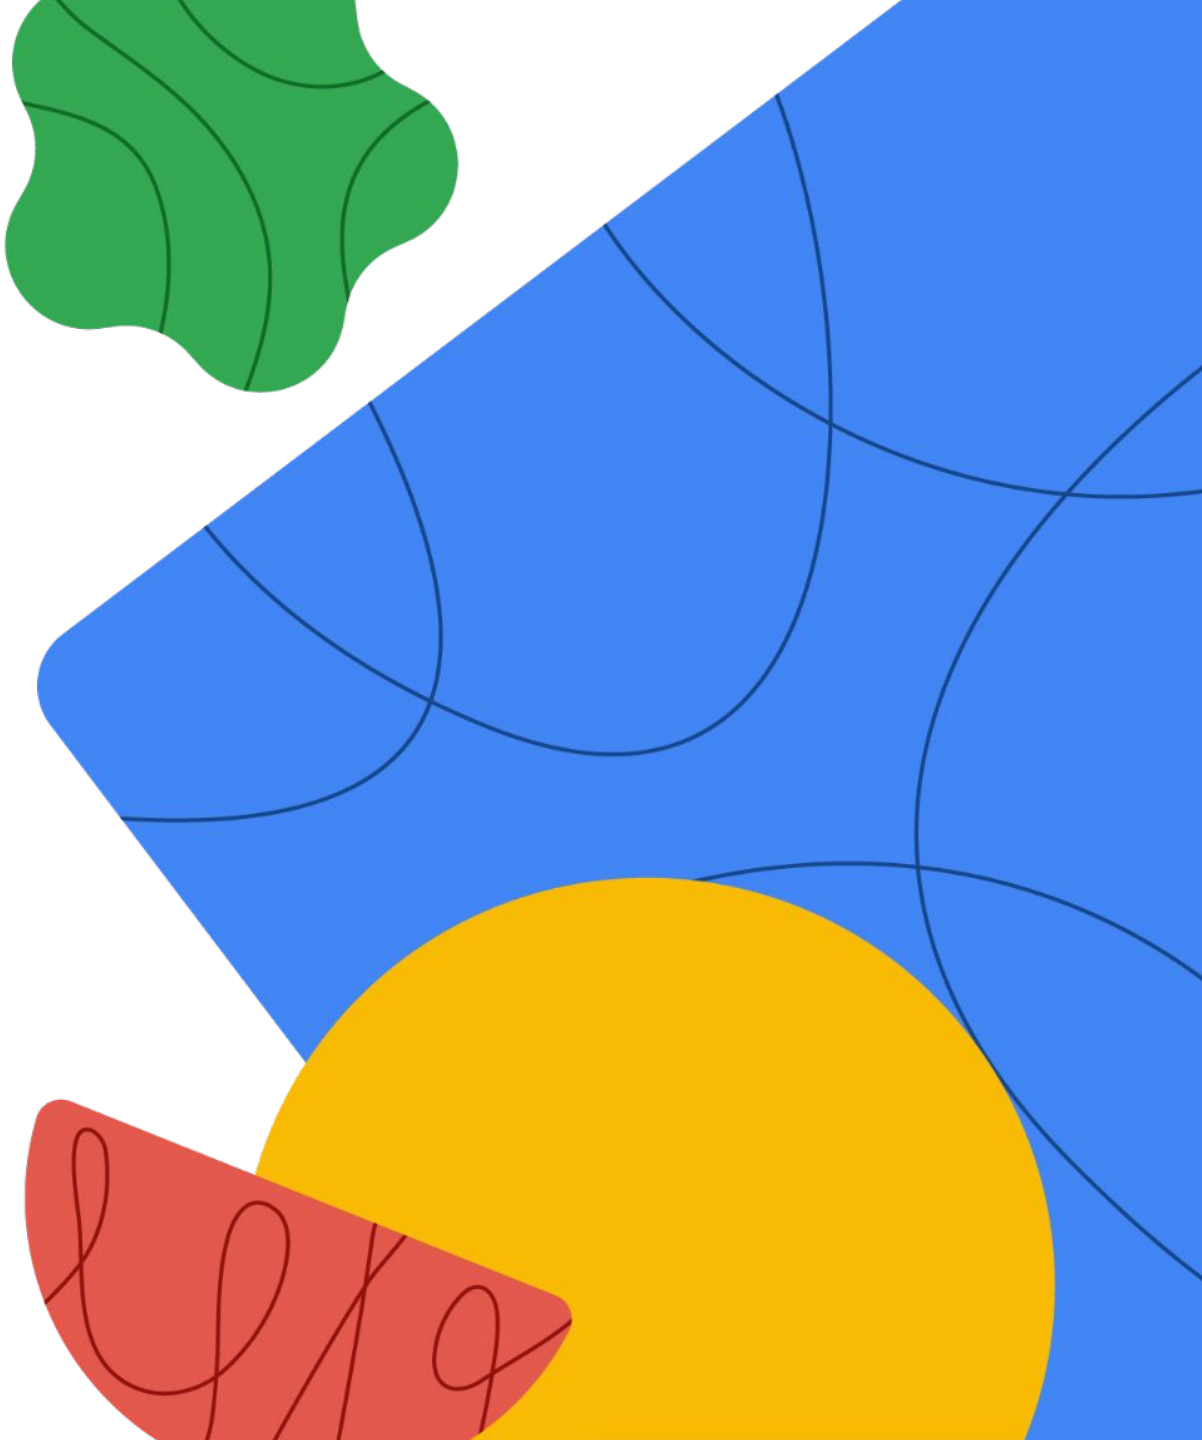
Google Cloud

モジュール 05
生成 AI エージェント: 組織の変革



機密 / 専有情報

生成 AI リーダー学習プログラム



01

生成 AI: chatbot を超えるもの

02

生成 AI: 基本概念の理解

03

生成 AI: 現状の把握

04

生成 AI アプリ: 働き方の変革

05

生成 AI エージェント: 組織の変革

機密 / 専有情報

モジュールの目的

01 生成 AI エージェントの構成要素を定義し、
それぞれがどのように連携するかを確認する。

02 生成 AI エージェントの構成要素を組み合わせて、
強力なソリューションを構築する方法を説明する。

03 Google Cloud の生成 AI プロダクトを使用して
生成 AI エージェントおよび生成 AI ソリューションを作成
する方法を説明する。

04 生成 AI を使用して、組織の変革を効果的に推進
する方法を説明する。





アジェンダ

01 昨今のエージェント

02 エージェントの構築

03 エージェントによるカスタマー エクスペリエンスの向上



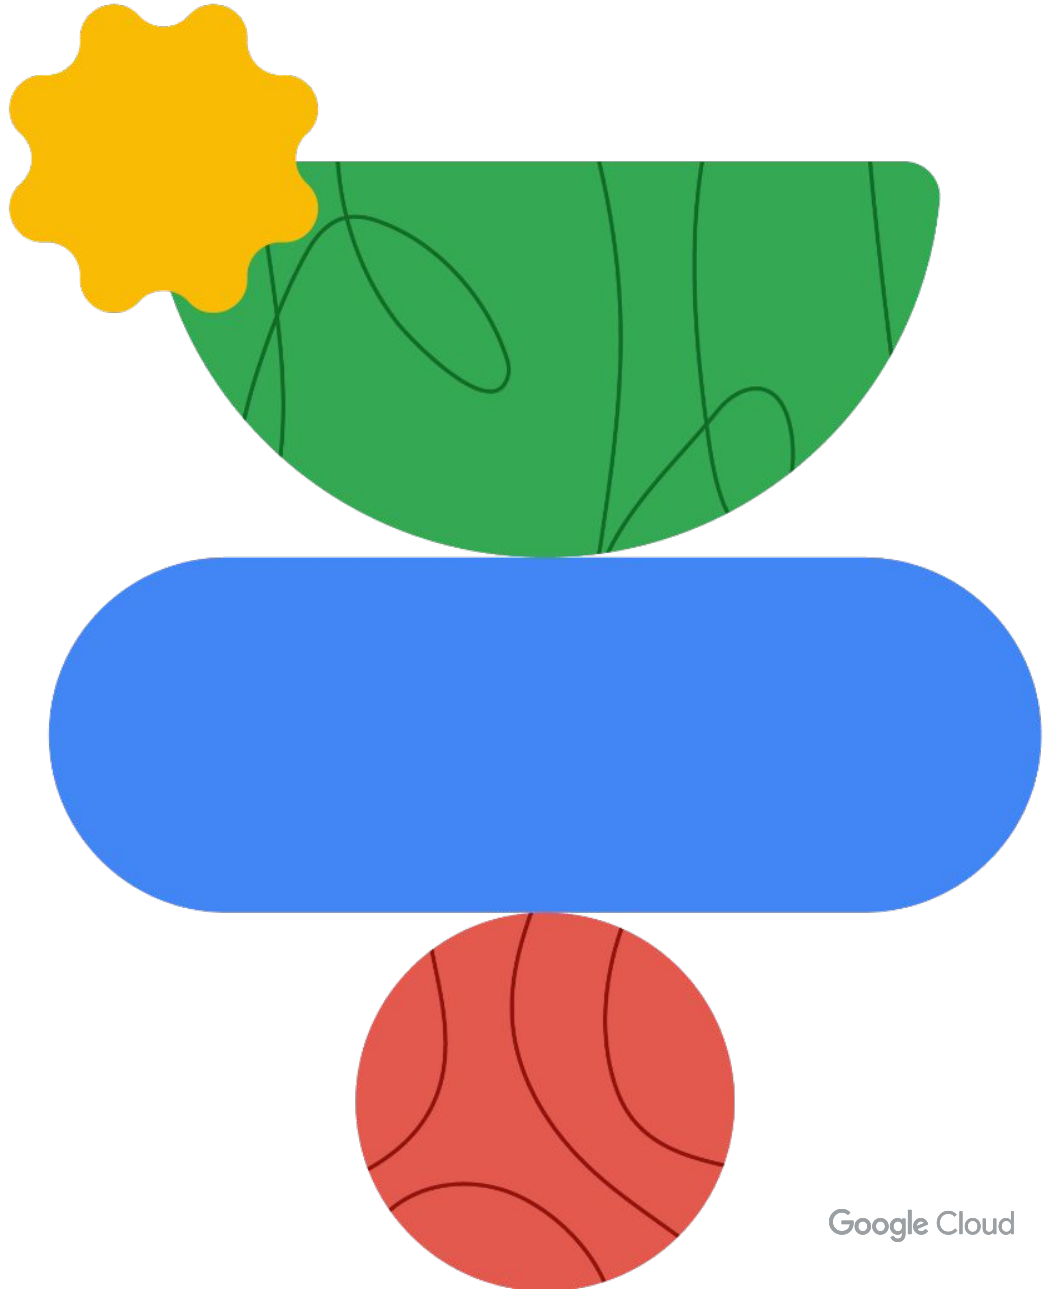
機密 / 専有情報



昨今のエージェント

機密 / 専有情報

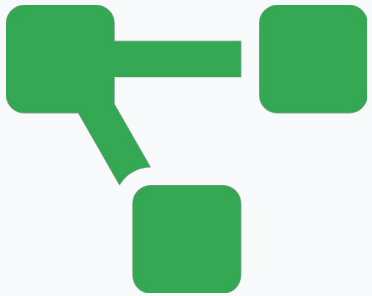
エージェントの歩み



エージェントの歩み

01 決定論的（従来型）

- 事前定義されたパスとアクションに基づく
- ワークフローベースでイベント ドリブン
- 高度に制御できて、予測しやすい
- 構成要素: 推論ループ + ツール（基盤モデルなし）



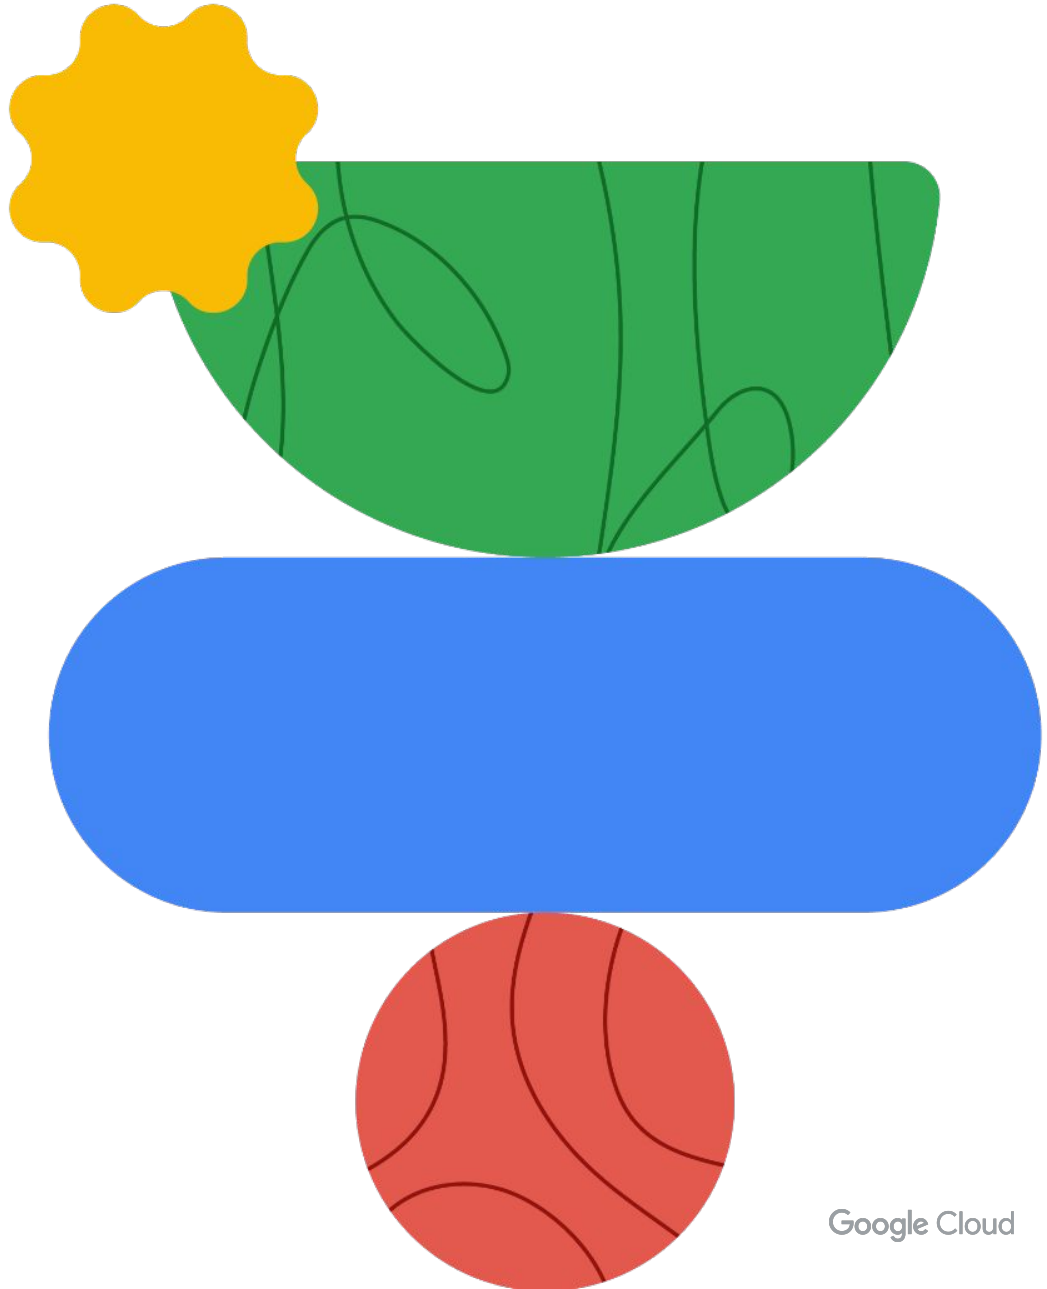
02 生成 AI エージェント

- より自然で柔軟な自律的会話・協調動作が可能
- 状況や文脈に応じて動的に回答が変化
- RAG等により、外部ソースからリアルタイムに情報統合
- 構成要素: 推論ループ + ツール + 基盤モデル



機密 / 専有情報

生成 AI エージェントの構成要素



生成 AI エージェントの構成要素

基盤モデル・ツール・推論ループの三位一体により、単なる対話型モデルを超えた自律的タスク遂行を実現

01 基盤モデル

- エージェントを支える**基盤となる大規模言語モデル（LLM）**
- 意図された**ユースケースに関連するデータ**でトレーニングされたモデルを選択
- 小規模・大規模モデル、**Gemini などの Google 製**および外部モデルを用途に応じて適用



02 ツール

- 世界を**観察し、それに応じて行動** すること（インタラクション）を可能にする
- **拡張機能（API 接続）**、**関数（疑似 API 呼び出し）**、**データストア** など
- 外部システムとの接続により、**リアルタイム情報取得や実作業の実行** を代行



03 推論ループ

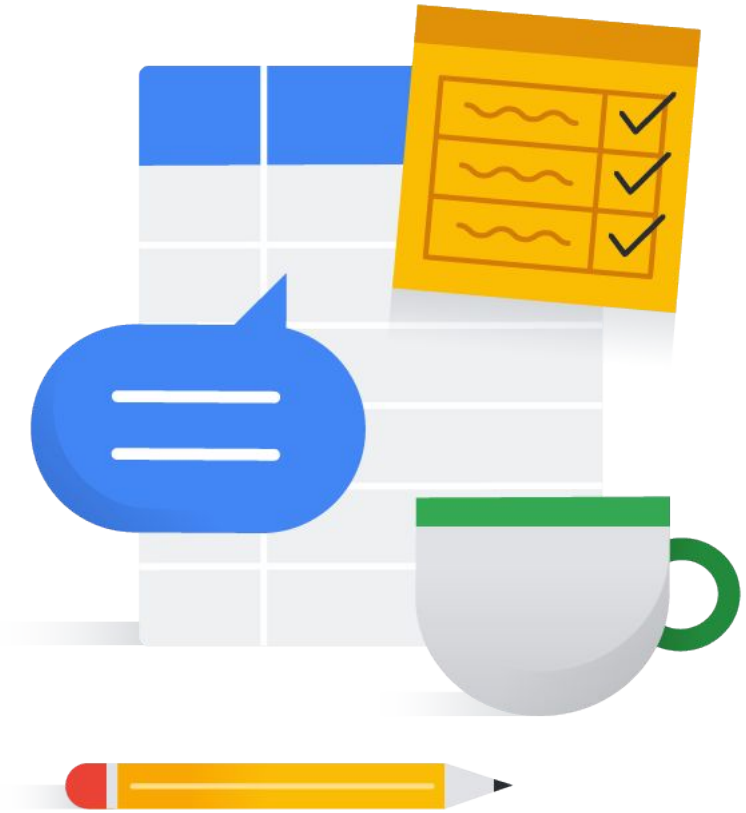
- エージェントによる**意思決定と行動を司る中核**
- **目標、利用可能なツール、収集した情報**を総合的に考慮する反復プロセス
- **ReAct（Reason and Act）**などの確立されたフレームワークによってプロセスを主導



3 つの要素が協調することで、外部環境の認識から自律的な行動・反復学習までの一連のサイクルが完結

重要ポイント

- 自然言語理解機能が追加されたことによって、柔軟性のない決定論的エージェントから生成 AI エージェントに進化した。生成 AI エージェントは、基盤モデル、インタラクションのためのツール、推論ループを使用する。





アジェンダ

01 昨今のエージェント

02 エージェントの構築

03 エージェントによるカスタマー エクスペリエンスの向上



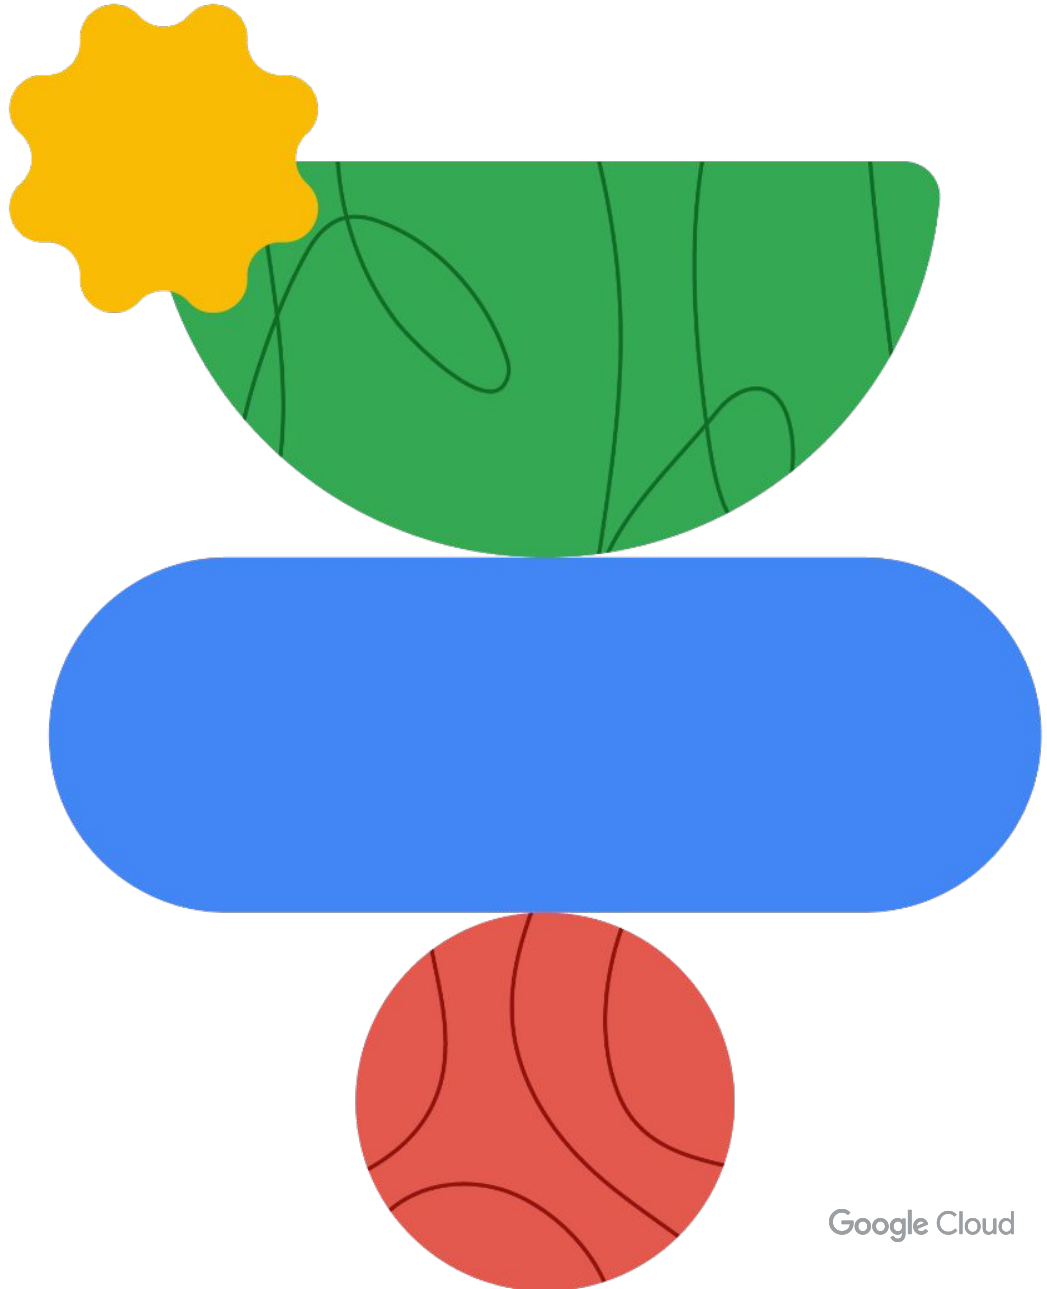
機密 / 専有情報



エージェントの構築

機密 / 専有情報

モデルの使用



サンプリング パラメータと設定

トークン数	処理単位	**テキストの基本単位と処理容量** 1トークン ≒ 4 文字。一度に扱える情報量と必要計算リソースの上限を規定
温度（Temperature）	ランダム性	**単語選択のランダム性と創造性の制御** 低値で決定的・再現性重視（Q&A）、高値で多様・予想外な表現（創作）
Top-K	上位固定候補	**確率上位 K 個からのランダム選択**単語候補を上位の決まった個数に限定し、極端に不適切な単語の混入を防止
Top-P（Nucleus サンプリング）	累積確率	**累積確率に基づく動的な候補の絞り込み** 確信度に応じて候補数を伸縮させ、整合性とバリエーションを両立
安全性設定	保護・統制	**有害・不適切な出力のフィルタリング** ニーズやコンプライアンスに応じてカテゴリ別のブロック基準を調整
出力長（Max Output Tokens）	応答長制御	**生成されるテキストの最大長を決定** 単語数や最大トークン数を指定し、簡潔な回答維持やコスト消費をコントロール

温度（Temperature）と Top-P

モデルの「決定性（事実性）」と「多様性（創造性）」を制御する仕組みと、試験で問われる使い分けの鉄則

0.0事実性・再現性の最大化 ——— **創造性・多様性の最大化 1.0**

決定的な回答 / 確実なタスク向け

確率の差を極端に強調し、常に最も確率の高い単語を選択（再現性100%のGreedy Searchに近い）。構文エラーを嫌うコード生成や事実のみを答えるQ&Aに最適。

意外性のある表現 / 斬新なアイデア創出向け

確率分布をなだらかにし、低確率の言葉もサンプリング対象に。表現の幅が広がりユーモアや物語を生む一方、ハルシネーション（事実誤認）のリスクが増加。

試験対策：タスク別推奨パラメータ設定マトリクス

💻 コード生成 / 事実ベース回答

厳密な論理、一貫性、バグのなさが絶対条件となる再現重視タスク

Temperature: 0.0 ～ 0.2

Top-P: 0.1 ～ 0.5

【鉄則】迷ったら即座に Temperature=0を選択

📄 要約 / データ抽出 / 翻訳

原文の文脈を完全に保持しつつ、自然な表現のゆらぎを取り入れるタスク

Temperature: 0.2 ～ 0.5

Top-P: 0.7 ～ 0.8

【鉄則】事実性と表現のなめらかさのバランス調整

✨ 広告コピー / 創作 / ブレスト

ありきたりではない語彙、斬新なアイデア、多様な切り口を求めるタスク

Temperature: 0.7 ～ 1.0

Top-P: 0.9 ～ 0.95

【鉄則】不自然な単語を省きつつ創造性を最大化

モデルへのアクセスと設定変更



提供元や方法による個別設定

モデルの設定を変更する方法は、モデルの提供元（Google Cloud等）やアクセス方法（コンソール、Webツールなど）の環境によって仕様やインターフェースがそれぞれ異なります。



API を通じた設定変更（主要ルート）

多くの場合は、**アプリケーション プログラミング インターフェース（API）**を通じて、プログラムから動的かつ柔軟に設定（パラメータ、安全性設定など）を変更します。

Google の生成 AI ツール：選定と使い分け

開発フェーズと統制要件に合わせて、2つの環境を最適に使い分けます

Google AI Studio　Webベース (即時検証)

対象: 開発者・学生・研究者

アイデアを形にするためのエントリー環境。APIキーを即座に発行し、Geminiの性能を素早くテスト

移行のトリガー

・本番運用への実装
・厳格なガバナンス
・モデルの独自調整

Agent Studio　Google Cloud (本番・統制)

対象: 企業組織・MLエンジニア・エンタープライズ開発者

セキュリティと組織管理(IAM)を担保した本番運用向け環境。高度なチューニングや各種システムとの安全な統合をサポート。

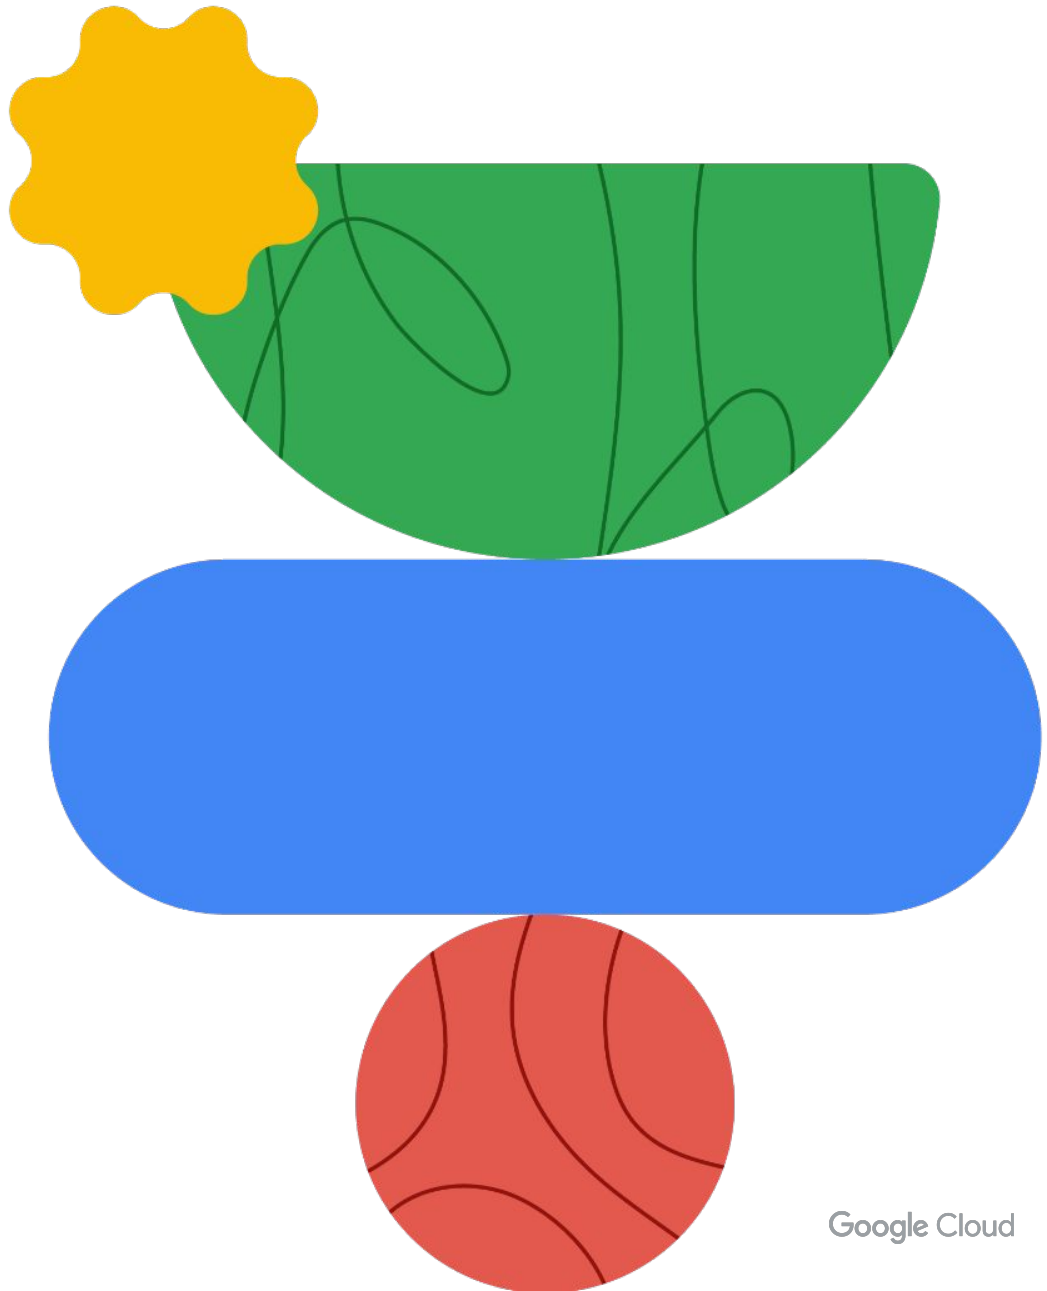
比較項目	Google AI Studio (プロトタイプ向け)	Agent Studio (エンタープライズ向け)
実行基盤 & アクセス	Web ブラウザ経由、標準の Google アカウントで即座に開始可能	Google Cloud コンソール内、GCP プロジェクト配下で利用
ガバナンス & セキュリティ	手軽な検証・個人開発に最適な基本構成	**組織ポリシー準拠、IAMによる詳細なアクセス制御、エンタープライズ基準**
主要な機能と連携	プロンプト実験、検証、Gemini API コードの即時取得	**基盤モデルのチューニング、グラウンディング、容易なデプロイ**
割り当て & 料金体系	利用量に上限あり(無料枠を中心としたプロトタイプ設計向き)	柔軟な割り当て調整、企業の商用利用に合わせた従量課金システム

💡 **実践のベストプラクティス ：**

まずは Google AI Studio で素早くプロトタイプ検証を行い、本番運用や厳格なガバナンスが必要になった段階で Agent Studio へ移行するのが 最適です。

機密 / 専有情報

推論ループへの プロンプト エンジニアリングの追加



推論ループ

反復プロセス

エージェントが自身の進捗状況を継続的に評価し、次に取るべき最善のアクションを決定する。

内部推論

エージェントが基盤となる言語モデルを使用して、タスクを完了するために必要なステップを推論
する。

意思決定

エージェントが内部推論に基づいて、次に取るべきアクションを決定する（ツールを選択し、ツールに必要な入力を判断する）。

推論フレームワーク

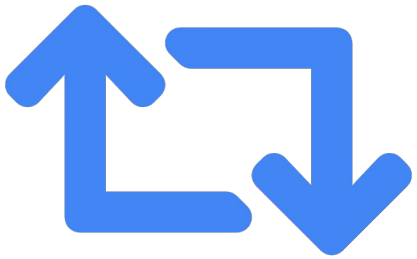
推論ループでは推論と計画の指針として、プロンプト エンジニアリングのフレームワークと手法が使用される。

プロンプト エンジニアリングの手法



Chain-of-Thought（CoT）

問題解決のプロセスに沿って言語モデルを誘導するために、中間の推論ステップを例で示すという手法。



ReAct（推論と行動）

コンテキストに沿った例の有無にかかわらず、言語モデルがユーザーのクエリに基づいて推論し、行動できるようにするためのプロンプト フレームワーク。

Chain-of-Thought（CoT）

- CoT は中間ステップを通じて推論能力を発揮できるようにする。
- LLM に単にプロンプトを渡して回答を期待するのではなく、推論プロセスに沿って LLM を導く。
- 中間ステップは、正解へと導く「思考の連鎖」。



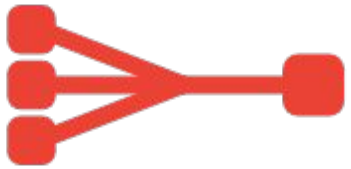
CoT の実装方法

- 自己整合性
- 積極的なプロンプティング
- マルチモーダル CoT

CoT の実装方法

01 自己整合性

- 複数のソリューションを生成し、その中から**最も整合性の高い解**を選択するよう促す
- 多様な推論パスを並行して展開し、**多数決による合意形成**を行う
- 推論の誤りやランダムなハルシネーションを大幅に抑制



02 積極的なプロンプティング

- LLM が**明確化のための質問や追加情報**を自律的にリクエストできるようにする
- 前提条件が曖昧な場合に独断で進めず、**能動的に確認・対話**
- ユーザー意図との齟齬を解消し、回答の正確性を向上



03 マルチモーダル CoT

- 推論を強化するために、テキストに**画像や動画などの多様なデータ**を組み合わせる
- 図表、ダイアグラム、映像フレームなどの**非言語コンテキスト**を思考ステップに統合
- 高度な空間認識や視覚的証拠に基づく判断を実現



CoT が重要である理由

推論機能の強化

LLM が論理的思考を必要とする複雑な問題を解決するうえで役立つ。

精度の向上

問題を小さなステップに分割すると、より精度の高い結果につなげることができる。

説明可能性の強化

LLM が回答にたどり着くまでの道筋が理解しやすくなり、信頼性と透明性が高まる。

CoT の活用例



複雑な推論タスク



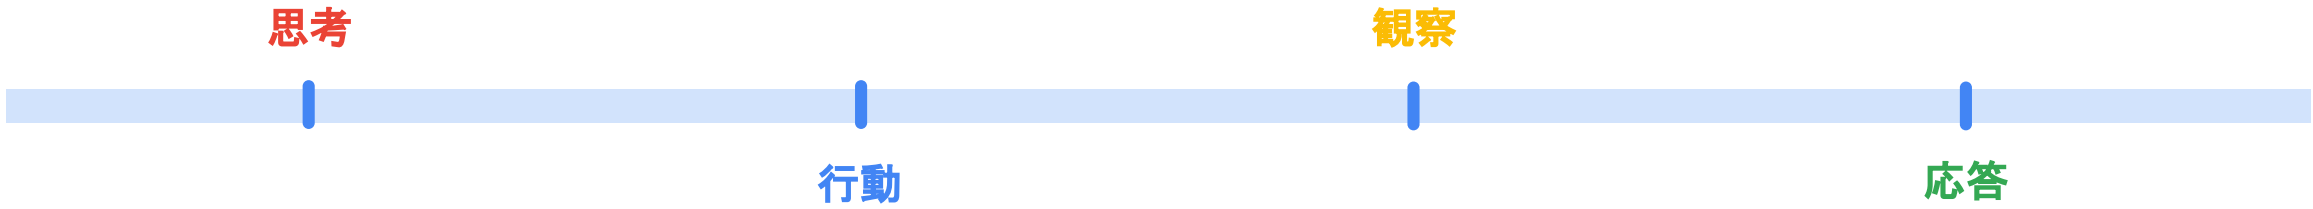
説明の生成



マルチステップの計画

ReAct の主な構成要素

ReAct を使用すると、LLM が実世界とやり取りして情報を収集できる。



ReAct の主な構成要素

思考
LLM が問題に関する思考を生成する。

行動
LLM が取るべき行動を決定し、その行動に必要な入力を指定する。

観察
行動の結果として、LLM がフィードバックを受け取る。

応答
LLM が応答を生成する。

機密 / 専有情報

ReAct:「思考 - 行動 - 観察」ループ



機密 / 専有情報

ReAct:「思考 - 行動 - 観察」ループの例

思考
この辺りにあるイタリア料理のレストランを見つけるよう要求されている。

行動
この地域のイタリア料理レストランをオンラインで検索しよう。

観察
評価の高い候補がいくつか見つかった。

思考
ユーザーの好みからすると、どの候補が最適だろう。

行動
メニューを見て、とりわけおいしそうな料理を提供しているレストランを選ぼう。

観察
ここでは、おいしそうなパスタ料理を提供している。

応答
[名前] をおすすめします。高い評価を受けていて、近くにあり、パスタ料理の種類も豊富なレストランです。

ReAct が重要である理由

動的な問題解決

外部リソースとやり取りして新しい情報に適応する必要がある複雑なタスクでも、LLM が対処できるようになる。

ハルシネーションの低減

グラウンディングにより、誤った情報や意味不明な情報を生成するリスクが軽減される。

信頼性の向上

LLM の推論プロセスと外部ソースとのやり取りを可視化できるため、応答の透明性と信頼性が高まる。

機密 / 専有情報

ReAct の活用例



質問応答



事実確認

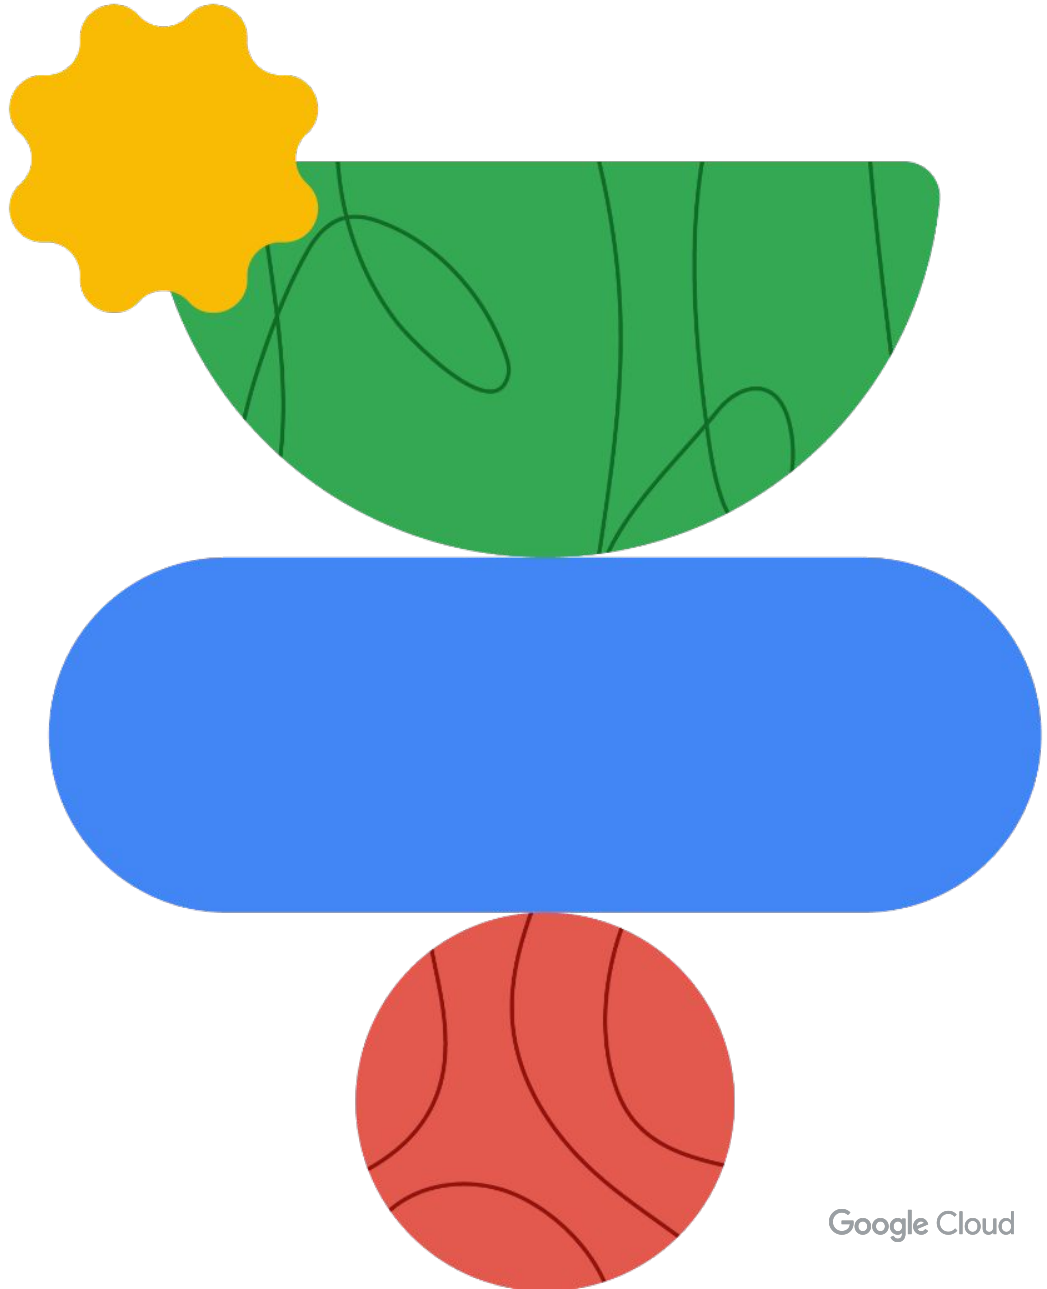


意思決定

CoT は内部推論に重点を置く一方、ReAct は外部とのやり取りを可能にする。これらのプロンプト エンジニアリング手法を組み合わせると、より深い推論と動的なアクションを実現できる。

機密 / 専有情報

ツールの追加



エージェント ツールの種類：主要な 4 つの分類

4 つのツールを組み合わせることで、エージェントは高度な自律的課題解決を実現

💡 **ツール全体の役割**：目標達成に必要な**スキル・接続・知識** を提供。情報アクセス、アクション実行、外部システム連携を自律的に行います。

拡張機能（API）

外部連携・標準化

外部 API とのやり取りを標準化し、サービスやデータへのアクセスを簡素化します。

💡 **活用例**

旅行予約エージェントが旅行会社API と通信し、フライト検索・予約に集中

関数

特化アクション

再利用可能な特化アクションをカプセル化し、推論システムがタスクに応じて選択・実行します。

💡 **活用例**

フライト情報と乗客データから合計金額を算出する「calculate_price」関数を自動呼出

データストア

情報・ナレッジ

リアルタイム情報・過去履歴・ナレッジベースに接続し、正確で関連性の高い回答を保証します。

💡 **活用例**

最新の気象情報、リアルタイム株価、顧客管理データベースを参照して情報を提供

プラグイン

機能拡張・統合

外部サービスやプラットフォームと連携し、新しいスキルとインテグレーションを追加します。

💡 **活用例**

カレンダーアプリでのスケジュール登録や、決済ゲートウェイによる決済処理

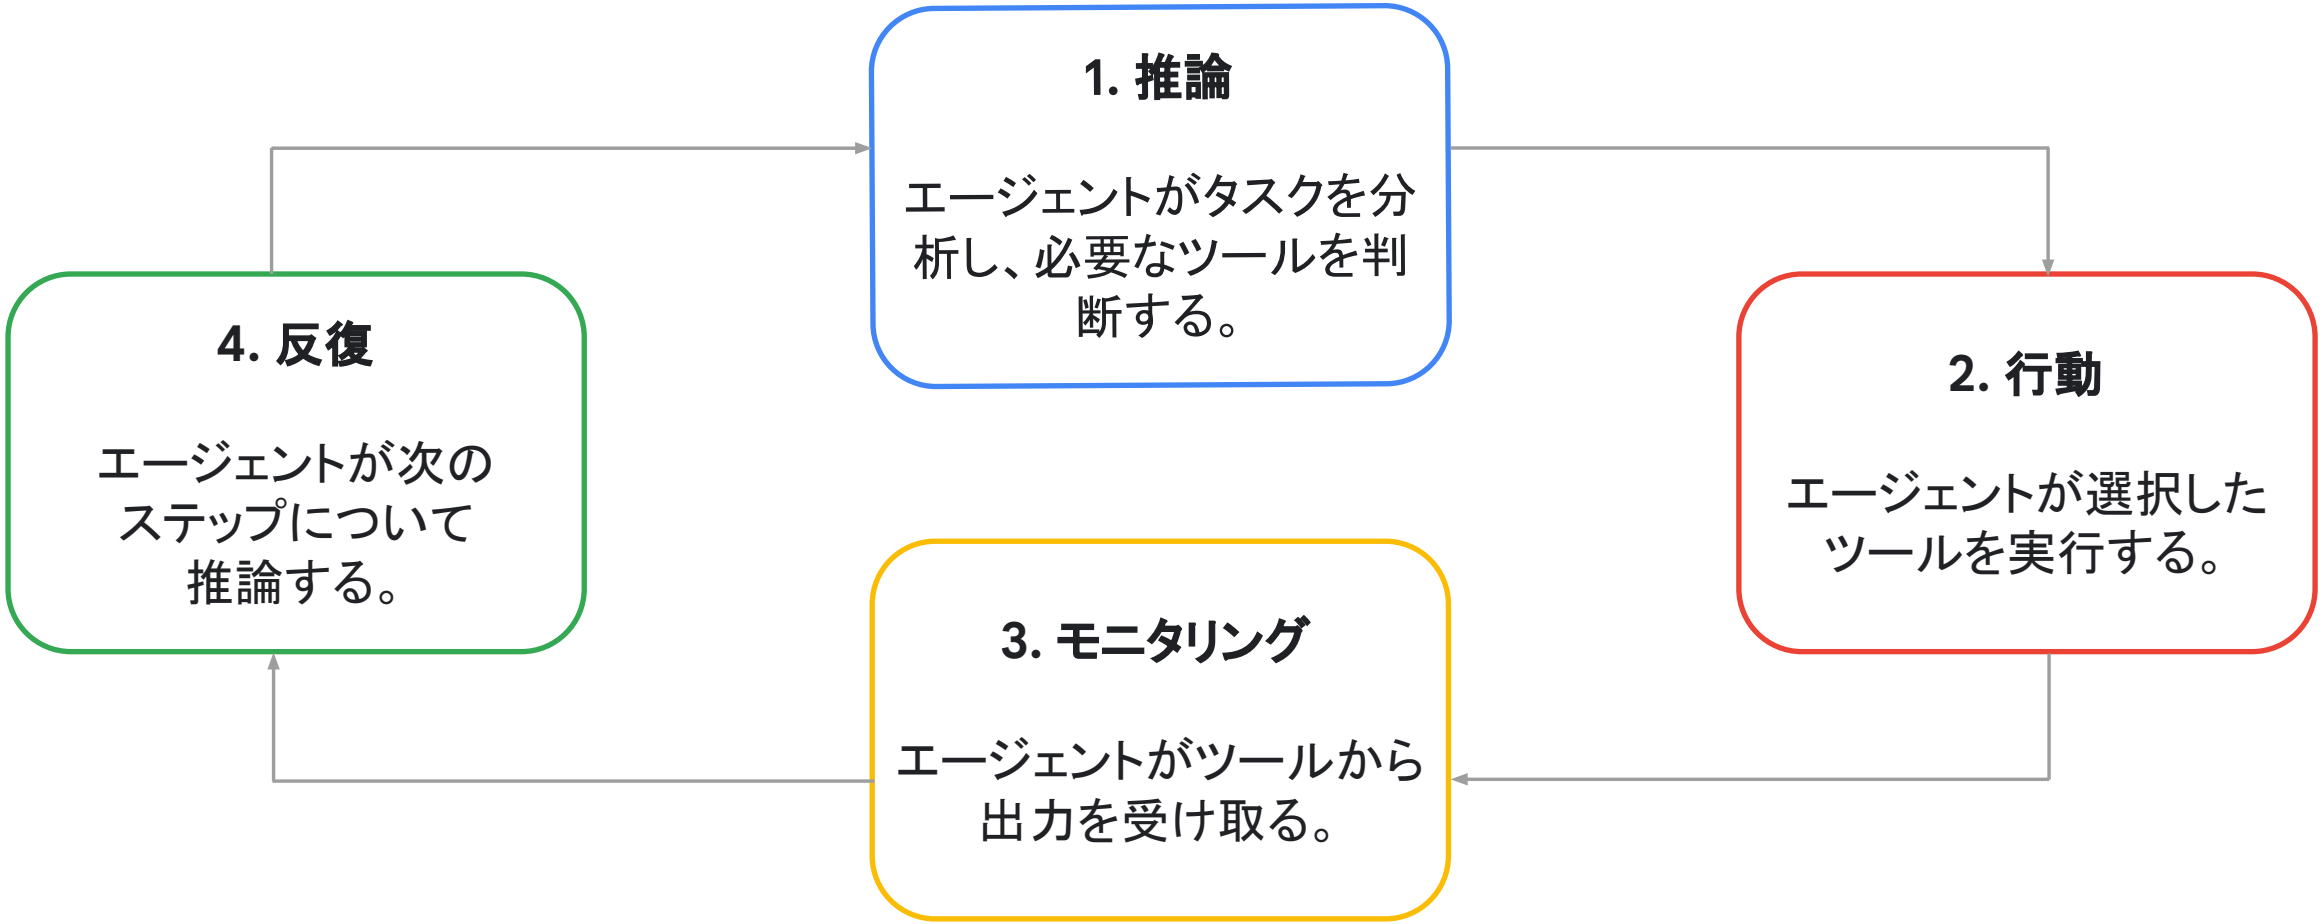
機密 / 専有情報

推論ループとツールが連動する仕組み



機密 / 専有情報

推論ループとツールが連動する仕組み



例: ガーデン コンサルティングのスケジュール設定



1. エージェントは、ガーデン コンサルティングの空き時間を見つける必要がある。
2. エージェントがスケジュール設定プラグインを使用して、造園家の翌週の空き状況を確認し、顧客データベースにアクセスする。
3. スケジュール設定プラグインから、空いている時間枠のリストが返される。
4. エージェントが、空いている時間枠をクライアントに提示する。

Google のツール: エージェント向けの主要な Google Cloud ツール

Cloud Storage	オブジェクト保存	**エージェント用データの安全な保管と取得** スケーラビリティと高耐久性を備え、大容量ファイルや各種ログを保持
データベース	データ永続化	**Cloud SQL / Spanner / Firestore の活用** 情報の保存・取得、ユーザーデータ管理、進捗状況の追跡を担う
Cloud Run functions	サーバーレス関数	**特化型タスクを実行する軽量ツール作成** 外部 API 呼出や DB 接続を自動スケーリング環境で迅速に実行・トリガー
Cloud Run	コンテナ実行基盤	**高度な依存関係を持つカスタム ツールの運用** ステートレスなコンテナをサーバーレスでデプロイし、より細かな実行制御を実現
Agent Platform	エージェント統合	**他エージェントから呼び出されるツールの構築** 独立した専門モデルやエージェント同士を「ツール」として相互連携・オーケストレーション

Google のツール: その他の構築済み AI API

Document AI API

さまざまなドキュメント形式からデータを抽出する API。

データ キャプチャやドキュメント処理の自動化に対応。

ドキュメントの要約にも対応。

Cloud Vision API

開発者が画像の内容を理解するために使用できる API。

画像のタグ付け、コンテンツの管理、画像検索に対応。

Cloud Video Intelligence API

開発者が動画コンテンツを分析し、有益な情報を抽出するために使用できる API。

コンテンツのレコメンデーション、動画検索、メディア分析に対応。

Natural Language API

非構造化テキストから分析情報を抽出できるようにする API。

テキストに込められたセンチメントの理解、コンテンツの分類、重要なエンティティの抽出に対応。

他プロダクトと連携する大規模な API ライブラリ

Google Cloud では、使い慣れた主要なGoogle プロダクトにリンクされた豊富なAPI 群を提供しています。



Google Maps

位置情報、ルート検索、プレイス情報などをダイナミックにアプリケーションに統合します。



Google Workspace

Gmail、カレンダー、ドライブなどの生産性向上ツールとシームレスに機能連携します。



YouTube

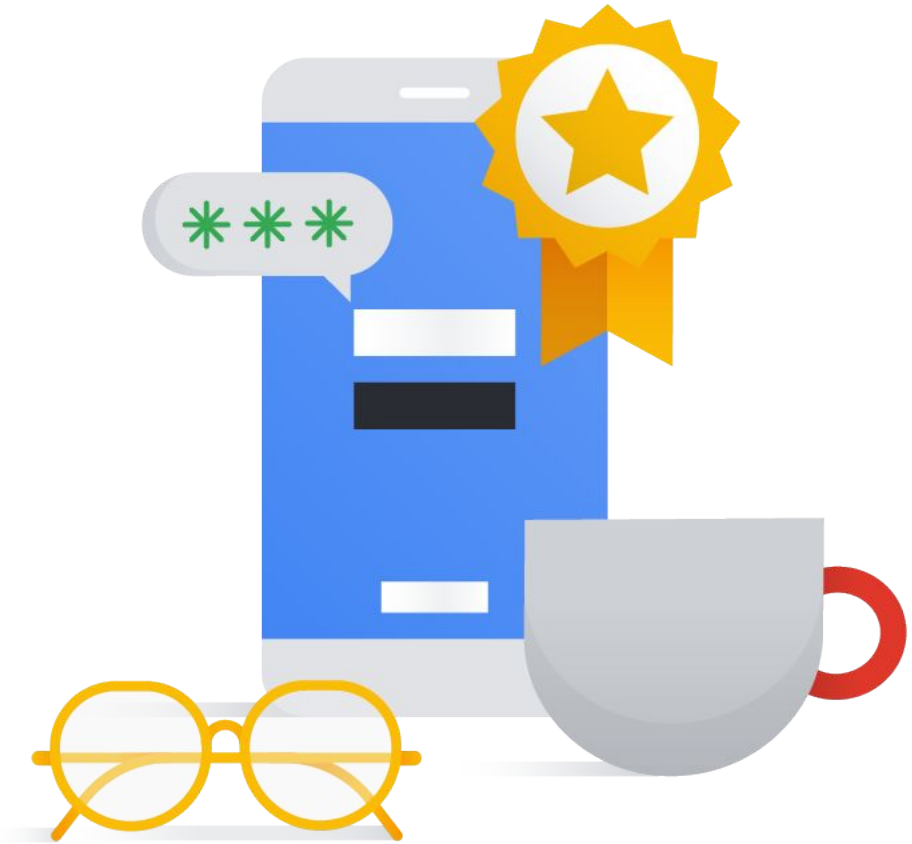
動画のアップロード、プレイリスト管理、検索・再生機能を独自システムに組み込みます。



Google Photos

写真やアルバムの安全なアップロード、自動共有、スマートな検索ロジックを実装します。

簡単な理解度チェックに挑戦しましょう



理解度チェック | 問題 01

質問

Gemini の出力のランダム性と創造性を制御するには、Google AI Studio でどのパラメータを調整しますか。

A. トークン数

B. 温度

C. 安全性設定

D. 出力長

理解度チェック | 問題 01

正解

Gemini の出力のランダム性と創造性を制御するには、Google AI Studio でどのパラメータを調整しますか。

A. トークン数

B. 温度 

C. 安全性設定

D. 出力長

理解度チェック | 問題 02

質問

ターゲット ユーザーという観点での Google AI Studio と Agent Studio の主な違いは何ですか。

A. Google AI Studio はカスタムモデルを構築するために使用し、Agent Studio はトレーニング済みモデルを利用するために使用する。

B. Google AI Studio は画像生成モデルにアクセスするために使用し、Agent Studio はテキストベースのモデルにアクセスするために使用する。

C. Google AI Studio は初心者やテスト向けに設計されている一方、Agent Studio はプロフェッショナルや大規模なプロジェクトを対象にしている。

D. Google AI Studio ではコーディングの経験が必要になる一方、Agent Studio ではノーコードインターフェースでモデルを操作できる。

理解度チェック | 問題 02

正解

ターゲット ユーザーという観点での Google AI Studio と Agent Studio の主な違いは何ですか。

A. Google AI Studio はカスタムモデルを構築するために使用し、Agent Studio はトレーニング済みモデルを利用するために使用する。

B. Google AI Studio は画像生成モデルにアクセスするために使用し、Agent Studio はテキストベースのモデルにアクセスするために使用する。

C. Google AI Studio は初心者やテスト向けに設計されている一方、Agent Studio はプロフェッショナルや大規模なプロジェクトを対象にしている。



D. Google AI Studio ではコーディングの経験が必要になる一方、Agent Studio ではノーコードインターフェースでモデルを操作できる。

理解度チェック | 問題 03

質問

次のうち、生成 AI エージェント内で生じる「推論ループ」の役割として最も適切な説明はどれですか。

A. エージェントが逸脱することなく従う 1 回限りの一連の指示を設定する。

B. エージェントがプロンプトや質問に応答し、会話形式でユーザーとやり取りできるようにする。

C. 観察、内部推論、意思決定というプロセスの反復により、タスクに対処するようエージェントを導く。

D. エージェントの行動を事前定義された応答一式に制限し、予測可能な動作を保証する。

理解度チェック | 問題 03

正解

次のうち、生成 AI エージェント内で生じる「推論ループ」の役割として最も適切な説明はどれですか。

A. エージェントが逸脱することなく従う 1 回限りの一連の指示を設定する。

B. エージェントがプロンプトや質問に応答し、会話形式でユーザーとやり取りできるようにする。

C. 観察、内部推論、意思決定というプロセスの反復により、タスクに対処するようエージェントを導く。



D. エージェントの行動を事前定義された応答一式に制限し、予測可能な動作を保証する。

理解度チェック | 問題 04

質問

チーム会議のスケジュール設定を AI エージェントに任せるとします。エージェントは、チームメンバーのカレンダーにアクセスして、適切な時間枠を提案し、招待状を送信する必要があります。このタスクにおいて最も重要なエージェント ツールの組み合わせはどれですか。

A. 拡張機能とプラグイン

B. データストアと関数

C. プラグインとデータストア

D. 関数とデータベース

理解度チェック | 問題 04

正解

チーム会議のスケジュール設定を AI エージェントに任せるとします。エージェントは、チームメンバーのカレンダーにアクセスして、適切な時間枠を提案し、招待状を送信する必要があります。このタスクにおいて最も重要なエージェント ツールの組み合わせはどれですか。

A. 拡張機能とプラグイン

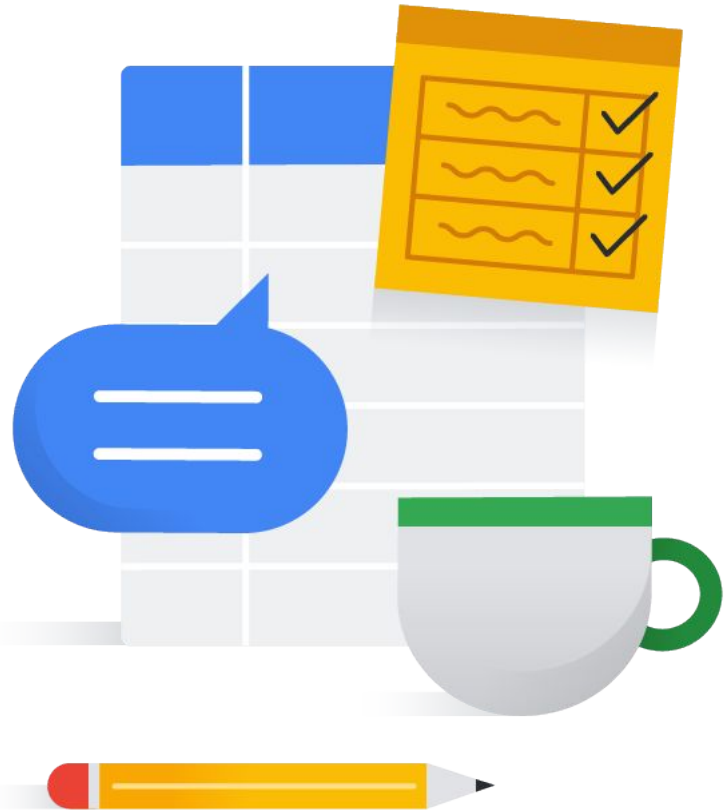
B. データストアと関数

C. プラグインとデータストア

D. 関数とデータベース

重要ポイント

- 生成 AI はテキストを作成するためにパターンを学習するAgent Studio や Google AI Studio などのツールを使用すると、パラメータを調整してアプリケーション統合をカスタマイズできる。
- 推論ループで情報を処理して、AI エージェントを意思決定に導く。プロンプト エンジニアリングにより、推論が強化され、効果的なやり取りになる。
- エージェント ツールは、AI がアクションを実行するための手段となる。複雑なタスクやインテリジェントなやり取りに対応させるために、AI エージェントにツールを提供する。
- 生成 AI を統合するには、各種のツールを使用できる。マルチエージェント システムを使用すると、多様なアプリケーションの効率が高まる。





アジェンダ

01 昨今のエージェント

02 エージェントの構築

03 エージェントによるカスタマー エクスペリエンスの向上



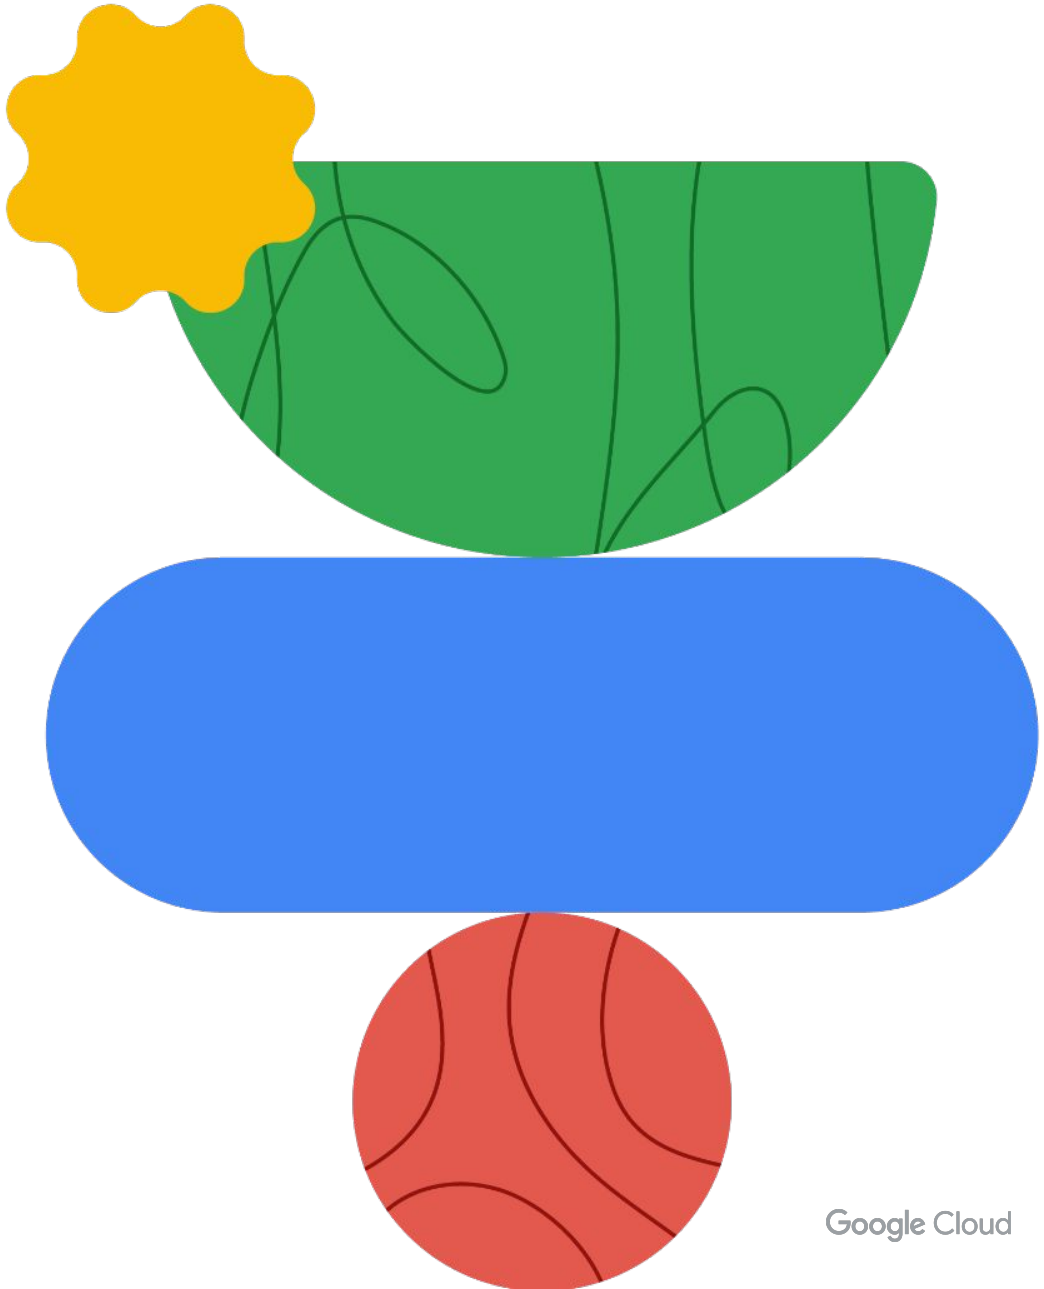
機密 / 専有情報



エージェントによるカスタマー エクスペリエンスの向上

機密 / 専有情報

検索拡張生成（RAG）とツール



モデルと RAG が連携する仕組み

検索拡張生成（Retrieval-Augmented Generation）における 3 つの基本ステージと反復サイクル

RAG とはLLM の回答を**外部の知識源に根拠づける（グラウンディング）**　技術。最新情報や社内データを取り込み、正確な回答を実現
ハルシネーション抑制最新データ即時反映出典・根拠の明記

Step 01 / Retrieval 取得

ユーザーの質問をもとに、検索ツールを備えた LLM が**外部ソースから関連情報を探索・特定**します。

主な検索ツールとソース

データストア	社内DB・ファイル等
ベクトル DB	類似度高速マッチ
検索エンジン	Web公開情報
ナレッジグラフ	関係性・事実データ

Step 02 / Augmentation 拡張

取得した関連情報をプロンプトへ組み込み、**LLM が文脈を理解できるよう入力を強化**します。

プロンプトの統合イメージ

ユーザーの元の質問＋検索で得た関連文脈

▼

拡張プロンプト（Augmented Prompt）

モデルの再学習なしで、固有の背景知識や最新の事実をプロンプト経由で動的に注入

Step 03 / Generation 生成

拡張されたプロンプトを LLM が処理し、**事実に基づいた正確で文脈に沿った回答を出力**します。

出力のメリットと特徴

✔**高い精度と適合性**：事実コンテキストに沿って的確に推論

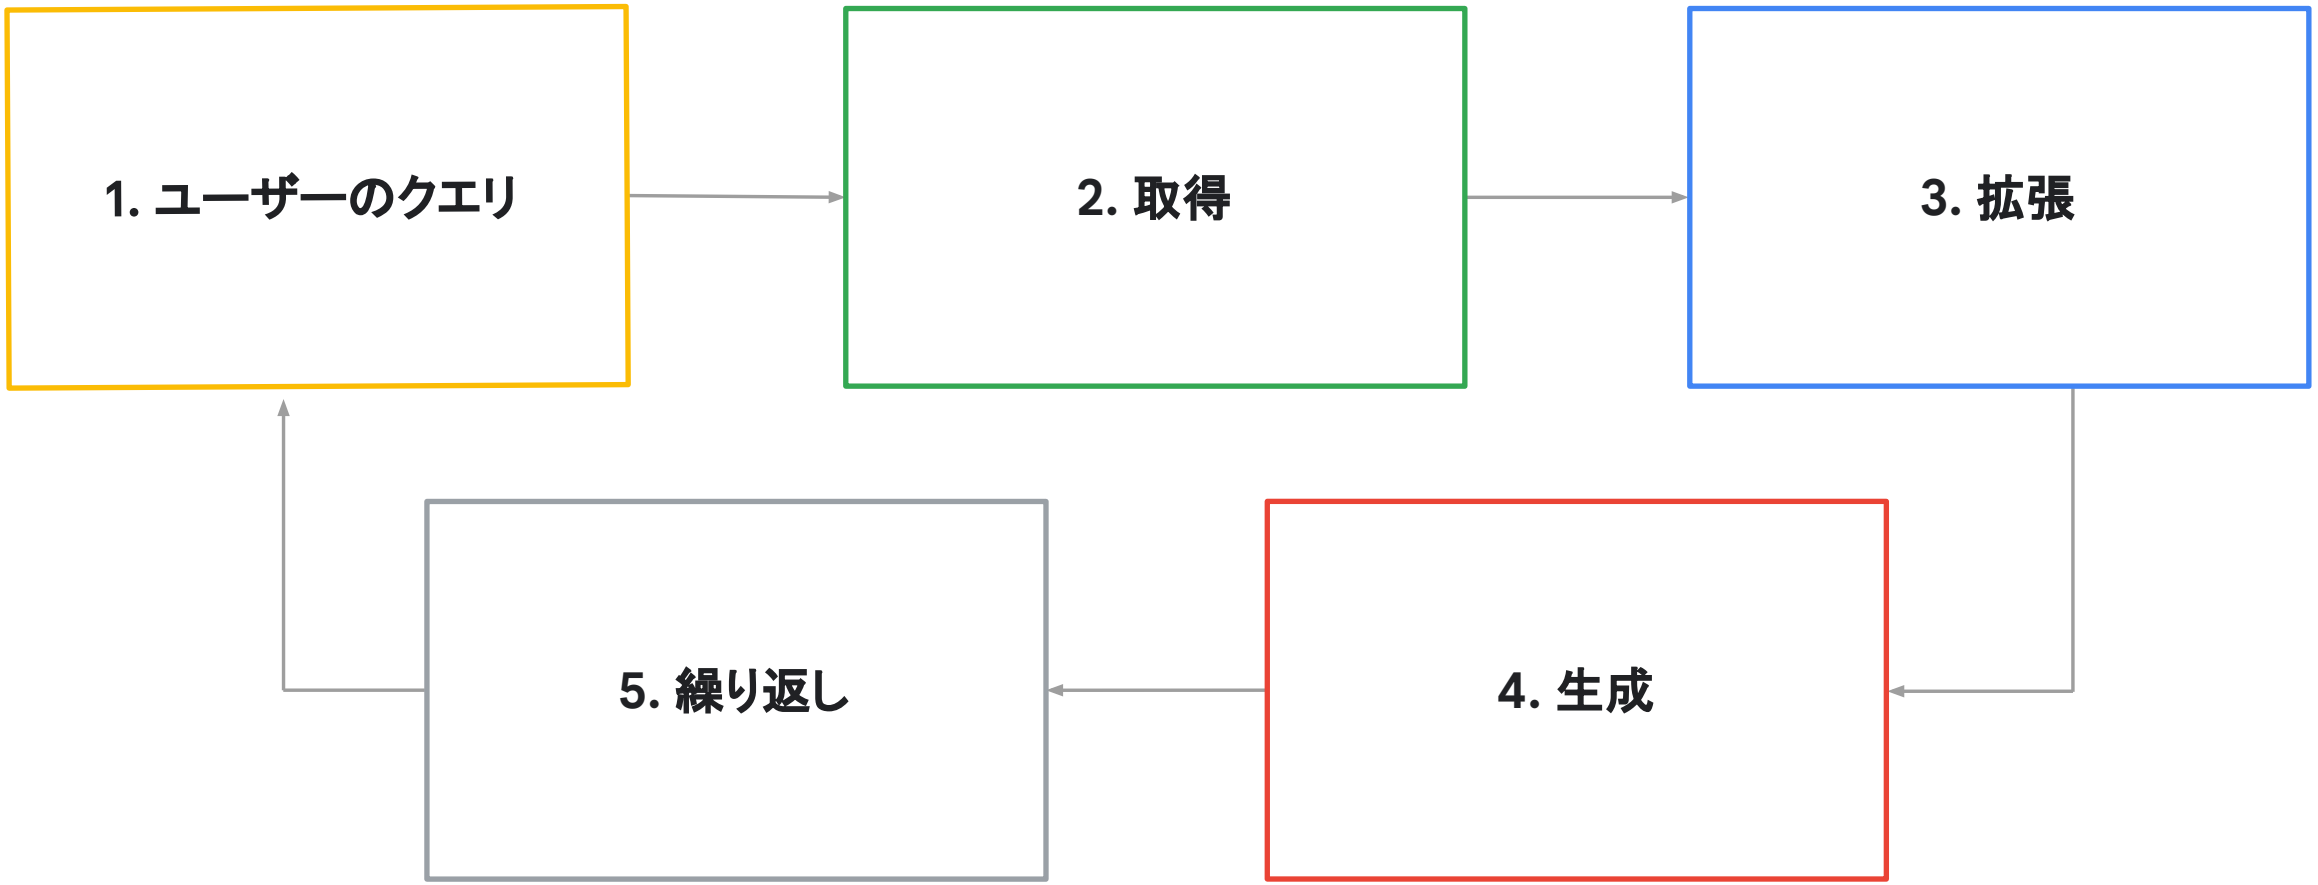
✔**出典の透明性**：参照した情報源（URL・文書）を明記し検証を容易化

✔**再学習コスト不要**：巨大な基盤モデルを再学習させずに常に最新化

発展：反復（Iteration）
初回検索で十分な情報が得られない場合、**クエリの自動再調整・別ツールの併用・ユーザーへの確認質問**　を行い、回答の品質を継続的に向上させる

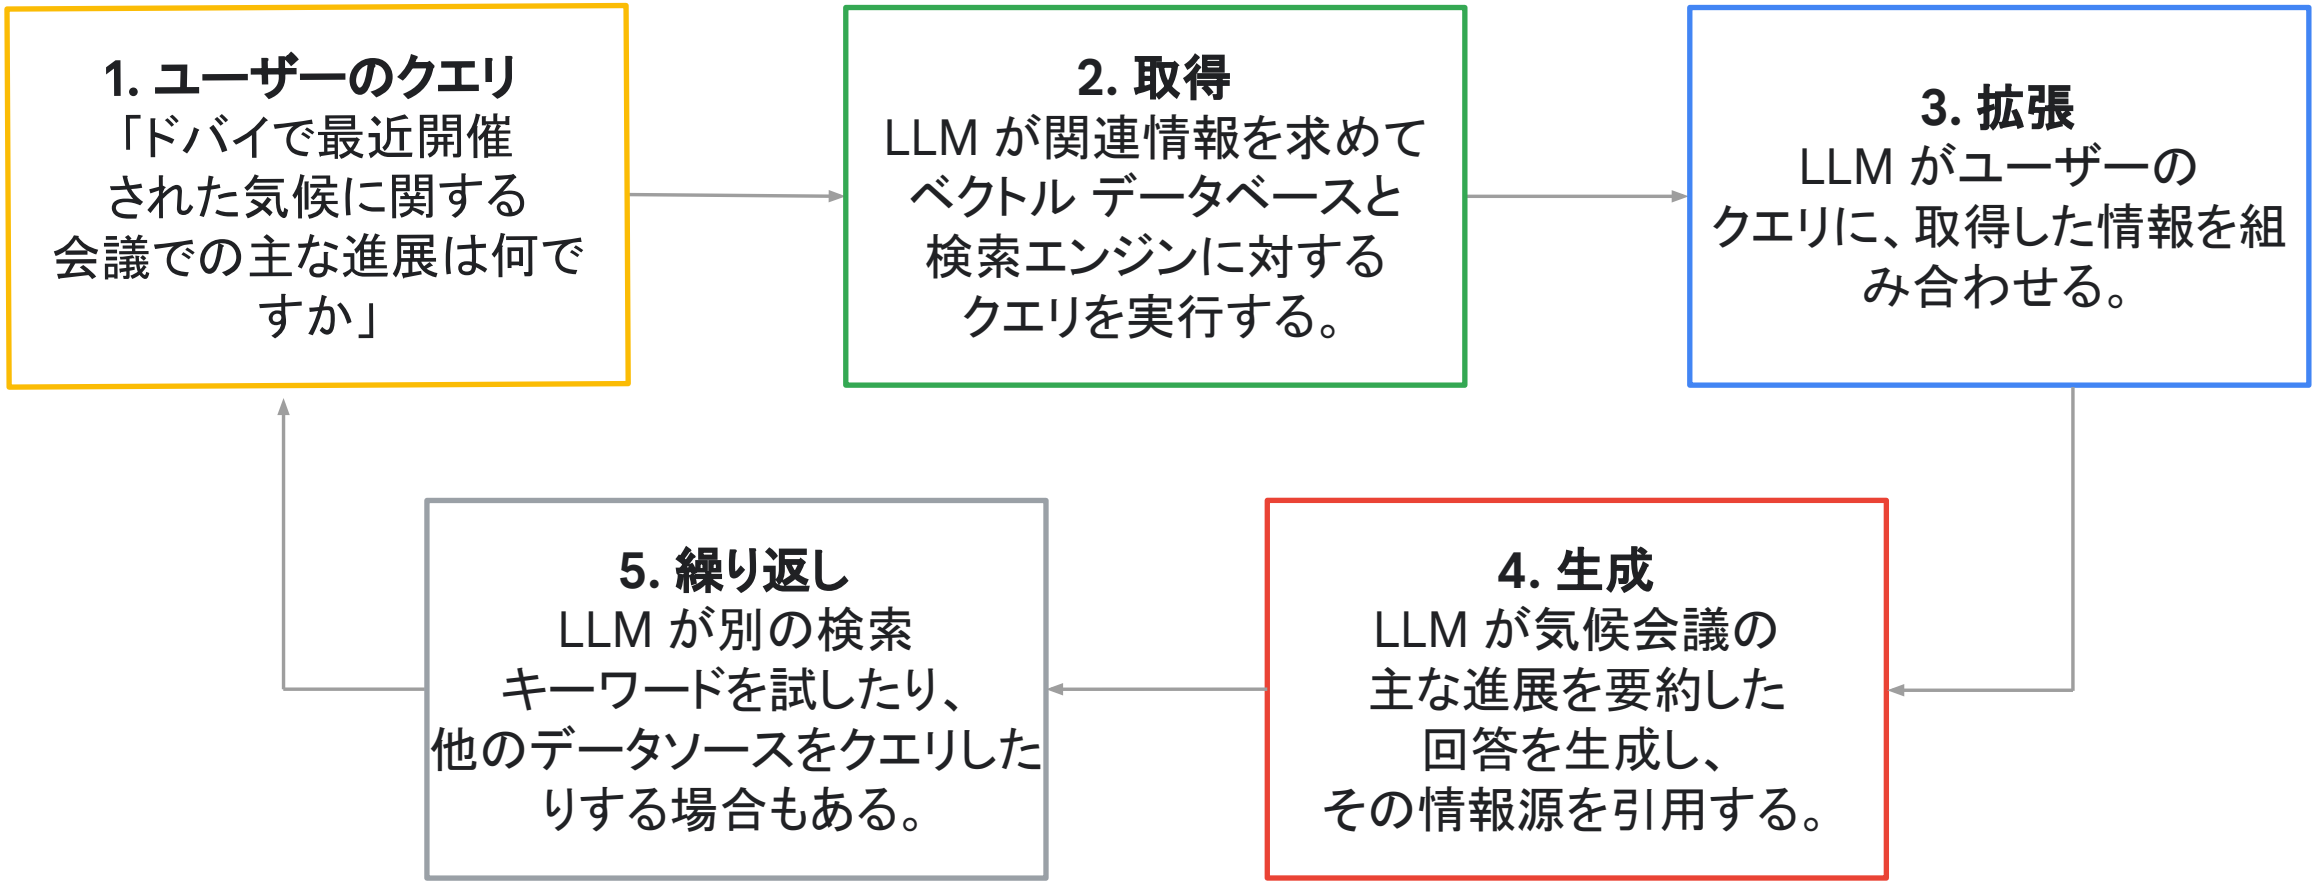
機密 / 専有情報

RAG の例: 最近の出来事に関する質問に答える



機密 / 専有情報

RAG の例: 最近の出来事に関する質問に答える



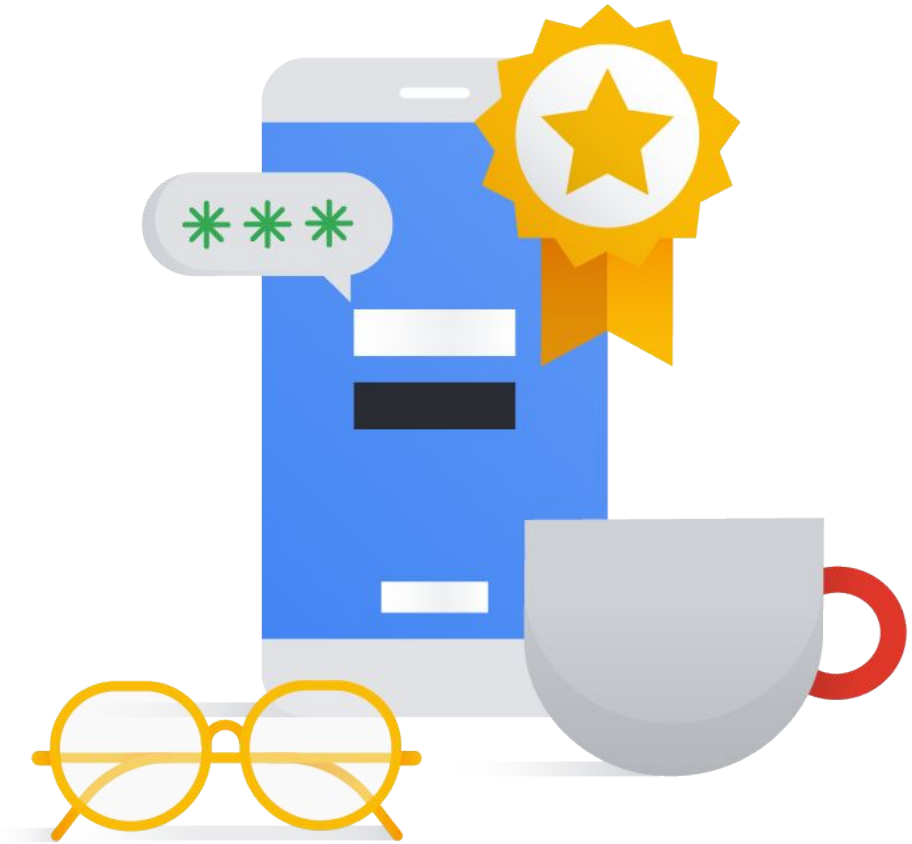
データストア

AI アプリケーション内のデータストアは、エージェントが活用できる構造化ナレッジベースおよび非構造化ナレッジベースとして機能する。

- ウェブサイト
- 構造化データベース
- 非構造化データ



簡単な理解度
チェックに挑戦
しましょう



理解度チェック | 問題 01

質問

ユーザーのクエリに基づいてナレッジベースから関連ドキュメントを取得するのは、
RAG のどの段階ですか。

A. 取得

B. 拡張

C. 生成

理解度チェック | 問題 01

正解

ユーザーのクエリに基づいてナレッジベースから関連ドキュメントを取得するのは、
RAG のどの段階ですか。

A. 取得



B. 拡張

C. 生成

理解度チェック | 問題 02

質問

ユーザーのクエリに対する回答を自然言語で作成するのは、RAG のどの段階ですか。

A. 取得

B. 拡張

C. 生成

理解度チェック | 問題 02

正解

ユーザーのクエリに対する回答を自然言語で作成するのは、RAG のどの段階ですか。

A. 取得

B. 拡張

C. 生成 

理解度チェック | 問題 03

正解

ナレッジベースからの追加情報を含めて、クエリにコンテキストを追加するのは、
RAG のどの段階ですか。

A. 取得

B. 拡張

C. 生成

理解度チェック | 問題 03

正解

ナレッジベースからの追加情報を含めて、クエリにコンテキストを追加するのは、
RAG のどの段階ですか。

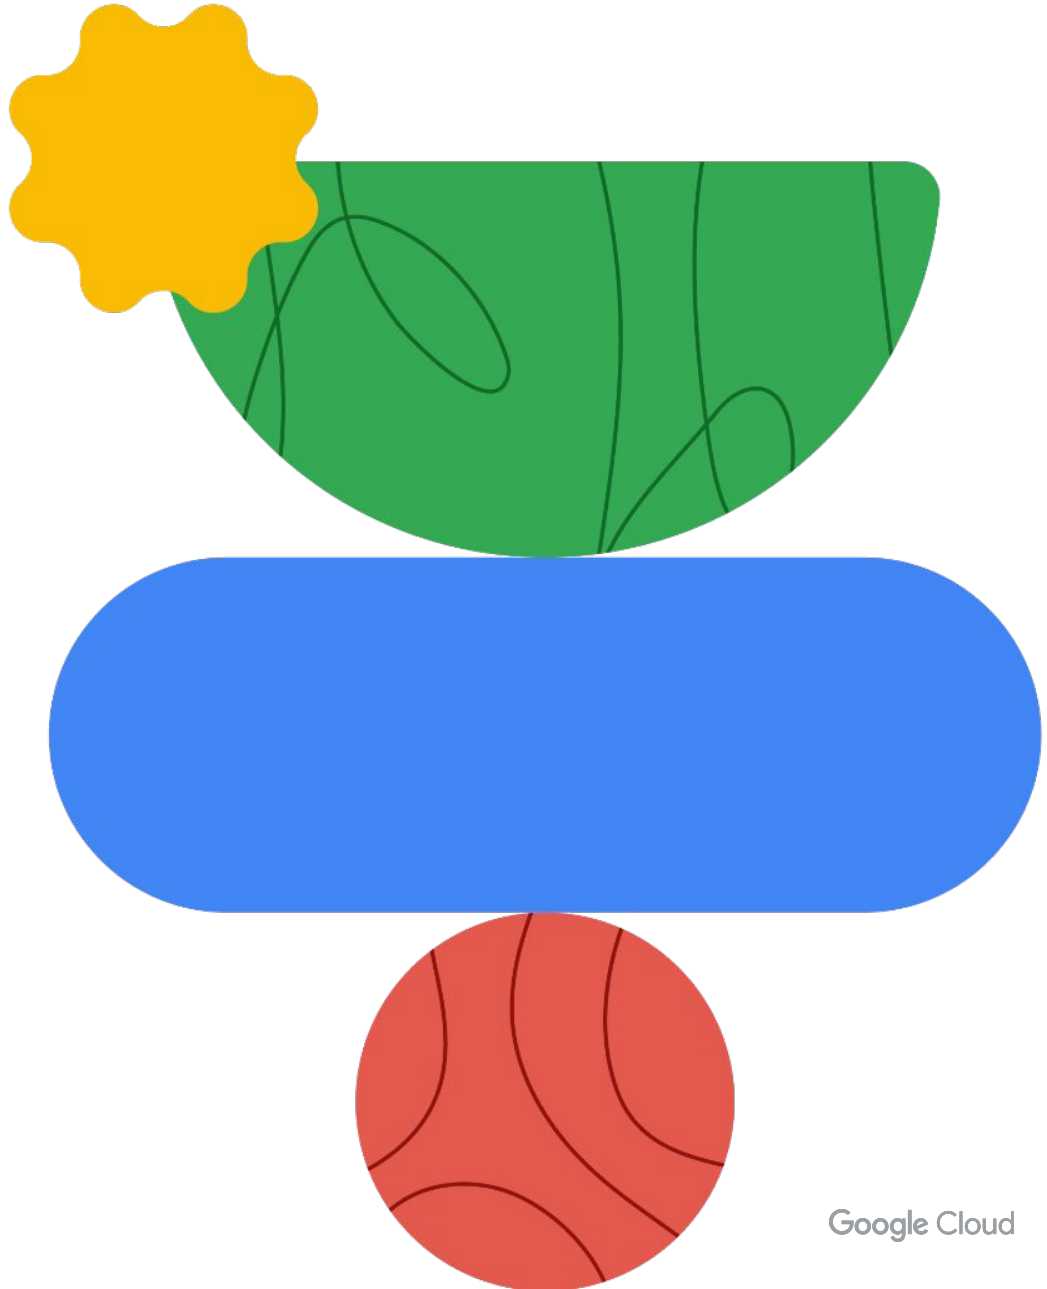
A. 取得

B. 拡張 

C. 生成

機密 / 専有情報

検索エージェントの力



Agent Platform: 検索ソリューション

ドキュメント検索

Google Cloud Storage に保存されている非構造化ドキュメントで構成されている大規模なリポジトリを検索するために使用する。

メディア検索

リッチメディア ライブラリで使用する。

画像、動画、音声ファイル内の情報を理解して検索する。

ヘルスケア検索

規制遵守に対応しつつ、ヘルスケア
データ全体を
検索できる。

Search for commerce

小売カタログ用の検索アプリを構築することに重点が置かれている。

Agent Platform: レコメンデーション ソリューション

メディア レコメンデーション

音声や動画のストリーミング、デジタル パブリッシングなど、一般ユーザー向けのメディア アプリケーションに合わせて調整されている。

Search for commerce

パーソナライズされたおすすめの商品情報を提供して販売を促進するよう、eコマース向けに最適化されている。

Agent Search の仕組み

- Agent Search は、インテリジェントなデータ接続と生成 AI を使用する。エージェントとして機能し、コンテキストに基づいて各種データストアから情報を取得して推奨する。
- **主な強み：** ファーストパーティ データ、キュレートされたサードパーティ データ、さらには Google のナレッジグラフを使用して、生成 AI LLM の回答をグラウンディングする（RAG アプローチを使用）。



Agent Search: その他の生成 AI 機能

検索結果の要約

簡潔でカスタマイズされた検索結果の要約を生成し、ユーザーの時間を節約して、概要や比較結果をすばやく提供する。

回答とフォローアップ

AI が生成した回答を検索結果に追加する。

ユーザーは自然言語で質問できる。

Agent Search：高度な統合と検索の最適化

アプリの強化

あらゆる規模の企業が、内部アプリケーションと外部アプリケーションの両方を強力にサポート・強化できます。

シームレスな統合

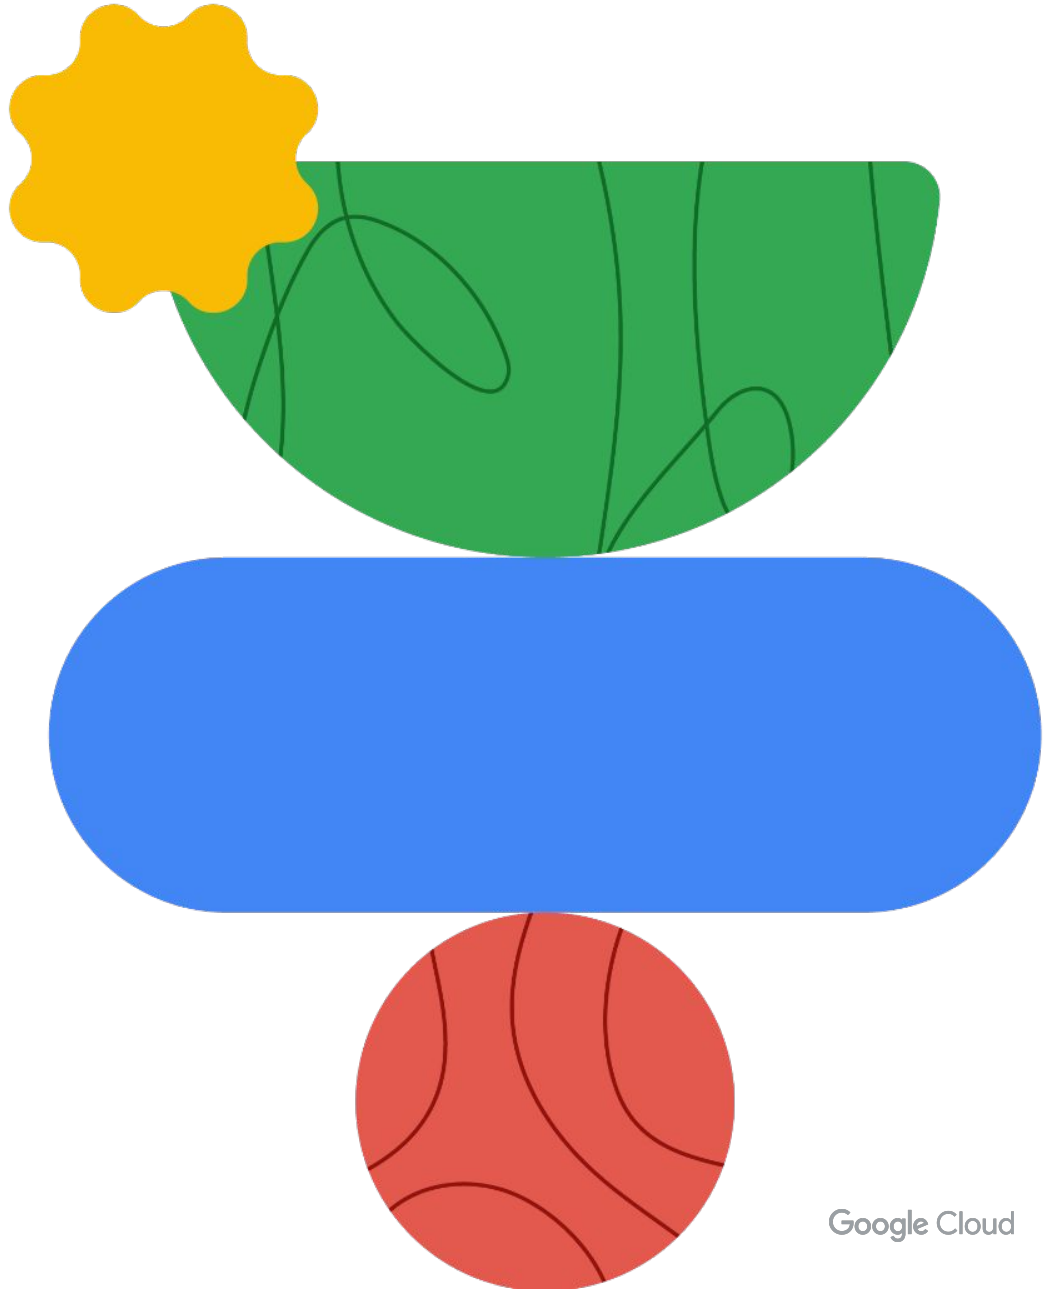
API や SDK を介して、安全で高度な検索機能を既存のシステムやアプリへ簡単かつ迅速に統合します。

安全・スケーラブル

高度な分析機能を備え、セキュアでエンタープライズレベルの拡張性を持つ検索エンジンを実現します。

機密 / 専有情報

顧客エンゲージメント



Gemini Enterprise for CX

カスタマー エクスペリエンス エージェント

顧客と効果的にコミュニケーションを取る chatbot として機能する。

Agent Assist

コンタクト センターで業務を行う人間のエージェントを支援する。

カスタマー エクスペリエンスのインサイト

顧客とのコミュニケーションすべてに関する分析情報を取得できる。

カスタマー エクスペリエンス エージェント

01 決定論的

決定論的エージェントは明示的に定義されたルールとロジックに従う。どのアクションでも必要となるコードは少ないか中程度。

02 生成

生成エージェントは、LLM を使用して自然な会話を行う。最小限のコードまたはコードなしで、プロンプトに基づいてアクションを決定する。

03 ハイブリッド

CX Agent Studio を使用して、決定論的制御と生成 AI の柔軟性を組み合わせたハイブリッド エージェントを実現することで、カスタマー サービスを向上できる。

Agent Assist

AI が以下の点でリアルタイムに人間のエージェントをサポートする。

- 回答の生成
- ナレッジベースの提案
- 音声文字変換
- Translation
- 迅速かつ的確な解決に向けた要約



カスタマー エクスペリエンス インサイト（CX インサイト）

顧客対話の分析

効率を高め、エージェントのパフォーマンスを改善するために、顧客とのやり取りを分析する。

生成 FAQ の活用

生成 FAQ で、よくある質問と回答の有効性を特定し、改善すべき領域を明らかにする。



Contact Center as a Service (CCaaS)

24時間365日体制のサポートと統合ツールにより、複雑なコンタクトセンターを簡素化

オムニチャネル サポート

- 24 時間 365 日体制の安定したサポート基盤を提供
- マルチチャネル コミュニケーションに完全対応
- 多様な顧客接点を一元化し、シームレスな対話を実現

CRM 統合

- 既存の CRM システムとの高度なデータ連携
- エージェントツールと分析システムをスムーズに統合
- リアルタイムな顧客コンテキストの把握を可能に

インフラストラクチャ管理

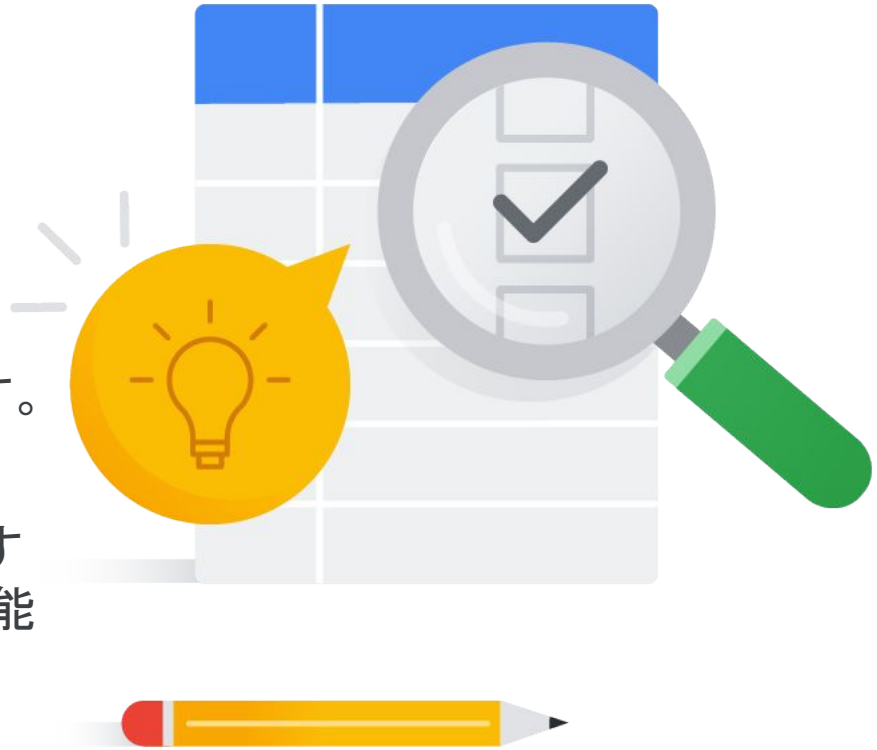
- 複雑なコンタクトセンターのインフラ構築・維持コストを削減
- クラウド化によるスケーラビリティと柔軟性の確保
- 運用負荷を軽減し、カスタマー エクスペリエンス（CX）の向上に専念

該当するプロダクト / ツールは...????

Agent Search	Agent Assist	Agent Platform レコメンデーション	Customer Experience Agent Studio
組織全体のデータを対象とした検索機能を実現する。	コンタクト センターで顧客と通話中の人間のエージェントに、ガイダンスと提案を提供する。	パーソナライズされた商品やコンテンツの候補をユーザーに提案する。	AI 搭載の chatbot と voicebot を設計、構築、デプロイするために使用される。
小売、メディア、医療などの業界向けに特化したチューニングが行われている。	人間のエージェントの効率、整合性、初回通話での解決率の向上を目的としている。	ユーザーによる関与と新たな発見を後押しすることを目的としている。	ユーザーの意図を理解して、重要な情報を抽出する。

選択肢: Agent Search、Agent Platform レコメンデーション、CX Agent Studio、Agent Assist、CX インサイト

重要ポイントの演習:
独自のエージェントを構築する（省略可）



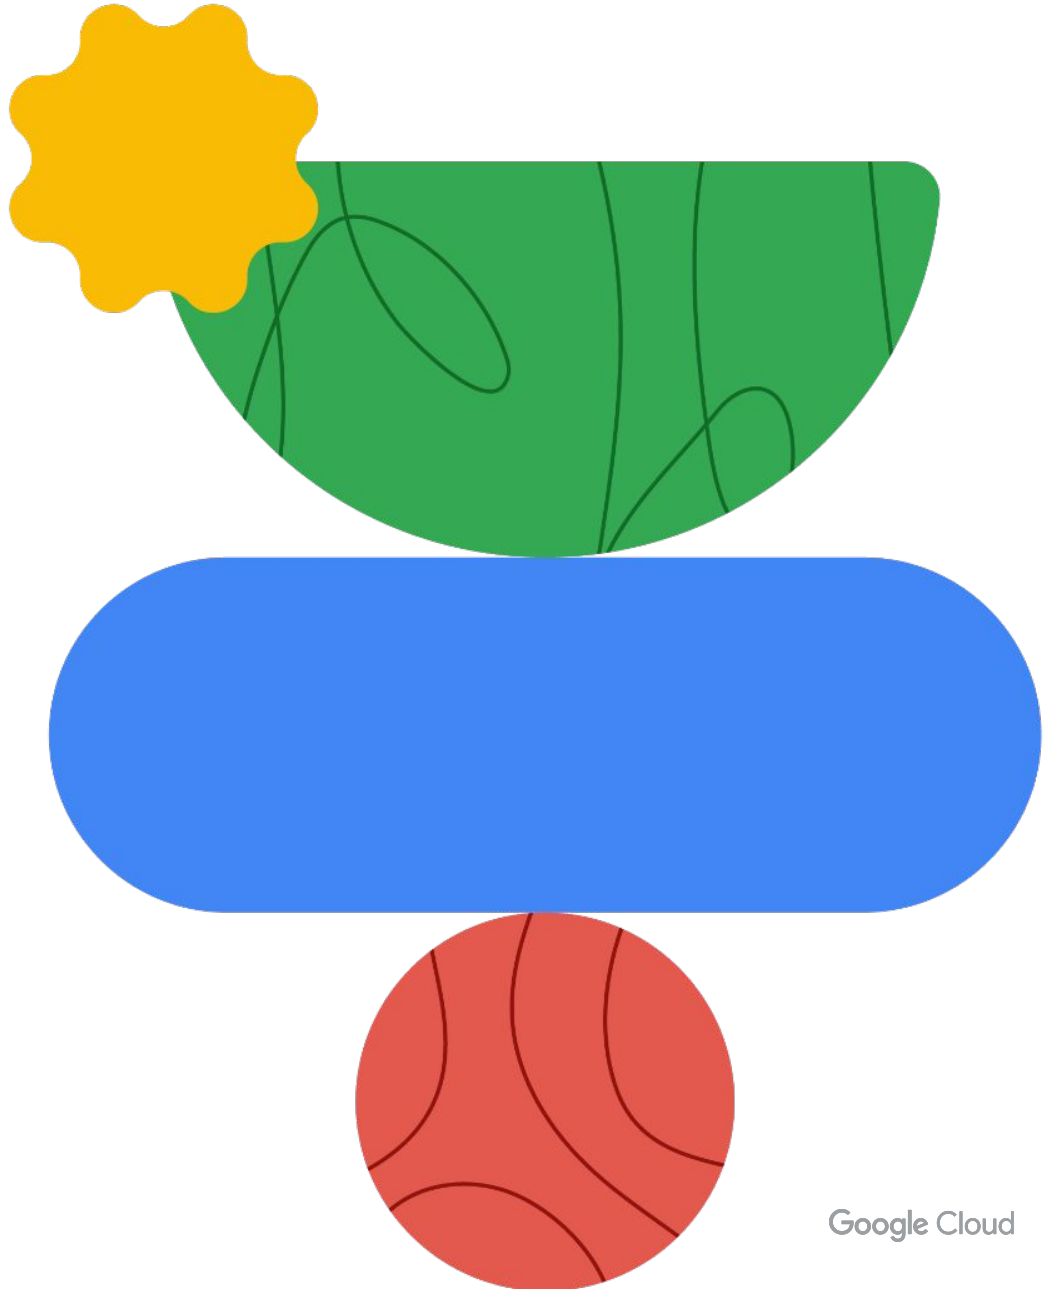
Google AI Studio を使って、Cymbal Manufacturing 社向けの完全な生成エージェントを構築する際の基本的な方法を確認します。

注: このアクティビティには、特定の Google Cloud 権限が必要ですが、受講者の皆さまの中にはその権限をお持ちでない方がいる可能性もあります。

参考資料: 重要ポイントの演習 - 独自のエージェントを構築する

機密 / 専有情報

戦略: 事前の計画



生成 AI 導入に向けた計画

生成 AI を組織に効果的に統合するための重要ステップ

明確なビジョンを確立する	戦略策定	**企業戦略との統合と推進体制の確立** リーダーの賛同確保と、現場を牽引する導入推進者の指名
影響力の高いユースケースを優先する	案件選定	**実現性と変革価値に基づく優先順位付け** 技術的実現性、データ準備状況、ビジネス目標への整合性を総合評価
能力開発に投資する	人材・文化	**スキル獲得と学習・試験運用の文化醸成** 体系的な研修・採用による人材強化と、積極的なPoC実践環境の提供
組織の変革を推進する	変革管理	**業務フロー移行と知識共有の拡大** 役割や思考の変化へプロアクティブに対応し、アジャイルな協調を促進
価値を測定し、実証する	効果測定	**データに基づく継続的な効果追跡と実証** 定量的KPIによる分析と改善を重ね、投資価値（ROI）を明確化
責任ある AI を推進する	統制・安全性	**堅牢なガバナンス フレームワークの実装** 公平性・透明性・プライバシー・セキュリティを全社横断で担保

効果に向けた計画

主な指標を定義する	目標やビジネス目標に最も関連性の高い指標を特定する。
データを収集して分析する	生成 AI イニシアチブの効果を把握するために、追跡メカニズムを確立し、アンケートを実施するとともに、既存のデータを分析する。
反復によって継続的に改善する	データから得た分析情報を基に、生成 AI 戦略に磨きをかけ、パフォーマンスを最適化する。

変化に向けた計画

戦略を定期的に
見直して改善する

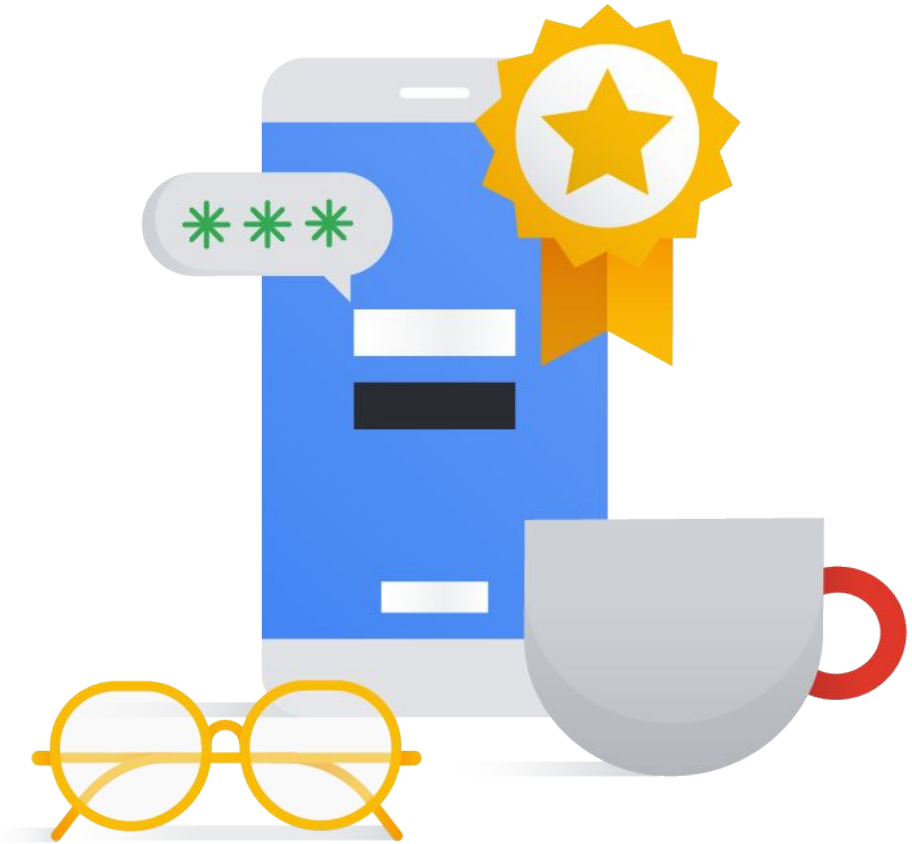
最新情報を
見逃さない

生成 AI コミュニティ
に関与する

トレーニングと能力
開発に投資する

有能な人材を獲得し
定着させる

簡単な理解度チェックに挑戦しましょう



理解度チェック | 問題 01

質問

大規模言語モデル（LLM）は、検索拡張生成（RAG）ワークフローでデータストアと
どのようにやり取りしますか。

A. LLM はデータストアに対してクエリを実行し、ユーザーのリクエストに関連する情報を取得して
回答を拡充する。

B. LLM はデータストアを使用して、基本的な知識とパラメータを永続的に拡張する。

C. LLM は、内部の知識を無視し、データストアのみに基づいて回答を生成する。

D. LLM は更新が push されるのを待ち、データストアから受動的に情報を受け取る。

理解度チェック | 問題 01

正解

大規模言語モデル（LLM）は、検索拡張生成（RAG）ワークフローでデータストアと
どのようにやり取りしますか。

A. LLM はデータストアに対してクエリを実行し、ユーザーのリクエストに関連する情報を取得して回答を拡充する。



B. LLM はデータストアを使用して、基本的な知識とパラメータを永続的に拡張する。

C. LLM は、内部の知識を無視し、データストアのみに基づいて回答を生成する。

D. LLM は更新が push されるのを待ち、データストアから受動的に情報を受け取る。

理解度チェック | 問題 02

質問

生成 AI のハルシネーションの問題を軽減するのに役立つ Agent Search のコア機能は次のうちどれですか。

A. マルチモーダル検索

B. きめ細かいアクセス制御

C. 高度な分析

D. グラウンディング

理解度チェック | 問題 02

正解

生成 AI のハルシネーションの問題を軽減するのに役立つ Agent Search のコア機能は次のうちどれですか。

A. マルチモーダル検索

B. きめ細かいアクセス制御

C. 高度な分析

D. グラウンディング 

理解度チェック | 問題 03

問題

組織で Gemini Enterprise を使用する主な目的は何ですか。

A. 会社のデータを活用して従業員を支援する AI エージェントを編成し、これらの AI エージェントにアクセスするための一元化されたプラットフォームを提供すること。

B. 組織のサイバーセキュリティ防御を強化するために、データ侵害を検出して防止すること。

C. すべての会社データを保存、管理するための中央リポジトリを作成すること。

D. AI 搭載の chatbot とやり取りできる、顧客向けインターフェースを提供すること。

理解度チェック | 問題 03

正解

組織で Gemini Enterprise を使用する主な目的は何ですか。

A. 会社のデータを活用して従業員を支援する AI エージェントを編成し、これらの AI エージェントにアクセスするための一元化されたプラットフォームを提供すること。



B. 組織のサイバーセキュリティ防御を強化するために、データ侵害を検出して防止すること。

C. すべての会社データを保存、管理するための中央リポジトリを作成すること。

D. AI 搭載の chatbot とやり取りできる、顧客向けインターフェースを提供すること。

理解度チェック | 問題 04

質問

生成 AI ソリューションを実装する際、効果に向けた計画において重要なステップは何ですか。

A. 倫理的な影響は考慮せず、AI の機能を優先する。

B. テクノロジーの導入を重視して、プラスの影響は後から付いてくるものだと想定する。

C. 最初は短期的な目標を焦点としてデータを収集し、分析する。

D. 重要な指標を定義し、データを収集して分析する作業を反復しながら改善する。

理解度チェック | 問題 04

正解

生成 AI ソリューションを実装する際、効果に向けた計画において重要なステップは何ですか。

A. 倫理的な影響は考慮せず、AI の機能を優先する。

B. テクノロジーの導入を重視して、プラスの影響は後から付いてくるものだと想定する。

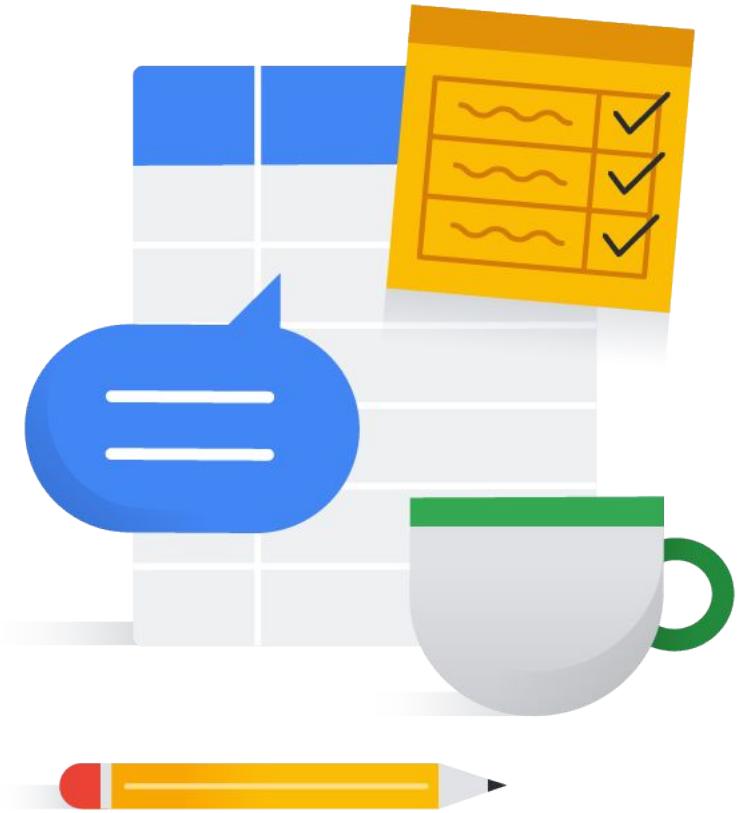
C. 最初は短期的な目標を焦点としてデータを収集し、分析する。

D. 重要な指標を定義し、データを収集して分析する作業を反復しながら改善する。

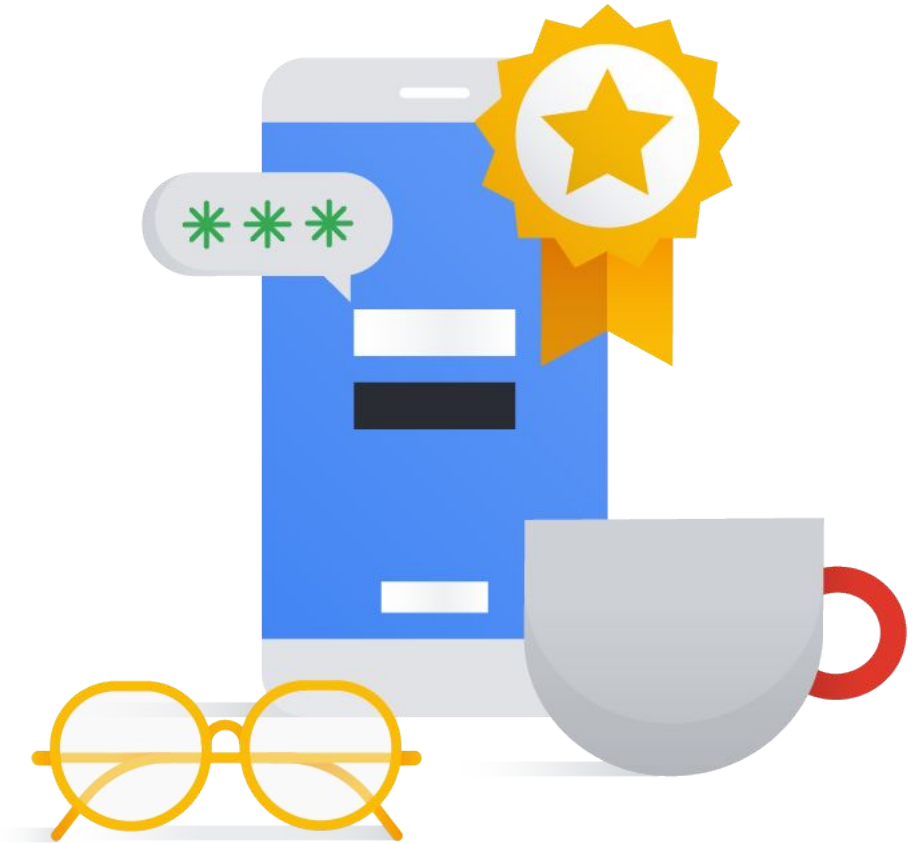


重要ポイント

- RAG を使用して正確で関連性の高い応答を目的に知識を管理するデータストアは、AI エージェントの信頼性を確保する鍵となる。
- Agent Search を統合することで、お客様は情報をより迅速に見つけて理解し、より良い意思決定と効率化を実現できる。
- Gemini Enterprise for Customer Experience では、生成 AI やその他のテクノロジーを活用して、シームレスなカスタマー エクスペリエンスに向けた優れたエージェントを提供できる。
- Gemini Enterprise は、カスタマイズされた業務用 AI アシスタント向けの安全な中央プラットフォームであり、さまざまなビジネス チームの生産性を向上させる。



最後に、モジュール 05 の理解度チェックに挑戦しましょう



理解度チェック | 問題 01

質問

AI エージェントの主な構成要素として最も適切なものは次のうちどれですか。

A. 複雑なアルゴリズム、ユーザー インターフェース、データ ストレージ システム。

B. 推論ループ、ツール、基盤モデル。

C. API 接続、Cloud Run functions、高度なデータベース。

D. 詳細なユーザー マニュアル、カスタマー サービス chatbot、高度なマーケティング手法。

理解度チェック | 問題 01

正解

AI エージェントの主な構成要素として最も適切なものは次のうちどれですか。

A. 複雑なアルゴリズム、ユーザー インターフェース、データ ストレージ システム。

B. 推論ループ、ツール、基盤モデル。 

C. API 接続、Cloud Run functions、高度なデータベース。

D. 詳細なユーザー マニュアル、カスタマー サービス chatbot、高度なマーケティング手法。

理解度チェック | 問題 02

質問

次のシナリオのうち、生成 AI のコンテキストにおけるマルチエージェント システムの概念を最もよく表しているのはどれですか。

A. メールの作成やドキュメントの要約など、複数のタスクを実行できる単一の AI エージェント。

B. データベースやウェブ検索 API などの複数のツールを使用してタスクを完了する AI エージェント。

C. それぞれに特化された複数の AI エージェントが連携して、旅行の予約などの複雑な目標を達成するシステム。

D. 各種のタスクに適応するために、さまざまなパラメータを使ってカスタマイズできる AI エージェント。

理解度チェック | 問題 02

正解

次のシナリオのうち、生成 AI のコンテキストにおけるマルチエージェント システムの概念を最もよく表しているのはどれですか。

A. メールの作成やドキュメントの要約など、複数のタスクを実行できる単一の AI エージェント。

B. データベースやウェブ検索 API などの複数のツールを使用してタスクを完了する AI エージェント。

C. それぞれに特化された複数の AI エージェントが連携して、旅行の予約などの複雑な目標を達成するシステム。



D. 各種のタスクに適応するために、さまざまなパラメータを使ってカスタマイズできる AI エージェント。

理解度チェック | 問題 03

問題

Gemini Enterprise for Customer Experience で CX エージェントを構築する際に、ハイブリッド アプローチ（決定論的 AI と生成 AI を組み合わせる）を使用する主な利点は何ですか。

A. エージェントが、シンプルで予測可能な顧客の問い合わせのみを処理するようになる。

B. 顧客とのやり取りに人間のエージェントが必要なくなる。

C. 生成 AI の柔軟性を活用しながら、エージェントの動作を厳密に制御できる。

D. エージェントの回答を事前定義されたスクリプトに制限し、整合性を確保できる。

理解度チェック | 問題 03

正解

Gemini Enterprise for Customer Experience で CX エージェントを構築する際に、ハイブリッド アプローチ（決定論的 AI と生成 AI を組み合わせる）を使用する主な利点は何ですか。

A. エージェントが、シンプルで予測可能な顧客の問い合わせのみを処理するようになる。

B. 顧客とのやり取りに人間のエージェントが必要なくなる。

C. 生成 AI の柔軟性を活用しながら、エージェントの動作を厳密に制御できる。 

D. エージェントの回答を事前定義されたスクリプトに制限し、整合性を確保できる。

機密 / 専有情報

モジュールの目的

01 生成 AI エージェントの構成要素を定義し、それぞれがどのように連携するかを確認する。

02 生成 AI エージェントの構成要素を組み合わせて、強力なソリューションを構築する方法を説明する。

03 Google Cloud の生成 AI プロダクトを使用して生成 AI エージェントおよび生成 AI ソリューションを作成する方法を説明する。

04 生成 AI を使用して、組織の変革を効果的に推進する方法を説明する。



参考情報

レッスン 02

- Agent Studio と Google AI Studio の比較
- 重要ポイントの演習 - Google AI Studio のパラメータ プレイグラウンド
- API ライブラリ
- 認証と認可を設定する
- API キーを生成する

レッスン 03

- 重要ポイント - RAG を実際に使ってみる
- 重要ポイント - 独自のエージェントを構築してみる

コースの学習ガイド



モジュール 05 試験出題ポイントチェックリスト

KEYWORD 01
エージェント 3 大構成要素

基盤モデル（LLM） 頭脳 / 動力源

自然言語の意図理解・高度な推論・回答生成

推論ループ 自律的意思決定

タスク分析・PDCA 反復による行動決定

ツール（Tools） 環境接続の手足

API・関数・データストアによる外部実行

★試験のツボ（最頻出）：
単体LLMとの決定的な違いは「推論ループ＋ツール」の有無！

KEYWORD 02
CoT vs ReAct 推論比較

CoT（思考の連鎖） 内部推論に特化

中間の推論ステップを段階的に記述

論理演算・算術の正解率向上＆思考過程を可視化

VS

ReAct（推論＋行動） 動的アクション

「思考 ➔ 行動 ➔ 観察」の反復ループで外部 API や検索を叩き、リアルタイム情報を取得

★試験のツボ（合言葉）：
内部熟考なら CoT、ツール連動・動的情報取得なら ReAct！

KEYWORD 03
データストア & Search

データストア 統合ナレッジ基盤

Web サイト・構造化 DB・PDF 文書を格納。エージェントが参照する正確な情報リポジトリ。

Agent Search (RAG) 根拠づけ

Google 検索技術を活用。社内データを高速特定し、引用付きでハルシネーションを強力抑制。

★試験のツボ（合言葉）：
「モデルの再学習なし」で最新・社内固有データに紐づける！

直前最終チェック：「推論ループ＋ツール」「内部の CoT / 外部の ReAct」「再学習不要の RAG」の 3 組を瞬時に想起！

機密 / 専有情報

モジュール 05
完了

Generative AI Leader 認定資格試験

Google Cloud Certified **Generative AI Leader**は、先見性のあるプロフェッショナルであり、Google Cloud の生成 AI プロダクトと生成 AI サービスを使用して生成 AI で企業を変革する方法について包括的なビジネス知識を有しています。Google が展開する AI ファーストのアプローチを理解しており、ユースケースの特定、技術チームと非技術チーム間のコラボレーションの促進、Google Cloud のエンタープライズ サービスの活用を通じて、革新的で責任ある AI の導入を推進することができます。



- 所要時間: 90 分
- 試験の形式: 50〜60 問の多肢選択式問題

- 詳細: cloud.google.com/learn/certification/generative-ai-leader

次のステップ

GEAR に登録すると毎月 **35** クレジットもらえる！

認定資格試験に向けて準備しましょう

- http://cloud.google.com/learn/certification/generative-ai-leader に用意されているリソースと情報を使用する
- コースの学習ガイドにアクセスする
- この ILT コースまたはオンデマンド形式の **生成 AI リーダー** 学習プログラム（https://www.skills.google/paths/1951）の資料を復習する

学習を続けましょう

- 生成 AI についてさらに詳しく学習するための他の学習プログラムやコースを調べる: https://www.skills.google/
- **中級: Google Cloud における Gemini を使用した生成 AI ラボ** で実践的な経験を積む: https://www.skills.google/paths/1872
- **Google Workspace with Gemini** で生産性と効率を向上させる: https://www.skills.google/paths/249

Gemini Notebook での学習もおすすめです ✨

質疑応答



ご参加いただき
ありがとうございました

ぜひフィードバックをお寄せください。コースの改善のために、簡単なアンケートにご協力をお願いします。

